Дополнительные главы оптимизации

Лекция 1. Выпуклость, строгая и сильная выпуклость, гладкость

План лекции

1. Постановка и выпуклые множества
2. Выпуклые функции
3. Глобальность и критерии выпуклости
4. Второй порядок
5. Строгая и сильная выпуклость
6. Гладкость
7. Квадратики, обусловленность и примеры
8. Существование решения
9. Итоги

Цели лекции

В этой лекции вводятся основные свойства функций, на которых будет строиться дальнейший анализ методов оптимизации: выпуклость, строгая и сильная выпуклость и L-гладкость.

Выпуклость позволяет превращать локальные условия оптимальности в глобальные: в частности, любая точка локального минимума выпуклой функции является точкой глобального минимума, а для дифференцируемой выпуклой функции условие $\nabla f(x^\star) = 0$ достаточно для глобальной оптимальности.

Строгая выпуклость гарантирует единственность точки минимума, если минимум достигается. Сильная выпуклость требует дополнительного квадратичного отклонения от линейной аппроксимации:

$$\frac{\mu}{2}\|y - x\|^2, \qquad \mu > 0.$$

L-гладкость ограничивает изменение градиента и даёт верхнюю квадратичную оценку. Для C^2-функции:

$$\mu I \preceq \nabla^2 f(x) \preceq LI.$$

Задача оптимизации

Рассмотрим задачу

$$\min_{x \in C} f(x),$$

где $x \in \mathbb{R}^n$ — переменная, $C \subseteq \mathbb{R}^n$ — допустимое множество, $f : C \to \mathbb{R}$ — целевая функция.

- $C = \mathbb{R}^n$: задача безусловной оптимизации;
- $C \subset \mathbb{R}^n$: задача условной оптимизации.

Оптимальное значение:

$$f^\star = \inf_{x \in C} f(x).$$

Если $f(x^\star) = f^\star$, то $x^\star$ называется точкой глобального минимума и

$$X^\star = \arg\min_{x \in C} f(x)$$

— множество решений.

Важно различать инфимум и достигаемый минимум. Пример:

$$\inf_{x > 0} x = 0,$$

но точки из допустимого множества $x > 0$, в которой значение равно нулю, не существует.

Локальный минимум

Definition 1

Точка $x^\star \in C$ называется точкой локального минимума, если существует $\varepsilon > 0$ такое, что

$$f(x^\star) \leq f(x) \qquad \forall x \in C \cap B_\varepsilon(x^\star).$$

Для общей невыпуклой задачи локальный минимум может не быть глобальным.

Одно из центральных преимуществ выпуклых задач: это различие исчезает.

Выпуклые комбинации и выпуклое множество

Definition 2

Вектор

$$x = \sum_{i=1}^{m} \theta_i x_i, \qquad \theta_i \geq 0, \qquad \sum_{i=1}^{m} \theta_i = 1$$

называется выпуклой комбинацией точек $x_1, \ldots, x_m$.

Для двух точек:

$$x = \theta x_1 + (1 - \theta) x_2, \qquad 0 \leq \theta \leq 1.$$

Definition 3

$C \subseteq \mathbb{R}^n$ выпукло, если

$$\boxed{x, y \in C,\ \theta \in [0, 1] \Longrightarrow \theta x + (1 - \theta) y \in C.}$$

Примеры выпуклых множеств I

Аффинное множество.

$$C = \{x \in \mathbb{R}^n : Ax = b\}.$$

Если $Ax = Ay = b$, то

$$A(\theta x + (1-\theta)y) = b.$$

Полупространство.

$$C = \{x \in \mathbb{R}^n : a^\top x \leq b\}.$$

Если $x, y \in C$, то

$$a^\top(\theta x + (1-\theta)y) = \theta a^\top x + (1-\theta)a^\top y \leq b.$$

Примеры выпуклых множеств II

Шар в произвольной норме.

$$C = \{x : \|x - x_0\| \leq r\}.$$

Для $x, y \in C$:

$$\begin{aligned}\|\theta x + (1-\theta)y - x_0\| &\leq \theta\|x - x_0\| + (1-\theta)\|y - x_0\| \\ &\leq r.\end{aligned}$$

Симплекс.

$$\Delta_n = \left\{ x \in \mathbb{R}^n : x_i \geq 0,\ \sum_{i=1}^{n} x_i = 1 \right\}.$$

Это пересечение полупространств $x_i \geq 0$ и аффинного множества $\sum_i x_i = 1$.

Операции, сохраняющие выпуклость множеств

Пересечение

Произвольное пересечение выпуклых множеств выпукло:

$$C = \bigcap_{\alpha} C_\alpha.$$

Если $x, y \in C$, то $x, y \in C_\alpha$ для каждого α, поэтому их выпуклая комбинация принадлежит каждому C_α.

Аффинный образ

Если C выпукло и $T(x) = Ax + b$, то $T(C) = \{Ax = b : x \in C\}$ выпукло, поскольку

$$T(\theta x + (1-\theta)y) = \theta T(x) + (1-\theta) T(y).$$

Аффинный прообраз

Если D выпукло, то множество

$$\{x : Ax + b \in D\}$$

выпукло.

Определение выпуклой функции

Пусть $C \subseteq \mathbb{R}^n$ — выпуклое множество.

Definition 4

$f : C \to \mathbb{R}$ называется выпуклой, если для любых $x, y \in C$ и $\theta \in [0, 1]$

$$\boxed{f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y).}$$

Геометрически график выпуклой функции на любом отрезке лежит не выше хорды, соединяющей значения функции на концах этого отрезка.

Неравенство Йенсена

Из определения индукцией получается конечномерное неравенство Йенсена:

$$\boxed{f\left(\sum_{i=1}^{m}\theta_i x_i\right) \leq \sum_{i=1}^{m}\theta_i f(x_i),}$$

где

$$\theta_i \geq 0, \qquad \sum_{i=1}^{m}\theta_i = 1.$$

Ограничение на прямую

Зафиксируем точку x и направление v и рассмотрим

$$\varphi_{x,v}(t) = f(x + tv)$$

на тех t, для которых $x + tv \in C$.

Критерий на прямых

f выпукла на C тогда и только тогда, когда для любой точки x и любого направления v соответствующая одномерная функция $\varphi_{x,v}$ выпукла на множестве допустимых значений t.

Иными словами, сужение f на любую прямую, пересекающую C, должно быть выпуклой функцией одной переменной. Этот принцип особенно полезен для критерия через гессиан.

Основные примеры выпуклых функций

Аффинная функция. Для $f(x) = a^\top x + b$

$$f(\theta x + (1-\theta)y) = \theta f(x) + (1-\theta)f(y).$$

Поэтому аффинная функция одновременно выпукла и вогнута.

Норма. Пусть $f(x) = \|x\|$. Тогда по неравенству треугольника и положительной однородности нормы

$$\begin{aligned} f(\theta x + (1-\theta)y) &= \|\theta x + (1-\theta)y\| \\ &\le \theta\|x\| + (1-\theta)\|y\| \\ &= \theta f(x) + (1-\theta)f(y). \end{aligned}$$

Любая норма выпукла. Выпуклость не означает гладкость: $|x|$ недифференцируема в нуле.

Неотрицательные линейные комбинации

Сохранение выпуклости

Если f_i выпуклы и $\alpha_i \geq 0$, то

$$f(x) = \sum_i \alpha_i f_i(x)$$

выпукла.

Действительно,

$$\begin{aligned} f(\theta x + (1-\theta)y) &= \sum_i \alpha_i f_i(\theta x + (1-\theta)y) \\ &\leq \sum_i \alpha_i \big(\theta f_i(x) + (1-\theta) f_i(y)\big) \\ &= \theta f(x) + (1-\theta) f(y). \end{aligned}$$

Композиции и выпуклость

Композиция с аффинным отображением

Если f выпукла, то

$$g(x) = f(Ax + b)$$

выпукла на своей области определения.

Поточечный максимум

Если $f_1, \ldots, f_m$ выпуклы, то

$$f(x) = \max_i f_i(x)$$

выпукла. В частности,

$$f(x) = \max_i (a_i^\top x + b_i)$$

выпукла.

Композиции и выпуклость

Композиция выпуклых функций

Пусть g выпукла, а f выпукла и не убывает на интервале, содержащем значения g. Тогда $h = f \circ g$ выпукла.

Действительно,

$$g(\theta x + (1-\theta)y) \leq \theta g(x) + (1-\theta)g(y),$$

а монотонность и выпуклость f дают

$$f(g(\theta x + (1-\theta)y)) \leq f(\theta g(x) + (1-\theta)g(y)) \leq \theta f(g(x)) + (1-\theta)f(g(y)).$$

Произвольная композиция: осторожно. Произвольная композиция двух выпуклых функций выпуклость сохранять не обязана.
Контрпример. $f(u) = -u$ аффинна, а значит выпукла; $g(x) = x^2$ выпукла. Однако

$$(f \circ g)(x) = -x^2$$

не является выпуклой функцией.

Множества подуровня

Definition 5

Для функции f и числа α множество

$$L_\alpha(f) = \{x : f(x) \leq \alpha\}$$

называется множеством подуровня.

Выпуклость множеств подуровня

Если f выпукла, то каждое $L_\alpha(f)$ выпукло.

Действительно, если $f(x), f(y) \leq \alpha$, то

$$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y) \leq \alpha.$$

Обратное неверно: для $f(x) = x^3$

$$L_\alpha(f) = (-\infty, \sqrt[3]{\alpha}]$$

выпукло для каждого α, но x^3 не выпукла на всей $\mathbb{R}$.

Локальный минимум выпуклой функции глобален

Theorem 6

Если f выпукла на выпуклом множестве C, то любая точка локального минимума f на C является точкой глобального минимума.

Доказательство: начало.

Предположим противное: $x^\star$ — локальный, но не глобальный минимум. Тогда существует $y \in C$:

$$f(y) < f(x^\star).$$

Для $\theta \in (0, 1)$ положим

$$x_\theta = (1 - \theta)x^\star + \theta y.$$

По выпуклости C: $x_\theta \in C$, а $x_\theta \to x^\star$ при $\theta \downarrow 0$. □

Локальный минимум выпуклой функции глобален: доказательство

Продолжение.

По выпуклости функции

$$\begin{aligned} f(x_\theta) &\leq (1-\theta)f(x^\star) + \theta f(y) \\ &< (1-\theta)f(x^\star) + \theta f(x^\star) = f(x^\star). \end{aligned}$$

Но из локальной минимальности существует $\varepsilon > 0$:

$$f(x^\star) \leq f(z) \qquad \forall z \in C \cap B_\varepsilon(x^\star).$$

При этом

$$\|x_\theta - x^\star\| = \theta\|y - x^\star\| \to 0.$$

Для достаточно малого $\theta > 0$ имеем $x_\theta \in C \cap B_\varepsilon(x^\star)$ и одновременно $f(x_\theta) < f(x^\star)$ — противоречие. □

Критерий выпуклости первого порядка

Начиная отсюда предполагаем, что функция определена и соответствующее число раз дифференцируема на открытом множестве, содержащем рассматриваемое выпуклое множество.

Theorem 7

Пусть C открыто и выпукло, $f : C \to \mathbb{R}$ дифференцируема. Тогда

$$f \text{ выпукла} \iff f(y) \geq f(x) + \nabla f(x)^\top (y - x) \quad \forall x, y \in C.$$

Геометрически касательная гиперплоскость задаёт глобальную нижнюю аффинную оценку функции.

Критерий выпуклости первого порядка: $\Rightarrow$

Proof.

Пусть f выпукла. Для $t \in (0, 1]$

$$f(x + t(y - x)) \leq (1 - t)f(x) + tf(y).$$

Следовательно,

$$\frac{f(x + t(y - x)) - f(x)}{t} \leq f(y) - f(x).$$

Переходя к пределу при $t \downarrow 0$, получаем

$$\nabla f(x)^\top (y - x) \leq f(y) - f(x),$$

то есть

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

□

Критерий выпуклости первого порядка: $\Leftarrow$

Proof.

Пусть неравенство первого порядка выполнено. Обозначим

$$z = (1-\theta)x + \theta y.$$

Тогда

$$f(x) \geq f(z) + \nabla f(z)^\top (x - z),$$
$$f(y) \geq f(z) + \nabla f(z)^\top (y - z).$$

Умножаем на $1-\theta$ и θ и складываем:

$$(1-\theta)f(x) + \theta f(y) \geq f(z),$$

поскольку

$$(1-\theta)(x-z) + \theta(y-z) = 0.$$

Следовательно, f выпукла. $\square$

Необходимое условие оптимальности первого порядка

Пусть $x^\star$ — точка локального минимума дифференцируемой функции в безусловной задаче.
Если $\nabla f(x^\star) \neq 0$, выберем

$$d = -\nabla f(x^\star).$$

Тогда

$$\nabla f(x^\star)^\top d = -\|\nabla f(x^\star)\|_2^2 < 0.$$

По дифференцируемости

$$f(x^\star + td) = f(x^\star) + t\nabla f(x^\star)^\top d + o(t), \qquad t \downarrow 0.$$

Для достаточно малого $t > 0$ получаем $f(x^\star + td) < f(x^\star)$ — противоречие с локальной минимальностью. Поэтому

$$\boxed{\nabla f(x^\star) = 0.}$$

Когда $\nabla f(x^\star) = 0$ достаточно?

Для произвольной дифференцируемой функции условие $\nabla f(x^\star) = 0$ только необходимо.
Для выпуклой функции оно также достаточно:

$$f(y) \geq f(x^\star) + \nabla f(x^\star)^\top (y - x^\star) = f(x^\star).$$

Следовательно, для безусловной дифференцируемой выпуклой задачи

$$\boxed{x^\star \in \arg\min f \quad \Longleftrightarrow \quad \nabla f(x^\star) = 0.}$$

При ограничениях это неверно

$$\min_{x \geq 1} x^2$$

имеет решение $x^\star = 1$, но $f'(1) = 2 \neq 0$.

Условие первого порядка при ограничениях

Для дифференцируемой выпуклой функции на выпуклом множестве C:

$$\boxed{\nabla f(x^\star)^\top (y - x^\star) \geq 0 \qquad \forall y \in C.}$$

Это условие необходимо и достаточно для глобальной оптимальности $x^\star$ в задаче $\min_{x \in C} f(x)$.

Достаточность:

$$f(y) \geq f(x^\star) + \nabla f(x^\star)^\top (y - x^\star) \geq f(x^\star).$$

Условие первого порядка при ограничениях: необходимость

Proof.

Зафиксируем $y \in C$ и рассмотрим

$$\varphi(t) = f(x^\star + t(y - x^\star)), \qquad t \in [0, 1].$$

По выпуклости C весь отрезок допустим. Поскольку $x^\star$ — точка минимума на C, $t = 0$ — точка минимума φ на $[0, 1]$. Поэтому

$$\varphi'(0+) \geq 0.$$

Производная

$$\varphi'(0+) = \nabla f(x^\star)^\top (y - x^\star),$$

следовательно,

$$\nabla f(x^\star)^\top (y - x^\star) \geq 0.$$

Так как $y \in C$ произвольна, условие выполнено для всех $y \in C$. □

Гессиан и матричные обозначения. Операторная норма матрицы

$f \in C^2(C)$ означает: f дважды непрерывно дифференцируема на C.
Гессиан:

$$\nabla^2 f(x) = \left(\frac{\partial^2 f(x)}{\partial x_i \partial x_j} \right)_{i,j=1}^{n}.$$

Для симметричной матрицы H:

$$H \succeq 0 \iff v^\top H v \geq 0 \quad \forall v, \qquad H \succ 0 \iff v^\top H v > 0 \quad \forall v \neq 0.$$

Для симметричных A, B:

$$A \preceq B \iff B - A \succeq 0 \iff v^\top A v \leq v^\top B v \quad \forall v.$$

В терминах собственных значений:

$$H \succeq 0 \iff \lambda_i(H) \geq 0 \ \forall i, \qquad H \succ 0 \iff \lambda_i(H) > 0 \ \forall i.$$

Операторная норма матрицы A, индуцированная евклидовой нормой:

$$\|A\|_{\text{op}} = \sup_{\|v\|_2 = 1} \|Av\|_2.$$

Для симметричной матрицы

$$\|A\|_{\text{op}} = \max_i |\lambda_i(A)|.$$

Критерий выпуклости второго порядка

Theorem 8

Пусть C открыто и выпукло, $f \in C^2(C)$. Тогда

$$\boxed{f \text{ выпукла} \iff \nabla^2 f(x) \succeq 0 \quad \forall x \in C.}$$

Для доказательства снова сведём многомерную задачу к одномерной:

$$\varphi(t) = f(x + tv),$$

$$\varphi'(t) = \nabla f(x + tv)^\top v, \qquad \varphi''(t) = v^\top \nabla^2 f(x + tv) v.$$

Почему у выпуклой C^2-функции $\varphi'' \geq 0$?

Для одномерной дважды непрерывно дифференцируемой выпуклой функции и $h > 0$:

$$\varphi'(t) \leq \frac{\varphi(t+h) - \varphi(t)}{h} \leq \varphi'(t+h).$$

Следовательно,

$$\varphi'(t+h) - \varphi'(t) \geq 0.$$

Делим на $h > 0$ и переходим к пределу при $h \downarrow 0$:

$$\boxed{\varphi''(t) \geq 0.}$$

Критерий второго порядка: доказательство

Proof.

Если f выпукла, то каждое сужение $\varphi(t) = f(x + tv)$ выпукло, значит $\varphi''(t) \geq 0$. При $t = 0$:

$$v^\top \nabla^2 f(x) v = \varphi''(0) \geq 0.$$

Так как v произвольно, $\nabla^2 f(x) \succeq 0$; так как x произвольно, это верно на всём C.

Обратно, если $\nabla^2 f(z) \succeq 0$ для всех $z \in C$, то для любой прямой

$$\varphi''(t) = v^\top \nabla^2 f(x + tv) v \geq 0.$$

Следовательно, каждое одномерное сужение выпукло, а значит, выпукла и f. □

Строгая выпуклость

Definition 9

$f : C \to \mathbb{R}$ называется строго выпуклой, если для любых $x \neq y$ и $\theta \in (0, 1)$

$$\boxed{f(\theta x + (1-\theta)y) < \theta f(x) + (1-\theta) f(y).}$$

Единственность точки минимума

Строго выпуклая функция на выпуклом множестве имеет не более одной точки глобального минимума.

Если бы $x^\star \neq y^\star$ и $f(x^\star) = f(y^\star) = f^\star$, то

$$f\left(\frac{x^\star + y^\star}{2}\right) < \frac{1}{2} f(x^\star) + \frac{1}{2} f(y^\star) = f^\star,$$

что невозможно.

Строгая выпуклость обеспечивает единственность, *если минимум существует*.

Строгая выпуклость: осторожно

Если

$$\nabla^2 f(x) \succ 0 \qquad \forall x,$$

то f строго выпукла.
Обратное неверно. Например,

$$f(x) = x^4$$

строго выпукла на $\mathbb{R}$, но

$$f''(0) = 0.$$

Сильная выпуклость: определение

Строгая выпуклость качественно исключает линейные участки, но не задаёт равномерной количественной оценки отклонения от линейной аппроксимации.

Definition 10

Пусть $\mu > 0$. $f : C \to \mathbb{R}$ называется μ-сильно выпуклой относительно евклидовой нормы, если

$$\boxed{x \mapsto f(x) - \frac{\mu}{2}\|x\|_2^2 \quad \text{выпукла на } C.}$$

Сильная выпуклость: критерий первого порядка

Критерий первого порядка

Если f дифференцируема, то сильная выпуклость эквивалентна

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|_2^2.}$$

Proof.

Применяем критерий первого порядка к

$$g(x) = f(x) - \frac{\mu}{2}\|x\|^2, \qquad \nabla g(x) = \nabla f(x) - \mu x.$$

После раскрытия скобок получаем требуемое неравенство. Обратное доказательство проводится в обратном порядке. □

Сильная выпуклость: критерий второго порядка

Критерий второго порядка

Если $f \in C^2(C)$, то

$$\boxed{f \ \mu\text{-сильно выпукла} \iff \nabla^2 f(x) \succeq \mu I \quad \forall x \in C.}$$

Proof.

f μ-сильно выпукла тогда и только тогда, когда

$$g(x) = f(x) - \frac{\mu}{2}\|x\|^2$$

выпукла. По критерию второго порядка это эквивалентно

$$\nabla^2 g(x) = \nabla^2 f(x) - \mu I \succeq 0,$$

то есть $\nabla^2 f(x) \succeq \mu I$. □

Связь видов выпуклости

Связь свойств

При $\mu > 0$

$$\boxed{\mu\text{-сильная выпуклость} \Longrightarrow \text{строгая выпуклость} \Longrightarrow \text{выпуклость.}}$$

Обратные импликации неверны:

- x^4 строго выпукла, но не сильно выпукла на всей $\mathbb{R}$, поскольку $\inf_x f''(x) = 0$;
- $|x|$ выпукла, но не строго выпукла.

Строгая выпуклость — качественное свойство. Сильная выпуклость задаёт равномерную количественную нижнюю границу $\mu > 0$; именно μ входит в оценки скорости алгоритмов.

Единственность и квадратичный рост

Сильная выпуклость влечёт строгую, поэтому при существовании минимума он единственен.
Пусть $x^\star$ — точка минимума дифференцируемой μ-сильно выпуклой функции в безусловной задаче. Тогда $\nabla f(x^\star) = 0$, поэтому

Квадратичный рост

$$\boxed{f(y) - f^\star \geq \frac{\mu}{2}\|y - x^\star\|^2.}$$

Это неравенство связывает ошибку по значению функции с расстоянием до решения.

Монотонность градиента

Для выпуклой дифференцируемой функции:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x),$$

$$f(x) \geq f(y) + \nabla f(y)^\top (x - y).$$

Складывая и сокращая $f(x), f(y)$:

Монотонность градиента

$$\boxed{(\nabla f(x) - \nabla f(y))^\top (x - y) \geq 0.}$$

Это означает, что при переходе от y к x изменение градиента имеет неотрицательную проекцию на направление $x - y$.
Для дифференцируемой функции на выпуклой области монотонность градиента является ещё одной характеристикой выпуклости.

Сильная монотонность градиента

Для μ-сильно выпуклой функции складываем

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2,$$

$$f(x) \geq f(y) + \nabla f(y)^\top (x - y) + \frac{\mu}{2}\|x - y\|^2.$$

Получаем

Сильная монотонность градиента

$$\boxed{(\nabla f(x) - \nabla f(y))^\top (x - y) \geq \mu\|x - y\|^2.}$$

Такие оценки далее используются при анализе единственности решения и сходимости градиентных методов.

L-гладкость

Выпуклость даёт нижнюю геометрическую оценку. Теперь введём верхний контроль изменения градиента.

Definition 11

Пусть C открыто и выпукло, $f : C \to \mathbb{R}$ дифференцируема. Функция называется L-гладкой, если её градиент L-липшицев:

$$\boxed{\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2 \qquad \forall x, y \in C.}$$

Если не оговорено иное, гладкость понимается относительно евклидовой нормы. Константа L зависит от выбора нормы.

Гладкость и выпуклость — разные свойства

$$f(x) = x^2$$

выпукла и гладка;

$$f(x) = |x|$$

выпукла, но не гладка;

$$f(x) = -x^2$$

гладка, но не выпукла.

Верхняя квадратичная оценка

Theorem 12 (Лемма о спуске)

Если f является L-гладкой на выпуклом множестве C, то

$$\boxed{f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2}\|y - x\|^2.}$$

Неравенство позволяет оценить $f(y)$ сверху через $f(x)$, градиент в точке x и квадратичный член $\frac{L}{2}\|y - x\|^2$.

Лемма о спуске: доказательство I

Proof.

Положим $d = y - x$ и

$$\varphi(t) = f(x + td), \qquad t \in [0, 1].$$

По основной теореме анализа

$$f(y) - f(x) = \int_0^1 \nabla f(x + td)^\top d \, dt.$$

Добавим и вычтем $\nabla f(x)$:

$$f(y) - f(x) = \nabla f(x)^\top d + \int_0^1 (\nabla f(x + td) - \nabla f(x))^\top d \, dt.$$

□

Лемма о спуске: доказательство II

Продолжение.

По неравенству Коши–Буняковского и L-гладкости

$$(\nabla f(x + td) - \nabla f(x))^\top d \leq Lt\|d\|^2.$$

Следовательно,

$$\begin{aligned} f(y) - f(x) &\leq \nabla f(x)^\top d + \int_0^1 Lt\|d\|^2 dt \\ &= \nabla f(x)^\top d + \frac{L}{2}\|d\|^2. \end{aligned}$$

□

В лекции о градиентном методе подставим сюда

$$y = x - \alpha \nabla f(x).$$

Критерий гладкости через гессиан

Пусть $f \in C^2(C)$, C открыто и выпукло.

Критерий для общей C^2-функции

$$\|\nabla^2 f(x)\|_{\text{op}} \le L \qquad \forall x \in C$$

эквивалентно L-липшицевости градиента. Для симметричного гессиана:

$$-LI \preceq \nabla^2 f(x) \preceq LI.$$

Критерий для выпуклой C^2-функции

Если f выпукла, то $\nabla^2 f(x) \succeq 0$, поэтому

$$\boxed{0 \preceq \nabla^2 f(x) \preceq LI.}$$

Для невыпуклой функции одного условия $\nabla^2 f(x) \preceq LI$ недостаточно: оно не ограничивает по модулю отрицательные собственные значения.

Сильная выпуклость и гладкость вместе

Если f одновременно μ-сильно выпукла и L-гладка, то

$$f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2 \leq f(y)$$

и

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2}\|y - x\|^2.$$

Итоговая форма для C^2-функции

$$\boxed{\mu I \preceq \nabla^2 f(x) \preceq LI.}$$

Квадратичная функция как эталонный пример

Рассмотрим

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c, \qquad A = A^\top.$$

Тогда

$$\nabla f(x) = Ax - b, \qquad \nabla^2 f(x) = A.$$

Критерий для квадратичной функции

Если собственные значения A равны $\lambda_1, \ldots, \lambda_n$, то

$$f \text{ выпукла} \iff \lambda_i \geq 0 \quad \forall i.$$

При $A \succ 0$ функция сильно выпукла.

Параметры μ и L не уникальны: меньшая положительная $\tilde{\mu} \leq \mu$ также допустима, как и большая $\tilde{L} \geq L$.

Лучшие μ и L для квадратичной функции

Сильная выпуклость с параметром μ эквивалентна

$$A \succeq \mu I \iff A - \mu I \succeq 0.$$

Собственные значения $A - \mu I$ равны $\lambda_i(A) - \mu$, поэтому

$$\mu \leq \lambda_i(A) \quad \forall i.$$

Аналогично, L-гладкость выпуклой квадратичной функции:

$$A \preceq LI \iff \lambda_i(A) \leq L \quad \forall i.$$

Лучшие константы

$$\boxed{\mu_{\max} = \lambda_{\min}(A), \qquad L_{\min} = \lambda_{\max}(A).}$$

Итак,

$$\mu I \preceq A \preceq LI.$$

Обусловленность

В линейной алгебре обусловленность характеризует чувствительность численного решения к малым возмущениям исходных данных. В численной оптимизации аналогичный параметр отражает различие масштабов изменения функции по разным направлениям и входит в оценки скорости сходимости.

Число обусловленности гладкой сильно выпуклой задачи

Для μ-сильно выпуклой и L-гладкой функции:

$$\boxed{\kappa = \frac{L}{\mu}.}$$

Это обобщает спектральное число обусловленности матрицы: для положительно определённой квадратичной функции

$$\kappa = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}.$$

В общем случае L/μ даёт глобальную оценку отношения максимального и минимального масштабов второй производной. Чем больше κ, тем хуже обусловлена задача.

Задача наименьших квадратов

Для

$$f(x) = \frac{1}{2}\|Ax - b\|_2^2$$

имеем

$$\nabla f(x) = A^\top (Ax - b), \qquad \nabla^2 f(x) = A^\top A.$$

Следовательно,

$$L = \lambda_{\max}(A^\top A) = \sigma_{\max}(A)^2.$$

Если A имеет полный столбцовый ранг, то

$$\mu = \lambda_{\min}(A^\top A) = \sigma_{\min}(A)^2 > 0,$$

и

$$\kappa = \frac{\sigma_{\max}(A)^2}{\sigma_{\min}(A)^2} = \kappa_2(A)^2.$$

Переход к $A^\top A$ возводит число обусловленности в квадрат.

МНК и квадратичная регуляризация

Если полный столбцовый ранг отсутствует, то

$$\lambda_{\min}(A^\top A) = 0,$$

поэтому функция не является сильно выпуклой на всём $\mathbb{R}^n$.
Добавим квадратичную регуляризацию:

$$F(x) = \frac{1}{2}\|Ax - b\|^2 + \frac{\lambda}{2}\|x\|^2, \qquad \lambda > 0.$$

Тогда

$$\nabla^2 F(x) = A^\top A + \lambda I,$$

$$\mu = \lambda_{\min}(A^\top A) + \lambda, \qquad L = \lambda_{\max}(A^\top A) + \lambda.$$

Регуляризация меняет не только статистическую постановку, но и оптимизационную геометрию задачи.

Логистическая функция потерь

Пусть

$$\ell(z) = \log(1 + e^{-z}).$$

Имеем

$$\ell''(z) = \frac{e^z}{(1+e^z)^2} \geq 0, \qquad \ell''(z) \leq \frac{1}{4},$$

поэтому по критерию второго порядка ℓ выпукла.
Рассмотрим

$$F(w) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i a_i^\top w).$$

Отображение $w \mapsto y_i a_i^\top w$ аффинно; композиция с аффинным отображением и неотрицательная сумма сохраняют выпуклость. Поэтому F выпукла.

Почему логистическая функция не обязана быть сильно выпуклой?

Без дополнительных предположений о данных F не обязана быть сильно выпуклой. Даже полный столбцовый ранг матрицы признаков сам по себе не гарантирует глобальную сильную выпуклость нерегуляризованной логистической функции потерь на всём $\mathbb{R}^n$.

Причина:

$$\ell''(z) \to 0 \qquad \text{при } |z| \to \infty,$$

поэтому ℓ'' нельзя равномерно снизу оценить положительной константой.

Добавление

$$\frac{\lambda}{2}\|w\|^2, \qquad \lambda > 0,$$

обеспечивает сильную выпуклость всей целевой функции.

Теорема Вейерштрасса

До сих пор мы главным образом обсуждали свойства решения при условии, что оно существует.

Theorem 13 (Вейерштрасса)

Если C непусто и компактно, а $f : C \to \mathbb{R}$ непрерывна, то f достигает на C своего минимума и максимума.

Proof.

Непрерывный образ компактного множества компактен, поэтому $f(C) \subset \mathbb{R}$ — непустое компактное множество. В $\mathbb{R}$ компактное множество содержит свои точные нижнюю и верхнюю грани. Следовательно, существуют $x_{\min}, x_{\max} \in C$:

$$f(x_{\min}) = \min_{x \in C} f(x), \qquad f(x_{\max}) = \max_{x \in C} f(x).$$

□

Коэрцитивность

Definition 14

Функция $f : \mathbb{R}^n \to \mathbb{R}$ называется коэрцитивной, если

$$\boxed{\|x\| \to \infty \quad \Longrightarrow \quad f(x) \to +\infty.}$$

Утверждение 15

Непрерывная коэрцитивная функция на $\mathbb{R}^n$ достигает глобального минимума.

Коэрцитивность и существование минимума: доказательство

Proof.

Зафиксируем $x_0 \in \mathbb{R}^n$. По коэрцитивности существует $R > \|x_0\|$ такое, что при $\|x\| > R$

$$f(x) > f(x_0).$$

На замкнутом шаре

$$B_R = \{x : \|x\| \leq R\}$$

непрерывная f по теореме Вейерштрасса достигает минимума в некоторой $x^\star \in B_R$.
Поскольку $x_0 \in B_R$, $f(x^\star) \leq f(x_0)$, а вне B_R значения строго больше $f(x_0)$.
Следовательно, $x^\star$ — точка глобального минимума на $\mathbb{R}^n$. □

Сильная выпуклость и существование минимума

Дифференцируемая вещественнозначная μ-сильно выпуклая функция на всём $\mathbb{R}^n$ имеет единственную точку глобального минимума.
Зафиксируем произвольную $x_0 \in \mathbb{R}^n$. Из сильной выпуклости:

$$f(y) \geq f(x_0) + \nabla f(x_0)^\top (y - x_0) + \frac{\mu}{2}\|y - x_0\|^2.$$

Правая часть стремится к $+\infty$ при $\|y\| \to \infty$. Значит, f коэрцитивна, поэтому минимум достигается; единственность следует из строгой выпуклости.

Итоги: выпуклость и сильная выпуклость

Для дифференцируемой выпуклой функции:

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x).}$$

Для C^2-выпуклой функции:

$$\boxed{\nabla^2 f(x) \succeq 0.}$$

Для μ-сильно выпуклой функции:

$$\boxed{f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2,}$$

а при C^2:

$$\boxed{\nabla^2 f(x) \succeq \mu I.}$$

Итоги: гладкость и обусловленность

Для L-гладкой функции:

$$\boxed{\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|,}$$

$$\boxed{f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2}\|y - x\|^2.}$$

Если функция одновременно μ-сильно выпукла и L-гладка:

$$\boxed{\mu I \preceq \nabla^2 f(x) \preceq LI,} \qquad \boxed{\kappa = \frac{L}{\mu}.}$$