Дополнительные главы оптимизации

Лекция 3. Гладкая безусловная оптимизация: градиентный метод, метод Ньютона и квазиньютоновские методы

План лекции

1. Итерационные методы
2. Градиентный метод
3. Скорость градиентного метода
4. Сильная выпуклость и обусловленность
5. От градиента к методу Ньютона
6. Почему полного шага недостаточно
7. Квазиньютоновские методы
8. BFGS и L-BFGS
9. Остановка и сравнение
10. Что остаётся за пределами этой модели

Что будем делать сегодня

Рассматриваем гладкую безусловную задачу

$$\min_{x \in \mathbb{R}^n} f(x).$$

Даже если условия оптимальности известны, уравнение $\nabla f(x) = 0$ обычно нельзя решить аналитически. Поэтому строим последовательность приближений $x_0, x_1, \ldots$.

Как будем сравнивать методы

По каждому методу важно понимать:

- как и почему он строится;
- при каких предположениях и к каким задачам применим;
- что известно о сходимости и её скорости;
- сколько стоит одна итерация и сколько памяти требуется;
- как метод зависит от свойств задачи;
- какую слабость предыдущего рассмотренного метода он исправляет.

Линия лекции:

$$\text{градиент} \longrightarrow \text{обусловленность} \longrightarrow \text{гессиан} \longrightarrow \text{приближение гессиана}.$$

Общая схема итерационного метода

Переход от x_k к x_{k+1} задаётся вектором

$$s_k = x_{k+1} - x_k.$$

Любой ненулевой шаг можно представить как

$$s_k = \alpha_k p_k,$$

поэтому

$$\boxed{x_{k+1} = x_k + \alpha_k p_k.}$$

Две составляющие итерации:

1. выбрать направление p_k — *куда* двигаться;
2. выбрать шаг $\alpha_k > 0$ — *насколько далеко* двигаться.

Если f дифференцируема, то

$$f(x_k + \alpha p_k) = f(x_k) + \alpha \nabla f(x_k)^\top p_k + o(\alpha).$$

Поэтому условие

$$\boxed{\nabla f(x_k)^\top p_k < 0}$$

означает, что p_k является направлением убывания.

Сходимость методов

Алгоритм порождает последовательность $x_0, x_1, \ldots$. Утверждение о сходимости должно уточнять, *что именно* сходится и *к чему*:

$$x_k \to x^\star, \qquad f(x_k) \to f^\star, \qquad \|\nabla f(x_k)\| \to 0.$$

Это разные утверждения и без дополнительных предположений не обязаны быть эквивалентны.

Definition 1 (Локальная и глобальная сходимость)

Локальная сходимость: гарантия действует, если x_0 достаточно близка к решению.
Глобальная сходимость: гарантия действует из более широкого множества начальных точек при указанных предположениях.

«Глобальная сходимость» не означает автоматически нахождение глобального минимума произвольной невыпуклой функции.

Скорость сходимости и итерационная сложность

Пусть $e_k \geq 0$ — выбранная мера ошибки. Если метод сходится в выбранном смысле, хотим, чтобы $e_k \to 0$.
Примеры:

$$e_k = f(x_k) - f^\star, \qquad e_k = \|x_k - x^\star\|, \qquad e_k = \|\nabla f(x_k)\|.$$

Definition 2 (Скорость сходимости)

Характер убывания e_k при $k \to \infty$:

- **сублинейная:** например, $e_k \leq C/k$;
- **линейная (геометрическая):** $e_k \leq Cq^k$, $0 < q < 1$;
- **сверхлинейная:** $e_{k+1}/e_k \to 0$;
- **квадратичная:** локально $e_{k+1} \leq Ce_k^2$.

Definition 3 (Итерационная сложность)

Число итераций, достаточное для $e_k \leq \varepsilon$:

$$C/k \rightsquigarrow O(1/\varepsilon), \qquad Cq^k \rightsquigarrow O(\log(1/\varepsilon)).$$

Итерационная сложность не равна вычислительной стоимости: итерации разных методов стоят по-разному.

Как выбирать шаг α_k?

После выбора направления p_k остаётся решить, насколько далеко двигаться.

1. Фиксированный шаг:

$$\boxed{\alpha_k \equiv \alpha > 0.}$$

Он не требует дополнительных вычислений функции при каждой итерации, но безопасный масштаб зависит от свойств задачи. Для L-гладкого градиентного метода ниже получим естественный выбор $\alpha = 1/L$.

Более общо можно заранее задать последовательность шагов $\{\alpha_k\}$. В частности, используют

$$\boxed{\alpha_k \downarrow 0.}$$

Убывающие шаги особенно важны для субградиентных и стохастических методов; подробно вернёмся к ним позже.

2. Линейный поиск. Для уже выбранного p_k рассматриваем

$$\varphi_k(\alpha) = f(x_k + \alpha p_k), \qquad \alpha > 0,$$

и выбираем шаг по поведению функции вдоль этого направления.
Точный линейный поиск решает

$$\boxed{\alpha_k \in \arg\min_{\alpha > 0} f(x_k + \alpha p_k),}$$

но это обычно неоправданно дорого.

Как выбирать шаг α_k?

3. Условие Армихо и поиск шага с возвратом Пусть p_k — направление спуска, то есть

$$\nabla f(x_k)^\top p_k < 0.$$

При $c_1 \in (0,1)$ **условие Армихо** требует

$$\boxed{f(x_k + \alpha p_k) \le f(x_k) + c_1 \alpha \nabla f(x_k)^\top p_k.}$$

Правая часть меньше $f(x_k)$: требуется не просто уменьшение функции, а уменьшение, согласованное с локальным линейным прогнозом.

Поиск шага с возвратом (backtracking)

Выбираем начальный пробный шаг, например $\alpha = 1$, и параметр $\beta \in (0,1)$. Пока условие Армихо не выполнено, делаем

$$\boxed{\alpha \leftarrow \beta\alpha.}$$

Первый принятый шаг используем как α_k.

Для направления спуска и непрерывно дифференцируемой функции достаточно малый $\alpha > 0$ удовлетворяет условию Армихо, поэтому процедура заканчивается.

Почему направление $-\nabla f(x)$ естественно?

Для единичного направления p, $\|p\| = 1$, производная по направлению равна

$$D_p f(x) = \nabla f(x)^\top p.$$

По неравенству Коши–Буняковского

$$\nabla f(x)^\top p \geq -\|\nabla f(x)\|.$$

Минимум достигается при

$$p = -\frac{\nabla f(x)}{\|\nabla f(x)\|}.$$

Следовательно, антиградиент задаёт направление наиболее быстрого локального убывания в евклидовой геометрии.

Градиентный метод

$$\boxed{x_{k+1} = x_k - \alpha_k \nabla f(x_k).}$$

Остаётся главный вопрос: как лучше выбрать α_k?

Лемма о спуске

Theorem 4 (Лемма о спуске)

Если ∇f является L-липшицевым, то для любых x, y

$$\boxed{f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|^2 .}$$

Для градиентного шага $y = x - \alpha \nabla f(x)$:

$$f(x - \alpha \nabla f(x)) \leq f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2 .$$

Отсюда любой

$$0 < \alpha < \frac{2}{L}$$

гарантирует убывание в нестационарной точке.

Почему именно $\alpha = 1/L$?

Гарантированное уменьшение определяется коэффициентом

$$\psi(\alpha) = \alpha - \frac{L}{2}\alpha^2.$$

Максимизируем его:

$$\psi'(\alpha) = 1 - L\alpha = 0 \quad \Longrightarrow \quad \boxed{\alpha = \frac{1}{L}.}$$

Тогда

$$\boxed{f\left(x - \frac{1}{L}\nabla f(x)\right) \leq f(x) - \frac{1}{2L}\left\|\nabla f(x)\right\|^2.}$$

Если L существует, но неизвестна, можно использовать поиск шага с возвратом.

Цена одной итерации градиентного метода

Обозначим через C_g стоимость вычисления полного градиента $\nabla f(x)$. После вычисления градиента обновление

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

требует $O(n)$ арифметических операций.

$$\boxed{\text{стоимость итерации} = C_g + O(n).}$$

- Нельзя просто писать $O(n)$: C_g зависит от структуры задачи и часто доминирует.
- При линейном поиске добавляются пробные вычисления f и иногда ∇f.
- Храним постоянное число векторов длины n:

$$\boxed{\text{дополнительная память} = O(n).}$$

Выпуклый случай: какую ошибку измеряем?

Для выпуклой задачи естественная мера качества — невязка по значению функции

$$\boxed{\Delta_k = f(x_k) - f^\star \geq 0.}$$

Она отвечает на вопрос: насколько значение функции в x_k хуже оптимального?

Theorem 5 (Градиентный метод: выпуклый случай)

Пусть f выпукла и имеет L-липшицев градиент, $x^\star$ — точка минимума. При $\alpha = 1/L$

$$\boxed{f(x_k) - f^\star \leq \frac{L\|x_0 - x^\star\|^2}{2k}, \qquad k \geq 1.}$$

Следовательно,

$$f(x_k) - f^\star = O(1/k).$$

Доказательство оценки $O(1/k)$: ключевой шаг

Обозначим $g_k = \nabla f(x_k)$. Из выпуклости

$$f(x_k) - f^\star \le g_k^\top (x_k - x^\star).$$

Из леммы о спуске при $\alpha = 1/L$

$$f(x_{k+1}) \le f(x_k) - \frac{1}{2L} \|g_k\|^2 .$$

Поэтому

$$f(x_{k+1}) - f^\star \le g_k^\top (x_k - x^\star) - \frac{1}{2L} \|g_k\|^2 .$$

Но из

$$x_{k+1} = x_k - \frac{1}{L} g_k$$

следует

$$\boxed{f(x_{k+1}) - f^\star \le \frac{L}{2} \left(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2 \right).}$$

Это телескопическая оценка.

Доказательство $O(1/k)$: суммирование

Суммируем по $k = 0, \ldots, N-1$:

$$\sum_{k=0}^{N-1} (f(x_{k+1}) - f^\star) \leq \frac{L}{2} \|x_0 - x^\star\|^2 .$$

Значения $f(x_k)$ невозрастают, поэтому

$$N(f(x_N) - f^\star) \leq \sum_{k=0}^{N-1} (f(x_{k+1}) - f^\star).$$

Отсюда

$$\boxed{f(x_N) - f^\star \leq \frac{L \|x_0 - x^\star\|^2}{2N}.}$$

Для точности $f(x_k) - f^\star \leq \varepsilon$ достаточно

$$k \geq \frac{L \|x_0 - x^\star\|^2}{2\varepsilon},$$

то есть итерационная сложность по этой оценке — $O(1/\varepsilon)$.

Сильная выпуклость связывает градиент и ошибку

Lemma 6

Если f дифференцируема и μ-сильно выпукла, то

$$\boxed{\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^\star).}$$

Из сильной выпуклости для любого y:

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2.$$

Минимизируем правую часть по y. Для

$$q(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{\mu}{2}\|y - x\|^2$$

имеем

$$\nabla_y q(y) = \nabla f(x) + \mu(y - x) = 0,$$

откуда

$$\boxed{y = x - \frac{1}{\mu}\nabla f(x).}$$

Доказательство леммы и линейная сходимость

Подставляя $y = x - \mu^{-1}\nabla f(x)$, получаем

$$\min_y q(y) = f(x) - \frac{1}{2\mu}\|\nabla f(x)\|^2.$$

Так как $f^\star \geq \min_y q(y)$,

$$\|\nabla f(x)\|^2 \geq 2\mu(f(x) - f^\star).$$

Совмещаем с оценкой спуска:

$$\begin{aligned} f(x_{k+1}) - f^\star &\leq f(x_k) - f^\star - \frac{1}{2L}\|\nabla f(x_k)\|^2 \\ &\leq \left(1 - \frac{\mu}{L}\right)(f(x_k) - f^\star). \end{aligned}$$

Следовательно,

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^\star).}$$

Число обусловленности

Введём

$$\boxed{\kappa = \frac{L}{\mu} \geq 1.}$$

Тогда коэффициент линейной сходимости равен

$$1 - \frac{1}{\kappa}.$$

Чем больше κ, тем ближе этот коэффициент к единице и тем медленнее гарантированное уменьшение ошибки.
Для фиксированной начальной ошибки:

$$\boxed{O\left(\kappa \log \frac{1}{\varepsilon}\right)}$$

итераций до точности ε.

Но почему именно отношение L/μ управляет поведением метода? Для ответа рассмотрим квадратичную задачу, где динамику можно разобрать по собственным направлениям.

Квадратичная задача: динамика по собственным направлениям

Пусть

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x, \qquad A \succ 0.$$

Тогда

$$\nabla f(x) = Ax - b, \qquad x^\star = A^{-1}b.$$

Для ошибки $e_k = x_k - x^\star$:

$$e_{k+1} = (I - \alpha A)e_k.$$

Если $Aq_i = \lambda_i q_i$ и

$$e_k = \sum_i c_{k,i} q_i,$$

то

$$\boxed{c_{k+1,i} = (1 - \alpha\lambda_i)c_{k,i}.}$$

Каждое собственное направление затухает со своим множителем $1 - \alpha\lambda_i$.

Почему большая κ мешает градиентному методу?

Для направления с большой λ_i нужен малый шаг: иначе

$$|1 - \alpha\lambda_i| \geq 1$$

и возникают колебания или расходимость.
Но тот же малый α при маленькой λ_i даёт

$$1 - \alpha\lambda_i \approx 1,$$

то есть медленное уменьшение ошибки.
Для квадратичной задачи

$$L = \lambda_{\max}(A), \qquad \mu = \lambda_{\min}(A), \qquad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}}.$$

Вывод. Один скалярный шаг плохо согласует направления с сильно различающейся кривизной.

Лучший фиксированный шаг тоже зависит от обусловленности

Для квадратичной задачи минимизируем

$$\max_i |1 - \alpha\lambda_i|.$$

Оптимальный фиксированный шаг:

$$\boxed{\alpha_{\text{opt}} = \frac{2}{L + \mu}.}$$

Соответствующий наихудший множитель:

$$\boxed{\rho_{\text{opt}} = \frac{\kappa - 1}{\kappa + 1}.}$$

Это лучше, чем грубый выбор $1/L$, но при $\kappa \gg 1$

$$\rho_{\text{opt}} \approx 1.$$

Проблема обусловленности остаётся.

Что если градиент не глобально липшицев?

Стандартные оценки выше существенно используют L-гладкость.
Например,

$$f(x) = x^4, \qquad f'(x) = 4x^3$$

не имеет глобально липшицева градиента на $\mathbb{R}$.
Без глобальной L-гладкости нет универсального фиксированного шага и универсальной оценки $O(1/k)$ без дополнительных предположений.
Возможные варианты:

- локальная липшицевость градиента на области, где остаются итерации;
- поиск шага с возвратом;
- другие предположения о регулярности и другие оценки.

Что хотим исправить в градиентном методе?

1. **Чувствительность к обусловленности.** Один скалярный шаг одинаково масштабирует все направления.
2. **Скорость.** В гладком выпуклом случае — $O(1/k)$; при сильной выпуклости линейная сходимость ухудшается при большой κ.
3. **Только информация первого порядка.** Если вторые производные доступны, GD не использует локальную кривизну.

Идея следующего метода:

использовать гессиан для учёта кривизны по направлениям.

Но за это придётся платить более дорогой итерацией и большей памятью.

Почему возникает квадратичная модель?

Линейная модель

$$f(x+p) \approx f(x) + \nabla f(x)^\top p$$

даёт направление уменьшения, но при $\nabla f(x) \neq 0$ не имеет конечного минимума по $p \in \mathbb{R}^n$.
Если f дважды дифференцируема,

$$f(x+p) = f(x) + \nabla f(x)^\top p + \frac{1}{2} p^\top \nabla^2 f(x) p + o(\|p\|^2).$$

Отбрасываем остаток:

$$\boxed{m_x(p) = f(x) + g^\top p + \frac{1}{2} p^\top H p.}$$

Если $H \succ 0$, эта квадратичная модель имеет единственную точку минимума.

Направление метода Ньютона

Минимизируем квадратичную модель:

$$\nabla_p m_x(p) = g + Hp = 0.$$

Отсюда

$$\boxed{p_N = -H^{-1}g,}$$

или, вычислительно правильнее, решаем систему

$$\boxed{Hp_N = -g.}$$

Итерация метода Ньютона с полным шагом:

$$\boxed{x_{k+1} = x_k - [\nabla^2 f(x_k)]^{-1}\nabla f(x_k).}$$

Если $H = \nabla^2 f(x) \succ 0$ и $g \neq 0$, то

$$g^\top p_N = -g^\top H^{-1} g < 0,$$

то есть направление метода Ньютона является направлением спуска. В отличие от GD, здесь масштабирование зависит от кривизны по направлениям.

Квадратичная функция: решение за один шаг

Для

$$f(x) = \frac{1}{2} x^\top A x - b^\top x, \qquad A \succ 0,$$

имеем

$$\nabla f(x) = Ax - b, \qquad \nabla^2 f(x) = A.$$

Шаг метода Ньютона:

$$\begin{aligned} x_{k+1} &= x_k - A^{-1}(Ax_k - b) \\ &= A^{-1} b = x^\star. \end{aligned}$$

Ключевая идея

Метод Ньютона точно минимизирует локальную квадратичную модель. Если сама функция квадратична, модель точна во всём пространстве — поэтому решение находится за один шаг.

Локальная квадратичная сходимость: условия

Ключевой вопрос: если метод Ньютона точен для квадратичной функции, что происходит для функции, почти квадратичной около решения?

Theorem 7 (Локальная квадратичная сходимость)

Пусть f дважды непрерывно дифференцируема в окрестности $x^\star$, $\nabla f(x^\star) = 0$. Предположим, что в этой окрестности

$$\nabla^2 f(x) \succeq mI, \qquad m > 0,$$

и гессиан липшицев:

$$\left\|\nabla^2 f(x) - \nabla^2 f(y)\right\|_{\text{op}} \leq M \|x - y\|.$$

Тогда для достаточно близкого x_0 полный метод Ньютона корректно определён и

$$\boxed{\|x_{k+1} - x^\star\| \leq \frac{M}{2m} \|x_k - x^\star\|^2.}$$

Первое условие даёт устойчивую обратимость гессиана; второе контролирует изменение кривизны и ошибку локальной квадратичной модели.

Локальная квадратичная сходимость метода Ньютона

Обозначим $e_k = x_k - x^\star$, $H_k = \nabla^2 f(x_k)$. По основной теореме математического анализа, применённой к

$$t \mapsto \nabla f(x^\star + te_k),$$

получаем

$$\nabla f(x_k) = \int_0^1 \nabla^2 f(x^\star + te_k) e_k \, dt.$$

Из шага метода Ньютона:

$$\begin{aligned} e_{k+1} &= e_k - H_k^{-1} \nabla f(x_k) \\ &= H_k^{-1} \int_0^1 \left[H_k - \nabla^2 f(x^\star + te_k) \right] e_k \, dt. \end{aligned}$$

Так как $\left\| H_k^{-1} \right\| \leq 1/m$ и

$$\left\| H_k - \nabla^2 f(x^\star + te_k) \right\| \leq M(1-t) \left\| e_k \right\|,$$

то

$$\boxed{\left\| e_{k+1} \right\| \leq \frac{M}{2m} \left\| e_k \right\|^2.}$$

Это локальная квадратичная сходимость.

Полный шаг может быть плох далеко от решения

Рассмотрим выпуклую функцию

$$f(x) = \sqrt{1 + x^2}.$$

Тогда

$$f'(x) = \frac{x}{\sqrt{1 + x^2}}, \qquad f''(x) = \frac{1}{(1 + x^2)^{3/2}} > 0.$$

Шаг метода Ньютона:

$$x^+ = x - \frac{f'(x)}{f''(x)} = -x^3.$$

При $x_0 = 2$:

$$x_1 = -8, \qquad f(-8) > f(2).$$

Далее $x_2 = 512$.
Квадратичная модель локальна, а полный шаг может доверять ей слишком далеко.

В невыпуклой задаче гессиан может быть неопределённым

Пусть

$$f(x, y) = x^2 - y^2.$$

Тогда

$$\nabla f = (2x, -2y)^\top, \qquad \nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}.$$

Гессиан обратим, но не положительно полуопределён.
Направление метода Ньютона:

$$p_N = (-x, -y)^\top.$$

При этом

$$\nabla f^\top p_N = -2x^2 + 2y^2,$$

что может быть положительно.
Более того, метод Ньютона переводит любую точку в $(0, 0)$ — седловую точку.
Вывод. Метод Ньютона естественно связан с решением уравнения $\nabla f(x) = 0$, а стационарная точка не обязана быть минимумом.

Демпфированный метод Ньютона

Сохраняем направление метода Ньютона

$$\nabla^2 f(x_k) p_k = -\nabla f(x_k),$$

но не обязуемся делать полный шаг:

$$\boxed{x_{k+1} = x_k + \alpha_k p_k, \qquad 0 < \alpha_k \leq 1.}$$

Шаг α_k выбирается линейным поиском, например по условию Армихо:

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f(x_k)^\top p_k.$$

- далеко от решения линейный поиск защищает от слишком агрессивного полного шага;
- в хорошей локальной области обычно принимается $\alpha_k = 1$;
- тогда восстанавливается локальная квадратичная сходимость.

Глобальные гарантии зависят от дополнительных предположений.

Цена второго порядка

Пусть $H_k = \nabla^2 f(x_k)$ — плотная $n \times n$ матрица.

- хранение H_k: n^2 чисел

$$\boxed{O(n^2) \text{ памяти;}}$$

- вычисление градиента и построение гессиана имеют задачно-зависимые стоимости C_g и C_H;
- решение плотной системы

$$H_k p_k = -g_k$$

через факторизацию требует порядка

$$\boxed{O(n^3)}$$

операций; последующие подстановки — $O(n^2)$.

Важно

Это оценки для плотной общей задачи. Разреженность и специальная структура могут радикально изменить стоимость.

Если используется линейный поиск, добавляются пробные вычисления функции и, в зависимости от реализации, градиента.
Отсюда следующий вопрос: можно ли использовать информацию о кривизне, не вычисляя гессиан явно?

Идея квазиньютоновских методов

Вместо точного гессиана строим приближение

$$B_k \approx \nabla^2 f(x_k)$$

или приближение обратного гессиана

$$H_k \approx [\nabla^2 f(x_k)]^{-1}.$$

Направление выбираем как

$$B_k p_k = -\nabla f(x_k)$$

или

$$p_k = -H_k \nabla f(x_k).$$

Главный вопрос: как получать информацию о гессиане, если мы его не вычисляем? Ответ: использовать изменения градиента между соседними итерациями.

Что наблюдаем после очередного шага?

Определим

$$\boxed{s_k = x_{k+1} - x_k,} \qquad \boxed{y_k = \nabla f(x_{k+1}) - \nabla f(x_k).}$$

Обе величины доступны без вычисления гессиана.
В одномерном случае по теореме Лагранжа для f' существует ξ между x_k и x_{k+1}:

$$f'(x_{k+1}) - f'(x_k) = f''(\xi)(x_{k+1} - x_k).$$

То есть

$$y_k = f''(\xi)s_k.$$

Идея. Изменение градиента несёт информацию о второй производной.

Многомерный случай: от изменения градиента к гессиану

Параметризуем отрезок:

$$x(t) = x_k + ts_k, \qquad t \in [0, 1].$$

Для

$$\varphi(t) = \nabla f(x_k + ts_k)$$

имеем

$$\varphi'(t) = \nabla^2 f(x_k + ts_k)s_k.$$

По основной теореме математического анализа

$$\boxed{y_k = \int_0^1 \nabla^2 f(x_k + ts_k)s_k \, dt = \left(\int_0^1 \nabla^2 f(x_k + ts_k) \, dt\right) s_k.}$$

Если шаг невелик и гессиан меняется умеренно,

$$y_k \approx \nabla^2 f(x_{k+1})s_k.$$

Мы не узнали весь гессиан, но получили информацию о его действии на одно направление s_k.

Условие секущей

Хотим построить

$$B_{k+1} \approx \nabla^2 f(x_{k+1}).$$

Настоящий гессиан приблизительно удовлетворяет

$$\nabla^2 f(x_{k+1}) s_k \approx y_k.$$

Поэтому требуем, чтобы новое приближение точно воспроизводило наблюдаемую информацию:

$$\boxed{B_{k+1} s_k = y_k.}$$

Это **условие секущей**.
Для приближения обратного гессиана:

$$\boxed{H_{k+1} y_k = s_k.}$$

Но этого недостаточно

Одно условие даёт лишь n скалярных равенств для $n \times n$ матрицы.
Подходящих матриц бесконечно много.

Что хотим от нового приближения?

BFGS = **Broyden–Fletcher–Goldfarb–Shanno**.
Для $H_{k+1} \approx [\nabla^2 f(x_{k+1})]^{-1}$ естественно требовать:

1. условие секущей
$$H_{k+1} y_k = s_k;$$
2. симметрию $H_{k+1} = H_{k+1}^\top$;
3. сохранение положительной определённости при подходящем условии кривизны;
4. минимальное изменение уже накопленного приближения H_k, насколько это совместимо с новой информацией.

Разные формализации последнего требования приводят к различным квазиньютоновским обновлениям. BFGS — один из основных вариантов.

Формула BFGS

Обозначим

$$\rho_k = \frac{1}{y_k^\top s_k}.$$

Обновление приближения обратного гессиана:

$$\boxed{H_{k+1} = (I - \rho_k s_k y_k^\top) H_k (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top.}$$

Если $H_k \succ 0$ и

$$\boxed{y_k^\top s_k > 0,}$$

то BFGS сохраняет положительную определённость.
Направление:

$$\boxed{p_k = -H_k \nabla f(x_k).}$$

Обычно BFGS сочетают с линейным поиском.

Условие кривизны и условия Вольфе

Для сохранения положительной определённости BFGS нужно

$$\boxed{y_k^\top s_k > 0.}$$

Для μ-сильно выпуклой функции это условие возникает автоматически:

$$\begin{aligned} y_k^\top s_k &= (\nabla f(x_{k+1}) - \nabla f(x_k))^\top (x_{k+1} - x_k) \\ &\geq \mu \|s_k\|^2 > 0 \qquad (s_k \neq 0). \end{aligned}$$

В более общей постановке подходящий линейный поиск может обеспечивать нужную кривизну. **Условия Вольфе** требуют достаточного убывания

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^\top p_k$$

и условия на производную вдоль направления

$$\nabla f(x_k + \alpha p_k)^\top p_k \geq c_2 \nabla f(x_k)^\top p_k, \qquad 0 < c_1 < c_2 < 1.$$

Подробную теорию линейного поиска здесь не развиваем.

Проверка условия секущей для BFGS

Умножим формулу на y_k справа. Поскольку

$$\rho_k s_k^\top y_k = 1,$$

имеем

$$(I - \rho_k y_k s_k^\top) y_k = 0.$$

Поэтому первый член BFGS-обновления зануляется, а второй даёт

$$\rho_k s_k s_k^\top y_k = s_k.$$

Следовательно,

$$\boxed{H_{k+1} y_k = s_k.}$$

То есть формула действительно точно воспроизводит новую наблюдаемую информацию о кривизне.

BFGS: стоимость и свойства

H_k — плотная $n \times n$ матрица.

- память:

$$\boxed{O(n^2)};$$

- вычисление $p_k = -H_k g_k$: матрично-векторное произведение

$$\boxed{O(n^2)};$$

- обновление BFGS через внешние произведения также реализуется за

$$\boxed{O(n^2)}.$$

Плюс вычисление градиента и стоимость линейного поиска.

При стандартных предположениях гладкости и невырожденности решения вместе с подходящим линейным поиском для BFGS имеются глобальные результаты сходимости и локальная сверхлинейная сходимость. Это не безусловное утверждение; полную теорию здесь не доказываем.

Проблема: $O(n^2)$ памяти и вычислений становятся тяжёлыми при очень большом n.

L-BFGS: ограниченная память

Идея: не хранить плотную матрицу H_k, а хранить только последние r пар

$$(s_i, y_i).$$

Если $r \ll n$ фиксировано, то храним $2r$ векторов длины n:

$$\boxed{O(rn) \text{ памяти.}}$$

Двухцикловая рекурсия использует порядка r скалярных произведений и линейных комбинаций n-мерных векторов:

$$\boxed{O(rn) \text{ операций.}}$$

Компромисс. L-BFGS сохраняет ограниченную историю информации о кривизне и поэтому хорошо подходит для задач большой размерности. Не следует автоматически переносить на L-BFGS все локальные сверхлинейные гарантии полного BFGS.

Когда останавливать алгоритм?

На практике $x^\star$ и $f^\star$ обычно неизвестны, поэтому проверяем доступные величины.
Типичные критерии:

$$\|\nabla f(x_k)\| \le \varepsilon_g,$$

$$\frac{|f(x_{k+1}) - f(x_k)|}{1 + |f(x_k)|} \le \varepsilon_f,$$

$$\frac{\|x_{k+1} - x_k\|}{1 + \|x_k\|} \le \varepsilon_x.$$

Также используют ограничение на число итераций или время.

Осторожно

Малое изменение $f(x_k)$ само по себе не означает близость к точке минимума: метод может просто делать слишком маленькие шаги. Малый градиент в невыпуклой задаче означает лишь приближённую стационарность, а не близость к минимуму.

Сравнение методов: информация и стоимость

Метод	Информация	Память	Основная линейная алгебра
GD	∇f	$O(n)$	$O(n)$ после вычисления градиента
Метод Ньютона	$\nabla f, \nabla^2 f$	$O(n^2)$	$C_g + C_H + O(n^3)$ для плотной задачи
BFGS	∇f, пары (s_k, y_k)	$O(n^2)$	$O(n^2)$
L-BFGS	∇f, последние r пар	$O(rn)$	$O(rn)$

К этим оценкам добавляются стоимость вычисления производных и стоимость линейного поиска.

Сравнение методов: характер сходимости

- **Градиентный метод:** $O(1/k)$ для гладкой выпуклой функции; линейная сходимость при сильной выпуклости, с зависимостью от $\kappa = L/\mu$.
- **Метод Ньютона:** локально квадратичная сходимость при невырожденном решении и локально липшицевом гессиане.
- **BFGS:** при стандартных условиях гладкости, невырожденности решения и подходящем линейном поиске — глобальные результаты сходимости и локальная сверхлинейная сходимость.
- **L-BFGS:** рассчитан прежде всего на большие n и ограниченную память; нельзя автоматически переносить на него все локальные сверхлинейные гарантии полного BFGS.

Число итераций нельзя сравнивать в отрыве от цены одной итерации и требований к памяти.

Что именно исправляет каждый следующий метод?

- **Градиентный метод.** Использует дешёвую информацию первого порядка, но чувствителен к обусловленности.
- **Метод Ньютона.** Учитывает локальную кривизну и масштабирует направления по-разному, но требует гессиан и решение системы.
- **Демпфированный метод Ньютона.** Не доверяет локальной квадратичной модели на произвольно большом расстоянии: полный шаг заменяется контролируемым.
- **BFGS / L-BFGS.** Пытаются получить преимущества информации о кривизне без явного вычисления гессиана; L-BFGS дополнительно решает проблему памяти.

Проблемы: геометрия, негладкость, ограничения

1. Плохая обусловленность. При $\kappa \gg 1$ один скалярный шаг плохо работает с направлениями разной кривизны. Варианты: метод Ньютона, квазиньютоновские методы, предобусловливание, ускоренные методы первого порядка.

2. Негладкость. Для $|x|$ или ℓ_1-регуляризации обычный градиент может не существовать. Решения: субградиентные и проксимальные методы — лекция 4.

3. Ограничения. Обычный шаг

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k)$$

может вывести из допустимого множества. KKT уже дали язык оптимальности; алгоритмические подходы включают проекционные, штрафные и барьерные методы. В нашем курсе на лекции 5 подробно рассматриваются логарифмический барьер и методы внутренней точки.

Проблемы: масштаб данных, ускорение, невыпуклость

4. Дорогой полный градиент. В машинном обучении часто

$$f(x) = \frac{1}{N} \sum_{i=1}^{N} f_i(x).$$

Полный градиент требует обработки всех N слагаемых. Решения: стохастический градиент, мини-батчи, методы уменьшения дисперсии; базовые стохастические методы — лекция 6.

5. Даже $O(1/k)$ может быть слишком медленно. Можно ли ускорить гладкий выпуклый метод первого порядка без явного гессиана? Да: momentum и ускоренный градиентный метод Нестерова — лекция 6.

6. Невыпуклость. Условие $\nabla f(x) = 0$ не означает минимум: возможны максимумы, седловые точки и направления отрицательной кривизны. Метод Ньютона также не различает тип стационарной точки автоматически. Стационарность, условия второго порядка и отрицательная кривизна — лекция 7.

Предобусловливание как мост между GD и методом Ньютона

Вместо скалярного масштабирования можно использовать матрицу

$$\boxed{x_{k+1} = x_k - \alpha_k P_k \nabla f(x_k), \qquad P_k \succ 0.}$$

Идея: изменить геометрию шага так, чтобы эффективная задача была лучше обусловлена.

- $P_k = I$ — обычный градиентный метод;
- хороший предобусловливатель приближённо компенсирует различие масштабов по направлениям;
- метод Ньютона при положительно определённом гессиане использует крайний локальный вариант

$$P_k = [\nabla^2 f(x_k)]^{-1}.$$

Итоги лекции

1. Градиентный метод использует только информацию первого порядка; при L-гладкости шаг $1/L$ даёт контролируемое убывание.
2. Для гладкой выпуклой задачи получили $O(1/k)$; при сильной выпуклости — линейную сходимость с зависимостью от $\kappa = L/\mu$.
3. Спектральный анализ квадратичной задачи объясняет, почему плохая обусловленность мешает одному скалярному шагу.
4. Метод Ньютона минимизирует локальную квадратичную модель и локально может сходиться квадратично, но полный шаг не всегда надёжен и второй порядок дорог.
5. Демпфирование контролирует длину шага; BFGS и L-BFGS приближают информацию о кривизне по изменениям градиента.
6. Сравнивать методы нужно одновременно по предположениям, скорости, стоимости итерации, памяти и области применимости.

Куда дальше?

Сегодня мы работали с гладкой безусловной оптимизацией и постепенно усиливали используемую информацию:

$$\nabla f \quad \longrightarrow \quad \nabla^2 f \quad \longrightarrow \quad \text{приближение кривизны по } (s_k, y_k).$$

Следующие лекции будут систематически менять предположения и масштаб задачи:

- негладкость и композитная структура;
- ограничения и внутренние точки;
- ускорение и стохастические методы;
- невыпуклая оптимизация.