Дополнительные главы оптимизации

Лекция 4. Негладкая и составная оптимизация: субградиентные и проксимальные методы

План лекции

1. Субградиент как обобщение градиента
2. Субградиентный метод
3. Ограничения: проекционные методы
4. Проксимальный оператор
5. Проксимальный градиентный метод
6. Стоимость и область применимости
7. Куда развивается проксимальная идея
8. Итоги

Цели и логика лекции

На прошлой лекции локальная информация была градиентом или гессианом. Но в задачах машинного обучения негладкость часто *намеренно* кодирует структуру решения.

Главный пример:

$$\boxed{F(x) = \frac{1}{2}\|Ax - b\|_2^2 + \lambda \|x\|_1, \qquad \lambda > 0.}$$

Гладкая часть допускает обычный градиент, а ℓ_1-штраф негладок и способствует разреженности.

Два вопроса лекции

1. Чем заменить градиент для общей выпуклой негладкой функции? $\Rightarrow$ субградиент.
2. Как использовать специальную структуру $F = f + g$, не обращаясь со всей задачей как с произвольной негладкой? $\Rightarrow$ prox и проксимальный градиент.

$$\boxed{\begin{array}{c}\text{негладкость} \to \partial f \to \text{субградиентный метод} \\ \to \text{структура } f + g \to \text{prox} \to \text{проксимальный градиент}\end{array}}$$

Важно не смешивать два подхода. Общий субградиентный метод не гарантирует спуск на каждом шаге и имеет стандартную оценку скорости сходимости $O(1/\sqrt{k})$. Проксимальный градиент использует дополнительную структуру $f + g$ и позволяет вернуть оценку $O(1/k)$.

От опорной гиперплоскости к субградиенту

Для дифференцируемой выпуклой функции

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x).$$

В негладкой точке единственного касательного наклона может не быть. Сохраним главное: глобальную аффинную нижнюю оценку.

Definition 1 (Субградиент)

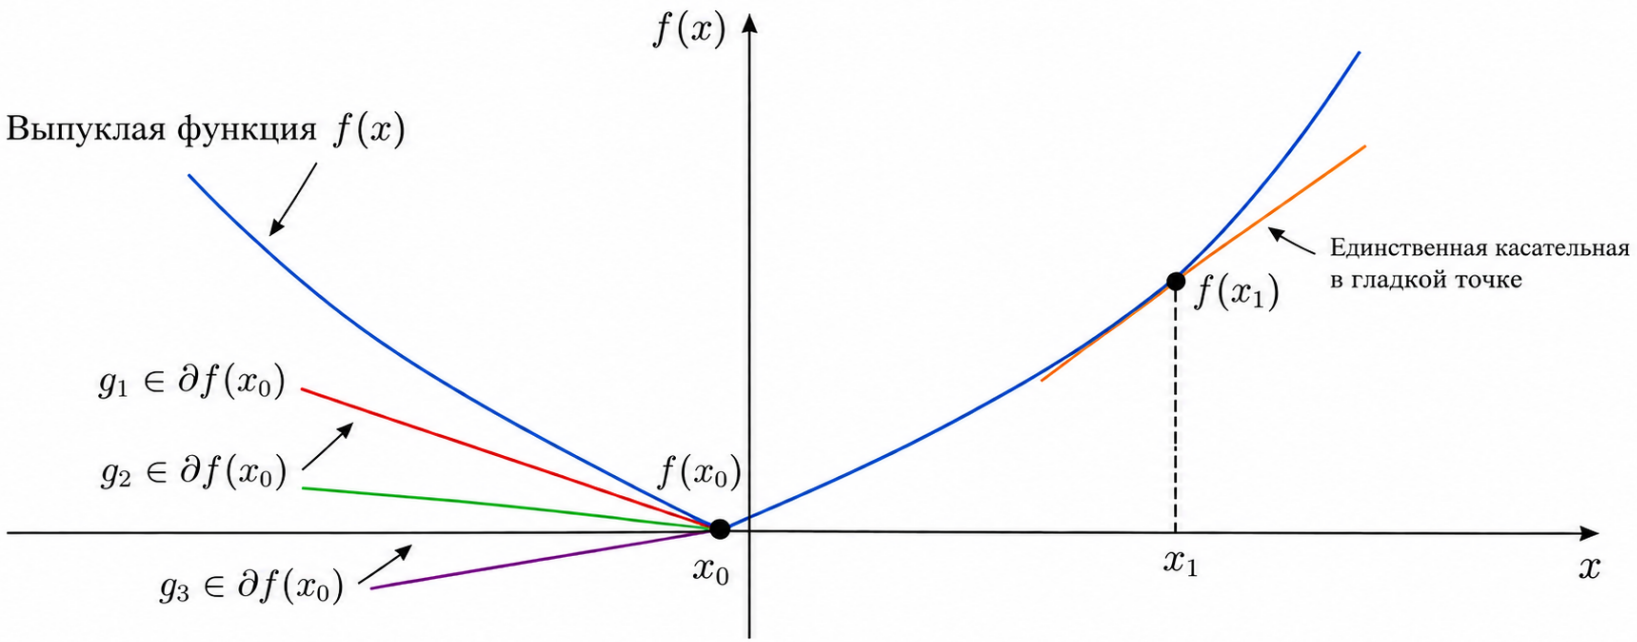
$g \in \mathbb{R}^n$ называется субградиентом выпуклой f в точке x, если

$$\boxed{f(y) \geq f(x) + g^\top (y - x) \qquad \forall y \in \mathbb{R}^n.}$$

Definition 2 (Субдифференциал)

$$\boxed{\partial f(x) = \{g : \ f(y) \geq f(x) + g^\top (y - x) \ \forall y\}.}$$

Иллюстрация: субградиенты как опорные наклоны



В гладкой точке субградиент совпадает с градиентом

Утверждение 3

Если выпуклая f дифференцируема в x, то

$$\boxed{\partial f(x) = \{\nabla f(x)\}.}$$

Proof.

Из выпуклости $\nabla f(x) \in \partial f(x)$. Пусть $g \in \partial f(x)$. Для любого d и $t > 0$ из определения $\partial f(x)$

$$\frac{f(x + td) - f(x)}{t} \geq g^\top d.$$

При $t \downarrow 0$:

$$\nabla f(x)^\top d \geq g^\top d.$$

Применяя то же к $-d$, получаем обратное неравенство. Значит,

$$\nabla f(x)^\top d = g^\top d \quad \forall d,$$

откуда $g = \nabla f(x)$. □

Таким образом, субградиент продолжает привычный градиент на выпуклый негладкий случай.

Основной пример: $f(x) = |x|$

Если $x > 0$, то $\partial|x| = \{1\}$; если $x < 0$, то $\partial|x| = \{-1\}$.
В точке $x = 0$ воспользуемся определением. Число g является субградиентом тогда и только тогда, когда

$$|y| \geq gy \qquad \forall y.$$

Для $y > 0$ получаем $g \leq 1$, для $y < 0$ — $g \geq -1$. Поэтому

$$\boxed{\partial|x| = \begin{cases} \{-1\}, & x < 0, \\ [-1, 1], & x = 0, \\ \{1\}, & x > 0. \end{cases}}$$

Для ℓ_1-нормы $\|x\|_1 = \sum_i |x_i|$ субдифференциал вычисляется покоординатно:

$$\boxed{\partial \|x\|_1 = \{g : \ g_i = \text{sign}(x_i) \text{ при } x_i \neq 0, \quad g_i \in [-1, 1] \text{ при } x_i = 0\}.}$$

Максимум выпуклых функций

Пусть

$$f(x) = \max_{i=1,\dots,m} f_i(x), \qquad I(x) = \{i : f_i(x) = f(x)\},$$

где f_i выпуклы и дифференцируемы. Тогда

$$\boxed{\partial f(x) = \operatorname{conv}\{\nabla f_i(x) : i \in I(x)\}.}$$

Почему выпуклая оболочка даёт субградиенты. Если

$$g = \sum_{i \in I(x)} \theta_i \nabla f_i(x), \quad \theta_i \geq 0, \quad \sum_i \theta_i = 1,$$

то для активных i

$$f(y) \geq f_i(y) \geq f(x) + \nabla f_i(x)^\top (y - x).$$

Умножая на θ_i и суммируя, получаем субградиентное неравенство для g.

Обратное включение требует дополнительных результатов выпуклого анализа и выходит за пределы курса.

Как частный случай, $|x| = \max\{x, -x\}$ даёт

$$\partial |x|(0) = \operatorname{conv}\{-1, 1\} = [-1, 1].$$

Некоторые правила субдифференциального исчисления для выпуклых функций

Для $a > 0$:

$$\partial(af)(x) = a\,\partial f(x).$$

Для суммы при подходящем условии на области определения, например если одна из выпуклых функций конечна и непрерывна хотя бы в одной точке области определения другой,

$$\partial(f+g)(x) = \partial f(x) + \partial g(x), \qquad A + B := \{a + b : a \in A,\ b \in B\}.$$

Основной случай лекции

Если $f : \mathbb{R}^n \to \mathbb{R}$ выпукла и дифференцируема на всём $\mathbb{R}^n$, а $g : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ собственная выпуклая, то для $x \in \operatorname{dom} g$

$$\boxed{\partial(f+g)(x) = \nabla f(x) + \partial g(x).}$$

Условия здесь относятся к правилу суммы субдифференциалов и не являются условиями регулярности типа LICQ из KKT.

Субградиентное условие оптимальности

Theorem 4 (Субградиентное условие оптимальности)

Для выпуклой $f : \mathbb{R}^n \to \mathbb{R}$

$$\boxed{x^\star \text{ — глобальный минимум } \iff 0 \in \partial f(x^\star).}$$

Proof.

Если $0 \in \partial f(x^\star)$, то

$$f(y) \geq f(x^\star) + 0^\top (y - x^\star) = f(x^\star) \quad \forall y.$$

Обратно, если $x^\star$ — глобальный минимум, то

$$f(y) \geq f(x^\star) = f(x^\star) + 0^\top (y - x^\star),$$

то есть $0 \in \partial f(x^\star)$. □

Для $F = f + g$ с гладкой f:

$$\boxed{0 \in \nabla f(x^\star) + \partial g(x^\star).}$$

Субградиентный метод

Для гладкой функции:

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Для выпуклой негладкой функции выбираем произвольный

$$g_k \in \partial f(x_k)$$

и строим

$$\boxed{x_{k+1} = x_k - \alpha_k g_k, \qquad \alpha_k > 0.}$$

Важно

Внешнее сходство с градиентным методом не означает сходства всех свойств. В частности, $-g_k$ вообще говоря не является направлением спуска, а значения $f(x_k)$ не обязаны убывать.

$-g$ не обязано быть направлением спуска

Для дифференцируемой f:

$$\nabla f(x)^\top(-\nabla f(x)) = -\|\nabla f(x)\|^2 < 0.$$

Для субградиента определение даёт нижнюю, а не верхнюю оценку функции.

Контрпример:

$$f(x_1, x_2) = \max\{x_1, -x_1 + 2x_2\} + \tfrac{1}{2}(x_1^2 + x_2^2).$$

В $(0,0)$

$$\partial f(0,0) = \operatorname{conv}\{(1,0), (-1,2)\}, \qquad 0 \notin \partial f(0,0),$$

то есть точка не оптимальна. Но для $g = (1,0)$ направление $-g = (-1,0)$ даёт

$$f(-t,0) = t + \tfrac{1}{2}t^2 > 0 = f(0,0), \qquad t > 0.$$

Следовательно, даже вне точки минимума отрицательный субградиент может вести вверх.

Следствие для анализа метода

Значения $f(x_k)$ могут увеличиваться. Поэтому естественно отслеживать

$$f_{\text{best}}^{(k)} = \min_{0 \le i \le k} f(x_i)$$

или использовать усреднение итераций: монотонность здесь не является базовым свойством.

Основное рекуррентное неравенство

Пусть $x^\star$ — точка минимума. Тогда

$$\begin{aligned}\|x_{k+1} - x^\star\|^2 &= \|x_k - \alpha_k g_k - x^\star\|^2 \\ &= \|x_k - x^\star\|^2 - 2\alpha_k g_k^\top (x_k - x^\star) + \alpha_k^2 \|g_k\|^2 .\end{aligned}$$

Из субградиентного неравенства

$$g_k^\top (x_k - x^\star) \geq f(x_k) - f^\star.$$

Следовательно,

$$\boxed{\|x_{k+1} - x^\star\|^2 \leq \|x_k - x^\star\|^2 - 2\alpha_k (f(x_k) - f^\star) + \alpha_k^2 \|g_k\|^2 .}$$

Это основное неравенство анализа субградиентного метода. Обратите внимание на принципиальное отличие от леммы о спуске: оно контролирует не непосредственное уменьшение $f(x_k)$, а баланс между расстоянием до решения, субоптимальностью и величиной шага.

Оценка субоптимальности

Предположим, что вдоль итераций субградиенты ограничены: $\|g_k\| \leq G$.
Суммируя рекуррентное неравенство по $k = 0, \ldots, N-1$,

$$2\sum_{k=0}^{N-1} \alpha_k (f(x_k) - f^\star) \leq \|x_0 - x^\star\|^2 - \|x_N - x^\star\|^2 + \sum_{k=0}^{N-1} \alpha_k^2 \|g_k\|^2$$

$$\leq \|x_0 - x^\star\|^2 + G^2 \sum_{k=0}^{N-1} \alpha_k^2.$$

Поскольку взвешенное среднее не меньше минимума:

$$\sum_{k=0}^{N-1} \alpha_k (f(x_k) - f^\star) \geq \left(\sum_{k=0}^{N-1} \alpha_k\right) \min_{0 \leq k < N} (f(x_k) - f^\star),$$

получаем

$$\boxed{\min_{0 \leq k < N} (f(x_k) - f^\star) \leq \frac{\|x_0 - x^\star\|^2 + G^2 \sum_{k=0}^{N-1} \alpha_k^2}{2 \sum_{k=0}^{N-1} \alpha_k}.}$$

Эта формула объясняет, почему выбор шага в субградиентном методе устроен иначе, чем в гладком градиентном спуске.

Выбор шага I: постоянный шаг

Пусть $\alpha_k \equiv \alpha$. Из общей оценки субоптимальности

$$\min_{0 \le k < N} (f(x_k) - f^\star) \le \frac{\|x_0 - x^\star\|^2 + G^2 \sum_{k=0}^{N-1} \alpha_k^2}{2 \sum_{k=0}^{N-1} \alpha_k}$$

получаем

$$\boxed{\min_{0 \le k < N} (f(x_k) - f^\star) \le \frac{\|x_0 - x^\star\|^2}{2\alpha N} + \frac{\alpha G^2}{2}.}$$

При $N \to \infty$ первый член исчезает, но второй остаётся. Поэтому фиксированный шаг в общем случае гарантирует лишь выход в окрестность оптимального значения, размер которой определяется α.

Выбор шага II: конечный горизонт

Пусть заранее известно число итераций N и имеется известная априорная оценка

$$\|x_0 - x^\star\| \leq R$$

для некоторой точки минимума $x^\star$. Знание R не означает знания самой точки $x^\star$: например, оценка может следовать из априорной информации о множестве, в котором лежит решение.

Возьмём постоянный на этих N итерациях шаг

$$\alpha = \frac{R}{G\sqrt{N}}.$$

Подставляя $\|x_0 - x^\star\| \leq R$ в оценку для постоянного шага,

$$\min_{0 \leq k < N} (f(x_k) - f^\star) \leq \frac{R^2}{2\alpha N} + \frac{\alpha G^2}{2}$$

$$= \frac{RG}{2\sqrt{N}} + \frac{RG}{2\sqrt{N}} = \boxed{\frac{RG}{\sqrt{N}}}.$$

Выбор шага II: конечный горизонт

Обозначим лучшее найденное значение

$$f_{\text{best}}^{(N-1)} = \min_{0 \le k < N} f(x_k).$$

Тогда после N итераций

$$\boxed{f_{\text{best}}^{(N-1)} - f^\star \le \frac{RG}{\sqrt{N}} = O(N^{-1/2}).}$$

Это **скорость сходимости**: она описывает, как гарантированная ошибка убывает с ростом числа итераций.
Чтобы гарантировать $f_{\text{best}}^{(N-1)} - f^\star \le \varepsilon$, достаточно потребовать

$$\frac{RG}{\sqrt{N}} \le \varepsilon \quad \Longleftrightarrow \quad N \ge \frac{R^2 G^2}{\varepsilon^2}.$$

Следовательно,

$$\boxed{N = O\left(\frac{R^2 G^2}{\varepsilon^2}\right) = O(\varepsilon^{-2})}$$

при фиксированных параметрах задачи. Это **итерационная сложность**: сколько итераций достаточно для заданной точности.

Выбор шага III: убывающие шаги

Классическое асимптотическое условие:

$$\alpha_k > 0, \qquad \sum_k \alpha_k = \infty, \qquad \sum_k \alpha_k^2 < \infty.$$

Пример: $\alpha_k = c/(k+1)$. Первая сумма не позволяет шагам закончиться слишком рано; вторая контролирует накопление $\alpha_k^2 \|g_k\|^2$.

Не следует смешивать это условие с конечногоризонтным выбором порядка $1/\sqrt{k}$: для него сумма квадратов расходится.

Выбор шага IV: шаг Поляка

Если $f^\star$ известно, выберем α_k так, чтобы минимизировать зависящую от шага часть рекуррентной оценки:

$$-2\alpha_k(f(x_k) - f^\star) + \alpha_k^2 \|g_k\|^2 .$$

Производная по α_k равна

$$-2(f(x_k) - f^\star) + 2\alpha_k \|g_k\|^2 .$$

Приравнивая её к нулю, получаем

$$\boxed{\alpha_k = \frac{f(x_k) - f^\star}{\|g_k\|^2}.}$$

Это шаг Поляка. Его практическое ограничение: оптимальное значение $f^\star$ обычно неизвестно.

Градиентный и субградиентный методы, сравнение

	Градиентный	Субградиентный
Объект 1-го порядка	единственный $\nabla f(x_k)$	любой $g_k \in \partial f(x_k)$
Направление	$-\nabla f$ — спуск при $\nabla f \neq 0$	$-g_k$ не обязано быть спуском
Монотонность	при корректном шаге	в общем случае нет
Типичный шаг	$1/L$ или линейный поиск	убывающий, конечный горизонт, Поляк
Стандартная выпуклая скорость	$O(1/k)$ при L-гладкости	$O(1/\sqrt{k})$ при ограниченных субградиентах

Сравнение скоростей корректно именно как сравнение двух разных стандартных классов задач и предположений: гладкой выпуклой L-гладкой задачи и общей выпуклой негладкой задачи с ограниченными субградиентами.

Евклидова проекция

Пусть $C \subset \mathbb{R}^n$ — непустое замкнутое выпуклое множество.

Definition 5 (Евклидова проекция)

$$\Pi_C(v) = \arg\min_{x \in C} \frac{1}{2} \|x - v\|^2 .$$

Благодаря строгой выпуклости квадратичной функции и замкнутости C проекция существует и единственна.

Проекционные субградиентный и градиентный методы

Для задачи $\min_{x \in C} f(x)$ субградиентный шаг состоит из двух стадий:

$$y_{k+1} = x_k - \alpha_k g_k, \qquad g_k \in \partial f(x_k),$$

$$x_{k+1} = \Pi_C(y_{k+1}).$$

Итого

$$\boxed{x_{k+1} = \Pi_C(x_k - \alpha_k g_k).}$$

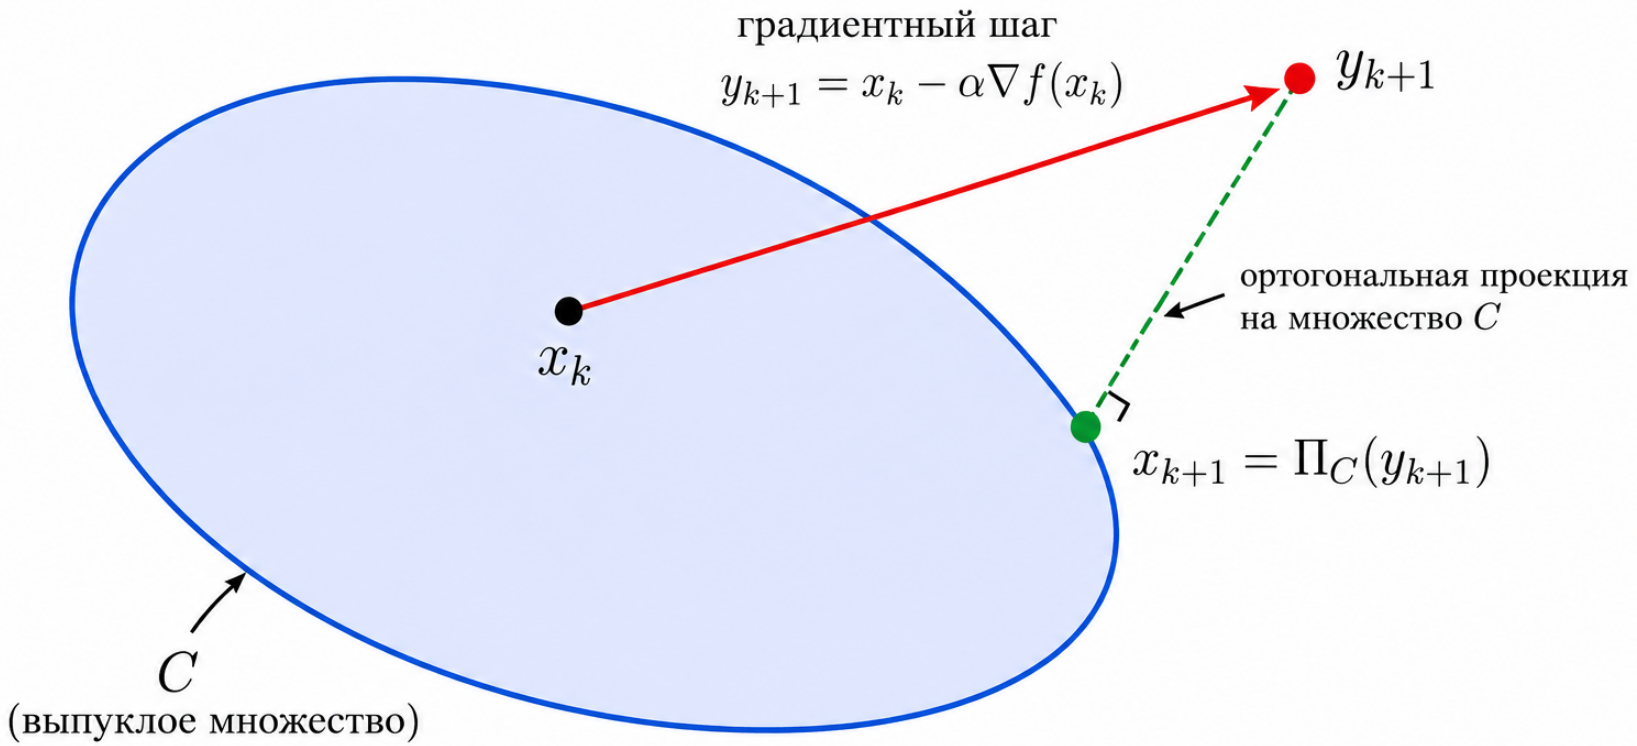
Сначала делаем обычный субградиентный шаг, который может выйти из C, затем возвращаемся к ближайшей допустимой точке.

Если f дифференцируема, получаем

$$\boxed{x_{k+1} = \Pi_C(x_k - \alpha_k \nabla f(x_k)).}$$

Ниже увидим, что проекция — частный случай prox, а этот алгоритм — частный случай проксимального градиента.

Иллюстрация: проекционный градиентный шаг



Зачем использовать структуру $F = f + g$?

Рассмотрим

$$\boxed{\min_x F(x) = f(x) + g(x),}$$

где f выпукла, дифференцируема и L-гладка, а g выпукла и может быть негладкой.

Можно было бы забыть структуру суммы, выбрать

$$s_k \in \partial F(x_k) = \nabla f(x_k) + \partial g(x_k)$$

и применить общий субградиентный метод. Но тогда мы сознательно выбрасываем полезную информацию:

- большая часть функции, f, гладкая;
- g может иметь специальный простой вид: $\lambda \|x\|_1$ (разреженность), δ_C (ограничение $x \in C$), другой регуляризатор с дешёвой вспомогательной задачей.

Идея prox

Линеаризовать гладкую часть, но *не линеаризовать* негладкую структурированную часть.

Градиентный шаг как минимум локальной модели

Для гладкой f рассмотрим

$$M_\alpha(y; x_k) = f(x_k) + \nabla f(x_k)^\top (y - x_k) + \frac{1}{2\alpha} \|y - x_k\|^2 .$$

Первое и второе слагаемые образуют линейную модель f, а квадратичный член штрафует слишком далёкое отклонение от x_k и делает модель сильно выпуклой по y.
Минимизируем по y:

$$\nabla_y M_\alpha = \nabla f(x_k) + \frac{1}{\alpha}(y - x_k) = 0,$$

откуда

$$y = x_k - \alpha \nabla f(x_k).$$

Значит,

$$\boxed{x_{k+1} = \arg\min_y \left\{ \nabla f(x_k)^\top (y - x_k) + \frac{1}{2\alpha} \|y - x_k\|^2 \right\}.}$$

Именно эта вариационная запись, а не формальное “добавим prox после градиента”, ведёт к prox.

Собственная и замкнутая функция

Чтобы кодировать ограничения, разрешаем $g : \mathbb{R}^n \to \mathbb{R} \cup \{+\infty\}$ и вводим

$$\operatorname{dom} g = \{x : g(x) < +\infty\}.$$

Собственная функция

g не тождественно $+\infty$ и нигде не принимает $-\infty$.

Замкнутая функция

Эпиграф

$$\operatorname{epi} g = \{(x, t) : g(x) \le t\}$$

замкнут. Для собственной выпуклой функции в конечномерном пространстве это эквивалентно нижней полунепрерывности:

$$x_j \to x \quad \Rightarrow \quad g(x) \le \liminf_j g(x_j).$$

Интуитивно, при переходе к пределу значение замкнутой функции не может внезапно «провалиться вниз». Замкнутость вместе с квадратичным штрафом обеспечивает достижение минимума в prox-подзадаче, а сильная выпуклость этой подзадачи — единственность.

Проксимальный оператор

Definition 6 (Проксимальный оператор)

Для $\alpha > 0$

$$\boxed{\operatorname{prox}_{\alpha g}(v) = \arg\min_x \left\{ g(x) + \frac{1}{2\alpha} \|x - v\|^2 \right\}.}$$

Квадратичное слагаемое делает подзадачу $1/\alpha$-сильно выпуклой, поэтому при стандартных предположениях минимум единственен.

Роль α

Малое α: сильнее требование оставаться близко к v. Большое α: сильнее влияние уменьшения $g(x)$.

Условие оптимальности для prox

Пусть $x^+ = \operatorname{prox}_{\alpha g}(v)$. Тогда x^+ минимизирует

$$\Phi(x) = g(x) + \frac{1}{2\alpha}\|x - v\|^2.$$

По субградиентному условию оптимальности, применённому именно к Φ,

$$0 \in \partial\Phi(x^+).$$

Квадратичное слагаемое дифференцируемо, причём

$$\nabla\left(\frac{1}{2\alpha}\|x - v\|^2\right) = \frac{1}{\alpha}(x - v).$$

По правилу суммы

$$\partial\Phi(x^+) = \partial g(x^+) + \frac{1}{\alpha}(x^+ - v),$$

поэтому

$$0 \in \partial g(x^+) + \frac{1}{\alpha}(x^+ - v) \quad \Longleftrightarrow \quad \boxed{\frac{v - x^+}{\alpha} \in \partial g(x^+).}$$

Ключевое отличие

Явный субградиентный шаг использует субградиент в старой точке; prox задаётся условием на субградиент в новой точке x^+.

Проекция как prox индикаторной функции

Для непустого замкнутого выпуклого C определим

$$\delta_C(x) = \begin{cases} 0, & x \in C, \\ +\infty, & x \notin C. \end{cases}$$

$+\infty$ здесь означает полный запрет точек вне C, а не просто большой штраф. Тогда

$$\begin{aligned} \operatorname{prox}_{\alpha\delta_C}(v) &= \arg\min_x \left\{ \delta_C(x) + \frac{1}{2\alpha}\|x - v\|^2 \right\} \\ &= \arg\min_{x \in C} \frac{1}{2\alpha}\|x - v\|^2 = \Pi_C(v). \end{aligned}$$

Итак,

$$\boxed{\operatorname{prox}_{\alpha\delta_C} = \Pi_C.}$$

Параметр α результата не меняет.

Prox нормы ℓ_1: сведение к одномерной задаче

Пусть $g(x) = \lambda \|x\|_1$, $\lambda > 0$. Тогда

$$\operatorname{prox}_{\alpha\lambda\|\cdot\|_1}(v) = \arg\min_x \left\{ \lambda \sum_{i=1}^n |x_i| + \frac{1}{2\alpha} \sum_{i=1}^n (x_i - v_i)^2 \right\}.$$

Целевая функция сепарабельна по координатам, поэтому каждая координата решает

$$\min_{x \in \mathbb{R}} \left\{ \lambda |x| + \frac{1}{2\alpha}(x - v)^2 \right\}.$$

Разберём три случая:

- $x > 0$: $\lambda + \frac{1}{\alpha}(x - v) = 0$, поэтому $x = v - \alpha\lambda$; условие $x > 0$ требует $v > \alpha\lambda$;
- $x < 0$: $-\lambda + \frac{1}{\alpha}(x - v) = 0$, поэтому $x = v + \alpha\lambda$; условие $x < 0$ требует $v < -\alpha\lambda$;
- $x = 0$: $0 \in \lambda[-1, 1] - v/\alpha \iff v/\alpha \in \lambda[-1, 1] \iff |v| \le \alpha\lambda$.

Prox нормы ℓ_1: мягкая пороговая обработка

Объединяя три случая, получаем оператор мягкой пороговой обработки

$$\boxed{S_{\alpha\lambda}(v) = \operatorname{sign}(v)\max\{|v| - \alpha\lambda, 0\}.}$$

Для вектора оператор применяется покоординатно:

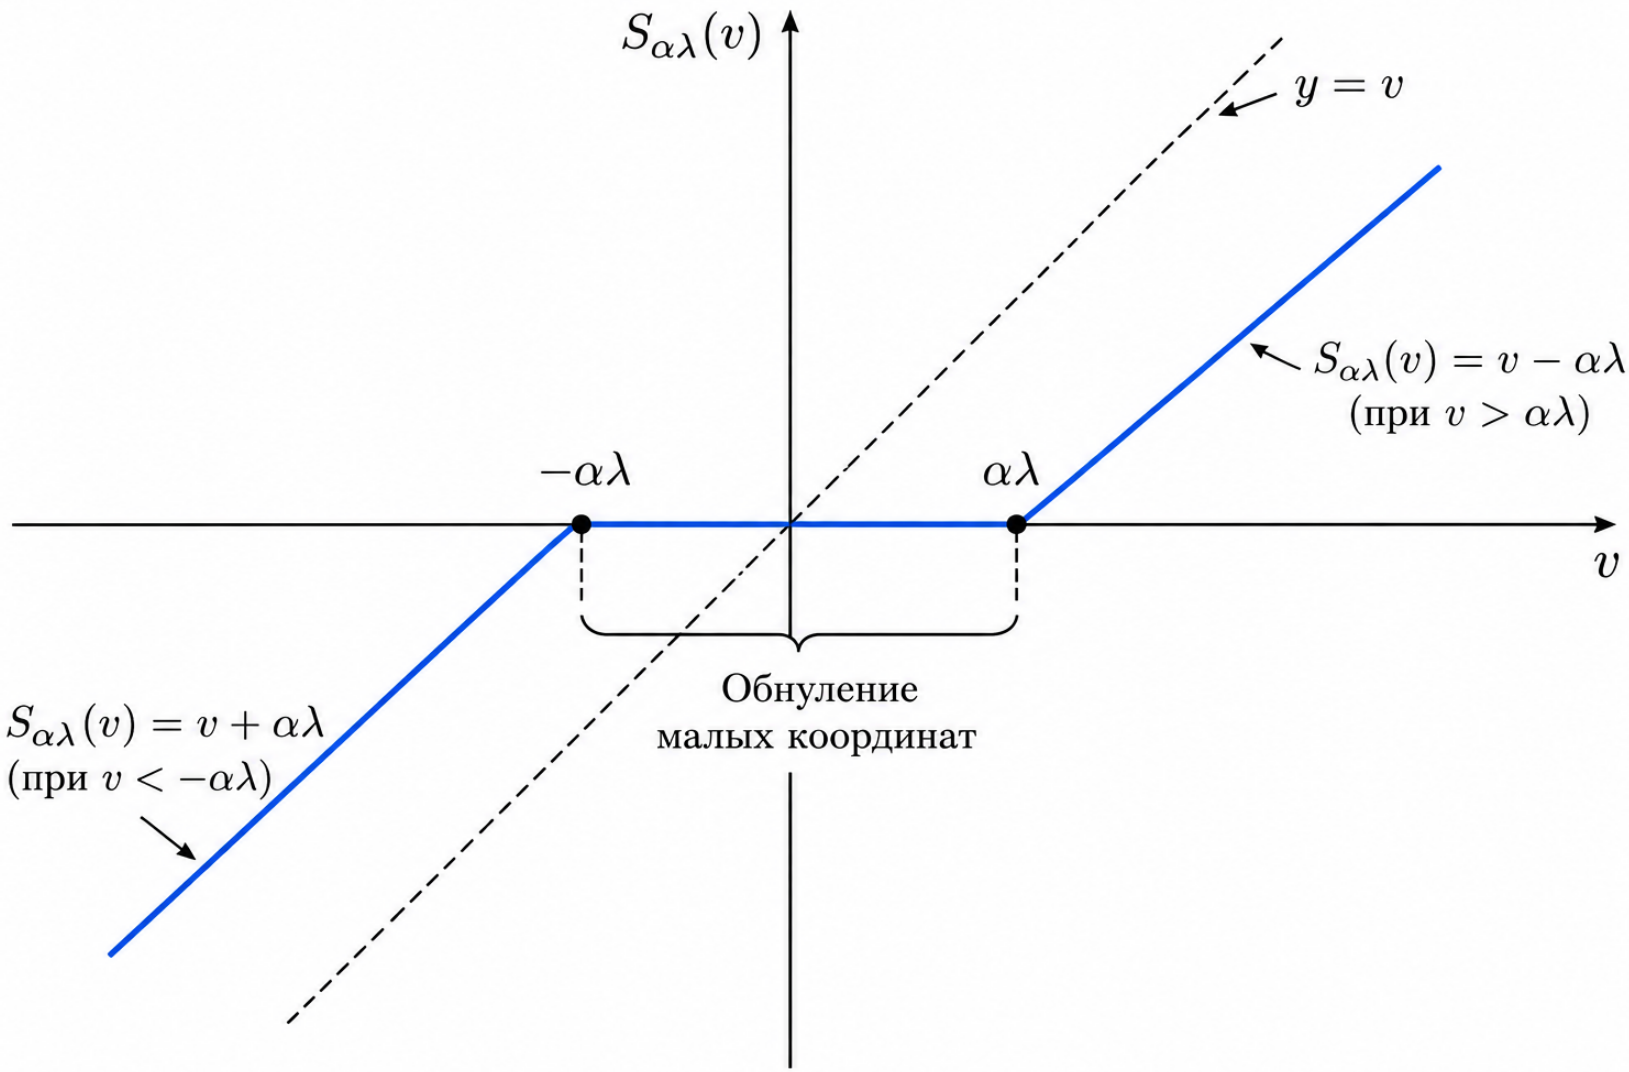
$$\boxed{[\operatorname{prox}_{\alpha\lambda\|\cdot\|_1}(v)]_i = \operatorname{sign}(v_i)\max\{|v_i| - \alpha\lambda, 0\}.}$$

Следовательно,

- если $|v_i| \le \alpha\lambda$, координата становится *точно нулевой*;
- если $|v_i| > \alpha\lambda$, её модуль уменьшается на $\alpha\lambda$.

Это и есть алгоритмический механизм возникновения разреженности.

Иллюстрация: мягкая пороговая обработка



Проксимальный градиент: локальная модель

Для $F = f + g$ хотим использовать гладкость f, но не заменять негладкую g субградиентом. В точке x_k линеаризуем только f, добавляем квадратичную стабилизацию, а g оставляем без изменений:

$$Q_\alpha(y; x_k) = f(x_k) + \nabla f(x_k)^\top (y - x_k) + \frac{1}{2\alpha} \|y - x_k\|^2 + g(y).$$

Следующую точку определяем как *точный минимум этой модели*:

$$\boxed{x_{k+1} = \arg\min_y Q_\alpha(y; x_k).}$$

Это тот же принцип, который дал обычный градиентный шаг, но теперь негладкая структурированная часть g сохраняется в модели в точности.

Проксимальный градиент: преобразование модели

Преобразуем зависящую от y квадратичную часть. С точностью до слагаемых, не зависящих от y,

$$\begin{aligned}
&\nabla f(x_k)^\top (y - x_k) + \frac{1}{2\alpha} \|y - x_k\|^2 \\
&= \frac{1}{2\alpha} \Big(\|y - x_k\|^2 + 2\alpha \nabla f(x_k)^\top (y - x_k) \Big) \\
&= \frac{1}{2\alpha} \|y - (x_k - \alpha \nabla f(x_k))\|^2 + \text{const}.
\end{aligned}$$

Поэтому

$$x_{k+1} = \arg\min_y \left\{ g(y) + \frac{1}{2\alpha} \|y - (x_k - \alpha \nabla f(x_k))\|^2 \right\}.$$

По определению prox,

$$\boxed{x_{k+1} = \operatorname{prox}_{\alpha g}(x_k - \alpha \nabla f(x_k)).}$$

Формула возникает из точной минимизации локальной модели, а не из формального «приклеивания prox» к градиентному шагу.

Определение проксимального градиентного метода

Definition 7 (Проксимальный градиентный метод)

Для

$$\min_x F(x) = f(x) + g(x)$$

строим

$$\boxed{x_{k+1} = \operatorname{prox}_{\alpha_k g}\left(x_k - \alpha_k \nabla f(x_k)\right).}$$

Для L-гладкой f стандартно берём $0 < \alpha_k \leq 1/L$; для доказательства скорости ниже — $\alpha_k = 1/L$.

Итерацию удобно читать как две стадии:

$$z_k = x_k - \alpha \nabla f(x_k), \qquad x_{k+1} = \operatorname{prox}_{\alpha g}(z_k).$$

Частные случаи проксимального градиента

$g \equiv 0$

$\text{prox}_{\alpha g}(v) = v$, поэтому

$$x_{k+1} = x_k - \alpha \nabla f(x_k).$$

Обычный градиентный метод.

$g = \delta_C$

$\text{prox}_{\alpha g} = \Pi_C$, поэтому

$$\boxed{x_{k+1} = \Pi_C(x_k - \alpha \nabla f(x_k)).}$$

Проекционный градиентный метод.

$g(x) = \lambda \|x\|_1$

$$\boxed{x_{k+1} = S_{\alpha\lambda}(x_k - \alpha \nabla f(x_k)).}$$

Это схема ISTA для задач с ℓ_1-штрафом.

Почему $\alpha \le 1/L$ естественен?

По лемме о спуске

$$f(y) \le f(x_k) + \nabla f(x_k)^\top (y - x_k) + \frac{L}{2} \|y - x_k\|^2 .$$

Если $\alpha \le 1/L$, то $1/(2\alpha) \ge L/2$, поэтому

$$F(y) \le Q_\alpha(y; x_k), \qquad Q_\alpha(x_k; x_k) = F(x_k).$$

То есть Q_α — верхняя модель F, касающаяся её в x_k.
Поскольку x_{k+1} минимизирует $Q_\alpha(\cdot; x_k)$,

$$Q_\alpha(x_{k+1}; x_k) \le Q_\alpha(x_k; x_k) = F(x_k).$$

С другой стороны, из $F(y) \le Q_\alpha(y; x_k)$ при $y = x_{k+1}$ имеем

$$F(x_{k+1}) \le Q_\alpha(x_{k+1}; x_k).$$

Объединяя два неравенства,

$$F(x_{k+1}) \le Q_\alpha(x_{k+1}; x_k) \le F(x_k).$$

Следовательно,

$$\boxed{F(x_{k+1}) \le F(x_k).}$$

В отличие от общего субградиентного метода, монотонность возвращается.

Скорость prox-gradient: предположения

Пусть

- f выпукла и имеет L-липшицев градиент;
- g — собственная замкнутая выпуклая функция;
- $F = f + g$ имеет точку минимума $x^\star$;
- $\alpha = 1/L$.

Обозначим $x = x_k$, $x^+ = x_{k+1}$.
Из оптимальности x^+ в локальной модели существует $s^+ \in \partial g(x^+)$ такое, что

$$\boxed{\nabla f(x) + L(x^+ - x) + s^+ = 0.}$$

Эта связь объединяет гладкую и негладкую части и является отправной точкой оценки скорости.

Одношаговое неравенство: три оценки

Пусть $x = x_k$, $x^+ = x_{k+1}$ и $s^+ \in \partial g(x^+)$ удовлетворяет

$$\nabla f(x) + L(x^+ - x) + s^+ = 0.$$

Для любого y по выпуклости g

$$g(y) \geq g(x^+) + (s^+)^\top (y - x^+) \quad \Longleftrightarrow \quad g(x^+) - g(y) \leq (s^+)^\top (x^+ - y).$$

По лемме о спуске

$$f(x^+) \leq f(x) + \nabla f(x)^\top (x^+ - x) + \frac{L}{2} \left\| x^+ - x \right\|^2.$$

По выпуклости f

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x) \quad \Longleftrightarrow \quad f(x) - f(y) \leq \nabla f(x)^\top (x - y).$$

Одношаговое неравенство: складываем оценки

Складывая три предыдущих соотношения,

$$F(x^+) - F(y) \le \nabla f(x)^\top (x^+ - y) + \frac{L}{2}\left\|x^+ - x\right\|^2 + (s^+)^\top (x^+ - y)$$
$$= (\nabla f(x) + s^+)^\top (x^+ - y) + \frac{L}{2}\left\|x^+ - x\right\|^2.$$

Из условия оптимальности локальной модели

$$\nabla f(x) + s^+ = -L(x^+ - x) = L(x - x^+),$$

поэтому

$$F(x^+) - F(y) \le L(x - x^+)^\top (x^+ - y) + \frac{L}{2}\left\|x^+ - x\right\|^2.$$

Используем тождество

$$2(x - x^+)^\top (x^+ - y) = \|x - y\|^2 - \left\|x^+ - y\right\|^2 - \left\|x - x^+\right\|^2.$$

Квадратичные члены сокращаются, и получаем

$$\boxed{F(x_{k+1}) - F(y) \le \frac{L}{2}\left(\|x_k - y\|^2 - \|x_{k+1} - y\|^2\right).}$$

Телескопирование и скорость $O(1/N)$

Положим $y = x^\star$:

$$F(x_{k+1}) - F^\star \le \frac{L}{2}\left(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2\right).$$

Суммируя по $k = 0, \dots, N-1$,

$$\begin{aligned}\sum_{k=0}^{N-1}(F(x_{k+1}) - F^\star) &\le \frac{L}{2}\sum_{k=0}^{N-1}\left(\|x_k - x^\star\|^2 - \|x_{k+1} - x^\star\|^2\right) \\ &= \frac{L}{2}\left(\|x_0 - x^\star\|^2 - \|x_N - x^\star\|^2\right) \\ &\le \frac{L}{2}\|x_0 - x^\star\|^2.\end{aligned}$$

Слагаемое с x_N не исчезает: его отбрасываем, поскольку $\|x_N - x^\star\|^2 \ge 0$.
Так как при $\alpha = 1/L$ $F(x_k)$ невозрастает,

$$N(F(x_N) - F^\star) \le \sum_{k=0}^{N-1}(F(x_{k+1}) - F^\star).$$

Итак,

$$\boxed{F(x_N) - F^\star \le \frac{L\|x_0 - x^\star\|^2}{2N} = O(1/N).}$$

Структура $f + g$ улучшает стандартную общую негладкую оценку $O(N^{-1/2})$ до $O(N^{-1})$.

Дальше по курсу: ускоренный проксимальный градиент позволяет улучшить оценку до $O(1/N^2)$; здесь ускоренную схему не вводим.

LASSO: от составной структуры к ISTA

Для

$$F(x) = \frac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1$$

имеем

$$f(x) = \frac{1}{2}\|Ax - b\|_2^2, \qquad g(x) = \lambda\|x\|_1,$$

$$\nabla f(x) = A^\top(Ax - b), \qquad \nabla f(x) - \nabla f(y) = A^\top A(x - y).$$

Следовательно,

$$\begin{aligned}\|\nabla f(x) - \nabla f(y)\| &= \left\|A^\top A(x - y)\right\| \\ &\le \left\|A^\top A\right\|_{\text{op}} \|x - y\|.\end{aligned}$$

Поэтому можно взять

$$\boxed{L = \left\|A^\top A\right\|_{\text{op}} = \|A\|_{\text{op}}^2.}$$

Поэтому

$$\boxed{x_{k+1} = S_{\alpha\lambda}\left(x_k - \alpha A^\top(Ax_k - b)\right), \qquad 0 < \alpha \le \frac{1}{\|A\|_{\text{op}}^2}.}$$

Это ISTA (iterative shrinkage-thresholding algorithm).

Градиентный шаг уменьшает квадратичную ошибку, а soft-thresholding обнуляет малые координаты и уменьшает остальные по модулю: регуляризатор непосредственно встроен в алгоритм.

Стоимость одной итерации

Субградиентный метод

Если $C_{\partial f}$ — стоимость одного субградиента, то

$$\boxed{\text{стоимость итерации} = C_{\partial f} + O(n), \qquad \text{доп. память} = O(n).}$$

Итерация дешева, но стандартная скорость — $O(1/\sqrt{k})$.

Проксимальный градиент

Если C_g — стоимость вычисления ∇f, а C_{prox} — стоимость prox, то

$$\boxed{\text{стоимость итерации} = C_g + C_{\text{prox}} + O(n).}$$

Последний член — простые векторные операции и может уже входить в реализацию первых двух частей. Ключевой момент: «простая» g здесь означает прежде всего функцию с эффективно вычислимым prox. Для $\lambda \|x\|_1$ он стоит $O(n)$; для δ_C стоимость равна стоимости проекции на C.

Когда какой подход естественен?

Ситуация	Метод	Почему
Общая выпуклая негладкая f, доступен субградиент	субградиентный	минимальные требования к структуре
Гладкая задача с простым $x \in C$	проекционный градиентный	проекция возвращает допустимость
$F = f + g$, f гладкая, prox для g дешёв	проксимальный градиентный	сохраняет структуру g и даёт более сильную стандартную оценку
ℓ_1-регуляризация	ISTA / prox-gradient	prox — явный soft-thresholding

Проксимальный метод точки: идея

Для выпуклой F:

$$\boxed{x_{k+1} = \operatorname{prox}_{\alpha_k F}(x_k) = \arg\min_x \left\{ F(x) + \frac{1}{2\alpha_k} \|x - x_k\|^2 \right\}.}$$

Условие оптимальности:

$$0 \in \partial F(x_{k+1}) + \frac{1}{\alpha_k}(x_{k+1} - x_k),$$

то есть

$$\boxed{x_{k+1} = x_k - \alpha_k g_{k+1}, \qquad g_{k+1} \in \partial F(x_{k+1}).}$$

Сравните с явным субградиентным шагом, использующим $g_k \in \partial F(x_k)$.

Это неявная схема: потенциально более сильный шаг, но цена — решение prox-подзадачи для всей F на каждой итерации. Если prox для всей F не имеет простой формы, непосредственная реализация может быть слишком дорогой.

Концептуально этот метод показывает, что prox — самостоятельный базовый механизм оптимизации, а не только дополнение к градиентному шагу.

ADMM: идея расщепления

Для

$$\min_{x,z} f(x) + g(z) \quad \text{при } Ax + Bz = c$$

масштабированная форма ADMM при $\rho > 0$:

$$x^{k+1} := \arg\min_x \left\{ f(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + u^k \right\|^2 \right\},$$

$$z^{k+1} := \arg\min_z \left\{ g(z) + \frac{\rho}{2} \left\| Ax^{k+1} + Bz - c + u^k \right\|^2 \right\},$$

$$u^{k+1} := u^k + Ax^{k+1} + Bz^{k+1} - c.$$

Главная идея

Совместная задача может быть трудной, а отдельные подзадачи по x и z — простыми. u играет роль масштабированной двойственной переменной и накапливает нарушение ограничения.

Сходимость, выбор ρ, residuals и распределённые реализации выходят за рамки лекции.

Что важно вынести I

1. $\partial f(x)$ заменяет градиент в выпуклом негладком случае; в гладкой точке $\partial f(x) = \{\nabla f(x)\}$.
2. Выпуклая оптимальность: $\boxed{0 \in \partial f(x^\star)}$.
3. Субградиентный метод
$$x_{k+1} = x_k - \alpha_k g_k$$
не является просто GD с другим названием: $-g_k$ может не быть направлением спуска, а значения функции могут быть немонотонны.
4. При ограниченных субградиентах стандартная оценка — $O(1/\sqrt{k})$, то есть $O(1/\varepsilon^2)$ итераций для точности ε.
5. Проекция Π_C даёт проекционные методы для простых выпуклых ограничений.

Что важно вынести II

6. Prox:
$$\operatorname{prox}_{\alpha g}(v) = \arg\min_x \left\{ g(x) + \frac{1}{2\alpha} \|x - v\|^2 \right\}.$$
7. $\operatorname{prox}_{\alpha \delta_C} = \Pi_C$, а prox ℓ_1 — soft-thresholding.
8. Prox-gradient выводится из локальной модели:
$$\boxed{x_{k+1} = \operatorname{prox}_{\alpha g}(x_k - \alpha \nabla f(x_k)).}$$
9. При выпуклой L-гладкой f и выпуклой g, $\alpha = 1/L$:
$$F(x_k) - F^\star \leq \frac{L \|x_0 - x^\star\|^2}{2k} = O(1/k).$$
10. Для LASSO получаем ISTA; soft-thresholding создаёт точные нули.
11. Proximal point и ADMM показывают более общую идею: использовать структуру частей задачи, а не игнорировать её.