Дополнительные главы оптимизации

Лекция 5. Барьерные методы и методы внутренней точки

План лекции

1. Как алгоритмически работать с ограничениями?
2. Логарифмический барьер и центрирующая задача
3. Центральная траектория, KKT и двойственность
4. Path-following и барьерный метод
5. Прямодвойственные методы внутренней точки

От условий оптимальности — к алгоритму

Во второй лекции мы отвечали на вопрос: *какими свойствами обладает решение?* Теперь вопрос алгоритмический: *как это решение находить?*

Основная задача лекции:

$$\begin{array}{lll} & \min\limits_{x\in\mathbb{R}^n} & f(x), \\ \text{при условиях} & s_i(x) \le 0, & i = 1,\dots,m, \\ & Ax = b, & \end{array} \tag{1}$$

- $f, s_1, \dots, s_m$ выпуклы и достаточно гладкие там, где это потребуется;
- равенства аффинны;
- существует точка, для которой $Ax = b$ и $s_i(x) < 0$ для всех i.

Последнее — условие типа Слейтера; оно понадобится и для барьерной конструкции, и для связи с двойственностью.

Логика лекции

1. **Как работать с ограничениями?** Проекция, штраф, негладкие формулировки, барьер.
2. **Логарифмический барьер и центрирование.** Барьер $\to$ барьерная задача $\to$ Ньютон.
3. **Центральная траектория, KKT и двойственность.** Возмущённые KKT $\to$ двойственные переменные $\to$ двойственный разрыв.
4. **Path-following и барьерный метод.** Отслеживание центральной траектории $\to$ алгоритм $\to$ Phase I.
5. **Прямодвойственные методы внутренней точки.** Возмущённая система KKT $\to$ совместное обновление прямых и двойственных переменных.

Главная идея

Методы внутренней точки возникают из уже знакомых объектов — выпуклости, KKT, двойственности и метода Ньютона — когда мы решаем задачи с неравенствами, двигаясь через внутренность допустимого множества.

Проекция: сделать шаг и вернуться в допустимое множество

Для выпуклого замкнутого множества C проекционный градиентный метод имеет вид

$$\boxed{x_{k+1} = \Pi_C(x_k - \alpha_k \nabla f(x_k))}, \qquad \Pi_C(y) = \arg\min_{x \in C} \frac{1}{2} \|x - y\|^2 .$$

Логика шага проста:

1. обычный градиентный шаг $x_k - \alpha_k \nabla f(x_k)$ может выйти из C;
2. проекция возвращает ближайшую допустимую точку.

Когда это действительно удобно?

Если Π_C вычисляется дёшево: например, для шара, ящика или полупространства.

Для $C = \{x : s_i(x) \le 0\}$ сама проекция может оказаться условной задачей оптимизации. Поэтому “просто спроецироваться” — не универсальный способ работы с ограничениями.

Штрафные методы: от ограничения к безусловной задаче

Рассмотрим сначала задачу с равенствами

$$\min_x f(x) \qquad \text{при } h(x) = 0.$$

Вместо точного ограничения минимизируем *квадратично штрафованную* функцию

$$\boxed{P_\rho(x) = f(x) + \frac{\rho}{2}\|h(x)\|^2}, \qquad \rho > 0. \tag{2}$$

Теперь задача безусловная: если $h(x) \neq 0$, нарушение увеличивает значение цели, а при росте ρ становится всё дороже.
Если $h = (h_1, \dots, h_p)$ дифференцируема, то

$$\nabla P_\rho(x) = \nabla f(x) + \rho J_h(x)^\top h(x),$$

где $J_h(x)$ — якобиан ограничений. Следующий вопрос: как стационарность этой задачи связана с KKT исходной?

Квадратичный штраф и множители Лагранжа

Стационарная точка штрафной задачи удовлетворяет

$$\nabla f(x_\rho) + J_h(x_\rho)^\top \underbrace{\big(\rho h(x_\rho)\big)}_{\lambda_\rho} = 0. \tag{3}$$

Сравним с условием стационарности KKT исходной задачи:

$$\nabla f(x^\star) + J_h(x^\star)^\top \lambda^\star = 0.$$

Поэтому величина

$$\boxed{\lambda_\rho := \rho h(x_\rho)}$$

естественно играет роль приближения к множителю Лагранжа.

Предельная связь

Если при $\rho \to \infty$ точки x_ρ сходятся к допустимой $x^\star$ и λ_ρ имеет конечный предел, то в пределе восстанавливается соответствующая часть условий KKT.

Именно сравнение двух условий стационарности объясняет появление λ_ρ; это не отдельное искусственное определение.

Квадратичный штраф для неравенств

Для ограничений $s_i(x) \le 0$ простая квадратичная конструкция имеет вид

$$\boxed{P_\rho(x) = f(x) + \frac{\rho}{2} \sum_{i=1}^{m} [s_i(x)]_+^2}, \qquad [u]_+ = \max\{u, 0\}. \tag{4}$$

Допустимое ограничение $s_i(x) \le 0$ ничего не добавляет к штрафу, а нарушенное $s_i(x) > 0$ получает положительную цену.

Почему нельзя просто взять очень большой ρ?

Чтобы сделать нарушение очень малым, квадратичному штрафу обычно требуется большое ρ. Тогда кривизна штрафной части в направлениях ограничений становится большой по сравнению с остальными направлениями, и задача может стать плохо обусловленной.

Поэтому схема $\rho_1 < \rho_2 < \cdots$, $\rho_k \to \infty$ концептуально проста, но численно не всегда удобна. Это мотивирует, например, метод множителей и расширенный лагранжиан, где штраф сочетается с обновлением оценок множителей.

Точный негладкий штраф

Помимо квадратичных штрафов можно использовать *негладкий* штраф

$$P_\rho(x) = f(x) + \rho \sum_{i=1}^{m} [s_i(x)]_+ + \rho \sum_{j=1}^{p} |h_j(x)|. \tag{5}$$

Ключевое отличие

При подходящих условиях такой штраф может быть *точным*: начиная с достаточно большого, но конечного ρ, решение штрафной задачи совпадает с решением исходной условной задачи.

Цена этого свойства — негладкость. Поэтому естественными инструментами становятся субградиентные и проксимальные методы из лекции 4.

Дальше покажем механизм точности в выпуклом случае: он непосредственно связан с оптимальными множителями и сильной двойственностью.

Почему негладкий штраф может быть точным

Пусть $x^\star$ — решение, существуют оптимальные множители $\lambda_i^\star \geq 0$, $\nu_j^\star$ и выполнена сильная двойственность. Тогда для любого x

$$f(x) + \sum_i \lambda_i^\star s_i(x) + \sum_j \nu_j^\star h_j(x) \geq f(x^\star).$$

Если

$$\rho \geq \max\left\{ \max_i \lambda_i^\star, \max_j |\nu_j^\star| \right\},$$

то

$$\rho\,[s_i(x)]_+ \geq \lambda_i^\star s_i(x), \qquad \rho|h_j(x)| \geq \nu_j^\star h_j(x).$$

Следовательно,

$$P_\rho(x) \geq f(x^\star).$$

В допустимой точке $x^\star$ штраф равен нулю, поэтому $P_\rho(x^\star) = f(x^\star)$ и $x^\star$ минимизирует штрафную функцию.

Оговорка

Это не означает, что все штрафные методы автоматически точны: свойство относится к определённым негладким штрафам и требует соответствующих предпосылок.

Другие подходы к условной оптимизации

- **Active-set methods**: пытаются определить активные ограничения.
- **SQP**: решает последовательность квадратичных задач с линеаризованными ограничениями.
- **Расширенный лагранжиан**: сочетает штраф и двойственные переменные.

Фокус этой лекции

Не обзор всей условной оптимизации, а другая фундаментальная ветвь: **барьерные методы и методы внутренней точки**.

От точного индикатора к гладкому барьеру

Для одного неравенства $s(x) \leq 0$ точный индикатор:

$$I_-(s(x)) = \begin{cases} 0, & s(x) \leq 0, \\ +\infty, & s(x) > 0. \end{cases}$$

Исходная задача эквивалентна

$$\min_{Ax=b} f(x) + \sum_{i=1}^{m} I_-(s_i(x)).$$

Но индикатор негладок. Хотим гладкую замену, которая:

1. определена и гладка при $s_i(x) < 0$;
2. стремится к $+\infty$ при $s_i(x) \to 0-$;
3. сохраняет выпуклость;
4. даёт удобные производные и локальные модели.

Логарифмический барьер

Для скалярного ограничения $u < 0$ рассмотрим

$$\beta(u) = -\log(-u).$$

При $u \to 0-$ имеем $\beta(u) \to +\infty$: приближение к границе становится всё более дорогим.

Definition 1 (Логарифмический барьер)

Для ограничений $s_i(x) < 0$

$$\boxed{\phi(x) = -\sum_{i=1}^{m} \log\bigl(-s_i(x)\bigr), \qquad \operatorname{dom}\phi = \{x : s_i(x) < 0 \ \forall i\}.} \tag{6}$$

Барьер конечен только во внутренности допустимой области. Поэтому, в отличие от штрафа, он не разрешает нарушить неравенства и затем “заплатить” за нарушение.

Почему именно логарифм: геометрия у границы

Логарифм не единственно возможный барьер, но сочетает несколько важных свойств.

- **Бесконечная стена:** $-s_i(x) \downarrow 0 \Rightarrow -\log(-s_i(x)) \uparrow +\infty$.
- **Выпуклость:** если s_i выпукла, то $u \mapsto -\log(-u)$ выпукла и неубывает на $u < 0$, поэтому композиция сохраняет выпуклость.
- **Гладкость во внутренности:** можно применять градиентные и ньютоновские методы.

Для линейного ограничения $a_i^\top x \le b_i$ производные растут как

$$\frac{1}{b_i - a_i^\top x}, \qquad \frac{1}{(b_i - a_i^\top x)^2},$$

поэтому барьер становится всё более крутым при приближении к границе. Ещё важнее для этой лекции: производная $-1/s_i(x)$ позже породит естественные множители

$$\lambda_i(t) = -\frac{1}{t s_i(x_t)}$$

и возмущённую дополняющую нежесткость.

Градиент и гессиан барьера

Для одного слагаемого $\phi_i(x) = -\log(-s_i(x))$ по правилу цепочки

$$\nabla \phi_i(x) = -\frac{1}{s_i(x)} \nabla s_i(x).$$

Поэтому

$$\boxed{\nabla \phi(x) = -\sum_{i=1}^{m} \frac{1}{s_i(x)} \nabla s_i(x).} \tag{7}$$

Дифференцируя ещё раз,

$$\boxed{\nabla^2 \phi(x) = \sum_{i=1}^{m} \left[\frac{\nabla s_i(x) \nabla s_i(x)^\top}{s_i(x)^2} - \frac{\nabla^2 s_i(x)}{s_i(x)} \right].} \tag{8}$$

Внутри области $s_i(x) < 0$; если s_i выпукла, то $\nabla^2 s_i(x) \succeq 0$, поэтому оба слагаемых в скобках положительно полуопределены.

Линейное ограничение: где растёт кривизна?

Для $s_i(x) = a_i^\top x - b_i$

$$\boxed{\nabla^2 \phi_i(x) = \frac{a_i a_i^\top}{(b_i - a_i^\top x)^2}.}$$

В произвольном направлении d:

$$d^\top \nabla^2 \phi_i(x) d = \frac{(a_i^\top d)^2}{(b_i - a_i^\top x)^2}.$$

Отсюда геометрия:

- $a_i^\top d = 0$: d параллельно границе; это ограничение не добавляет кривизны в таком направлении;
- $a_i^\top d \neq 0$: движение идёт поперёк границы, и кривизна положительна;
- при $b_i - a_i^\top x \to 0+$ кривизна в направлениях, пересекающих границу, резко возрастает.

По причине сильной неоднородности кривизны скалярный размер шага градиентного метода может быть неудобен и на этапе подбора алгоритма для решения задачи оптимизации естественно обратиться к Ньютону.

Семейство барьерных задач

Фиксируем параметризацию

$$\boxed{\begin{aligned} \min_x \quad & F_t(x) := tf(x) + \phi(x), \\ \text{при условии} \quad & Ax = b, \end{aligned} \qquad t > 0.} \tag{9}$$

Эквивалентная запись: $f(x) + (1/t)\phi(x)$. Умножение цели на положительное t не меняет точку минимума.

- малое t: относительно сильнее барьер;
- большое t: сильнее исходная цель f;
- при любом конечном $F_t(x)$: $s_i(x) < 0$ для всех i.

Запись $tf + \phi$ удобна: позже из неё естественно появится оценка m/t.

Центрирующая задача

Для фиксированного t задача (9) — *центрирующая*; её решение — *центральная точка*.

Не евклидов центр

Название не означает геометрический центр допустимого множества.

Если убрать исходную цель (или формально $t \to 0+$), остаётся

$$\min_{Ax=b} \phi(x) = \min_{Ax=b} \left[-\sum_i \log(-s_i(x)) \right].$$

Её решение — *аналитический центр*: минимум балансирует резко растущие воздействия барьера у границ. При $t > 0$ центральная точка — компромисс:

движение к минимуму f	$\leftrightarrow$	удержание во внутренности барьером.

Чем решать центрирующую задачу?

После введения барьера задача гладкая. Без равенств формально доступны

$$x_{k+1} = x_k - \alpha_k \nabla F_t(x_k),$$

квазиньютоновские методы и метод Ньютона.

Почему Ньютон особенно естествен? Для линейного ограничения

$$\nabla^2 \phi_i(x) = \frac{a_i a_i^\top}{(b_i - a_i^\top x)^2}.$$

При приближении к границе кривизна вдоль a_i может стать огромной, тогда как в других направлениях остаётся умеренной.

- Градиентный метод использует один скалярный масштаб шага для всех направлений.
- Ньютоновский шаг учитывает полный гессиан и масштабирует направления по локальной кривизне.

Это аргумент в пользу Ньютона, но не логическая необходимость: центрирующую задачу можно решать и другими гладкими методами.

Почему Ньютон удобен в path-following

Вторая причина связана уже не с одной барьерной задачей, а с последовательностью

$$(P_{t_k}) \quad \longrightarrow \quad (P_{t_{k+1}}), \qquad t_{k+1} > t_k.$$

Барьерный метод постепенно меняет t и использует решение предыдущей задачи как начальное приближение для следующей.
Если t меняется умеренно и центральная траектория регулярна, соседние центральные точки близки. Поэтому новая ньютоновская итерация часто начинается уже недалеко от решения.

Следствие

Ньютон может быстро попасть в свой локальный режим быстрой сходимости; это одна из причин его естественности в path-following.

Ньютоновский шаг без равенств

Для $F_t(x) = tf(x) + \phi(x)$

$$\nabla F_t(x) = t\nabla f(x) + \nabla\phi(x), \qquad \nabla^2 F_t(x) = t\nabla^2 f(x) + \nabla^2\phi(x).$$

Ньютоновское направление определяется линейной системой

$$\boxed{\nabla^2 F_t(x)\,\Delta x_{\mathrm{nt}} = -\nabla F_t(x).} \tag{10}$$

Алгоритмически нужно решать эту систему, а не вычислять обратную матрицу.
Полный шаг может выйти из строгой внутренности. Поэтому используют

$$x^+ = x + \alpha\Delta x_{\mathrm{nt}}, \qquad 0 < \alpha \le 1,$$

причём α сначала выбирают так, чтобы

$$s_i(x + \alpha\Delta x_{\mathrm{nt}}) < 0 \quad \forall i,$$

а затем требуют достаточного уменьшения F_t, например линейным поиском.

Ньютон при $Ax = b$: локальная квадратичная модель

Пусть текущая точка допустима по равенствам: $Ax = b$, и $x^+ = x + \Delta x$. Метод Ньютона выбирает Δx, минимизируя локальную квадратичную модель. По Тейлору

$$F_t(x + \Delta x) \approx F_t(x) + \nabla F_t(x)^\top \Delta x + \frac{1}{2}\Delta x^\top \nabla^2 F_t(x) \Delta x.$$

Слагаемое $F_t(x)$ от Δx не зависит, поэтому задача для направления:

$$\min_{\Delta x} \left\{ \nabla F_t(x)^\top \Delta x + \frac{1}{2}\Delta x^\top \nabla^2 F_t(x) \Delta x \right\}.$$

Но новая точка тоже должна удовлетворять равенствам:

$$A(x + \Delta x) = b, \qquad Ax = b \quad \Longrightarrow \quad \boxed{A\Delta x = 0.}$$

Итак, ньютоновское направление — решение *условной квадратичной задачи* с ограничением $A\Delta x = 0$.

Ньютон при $Ax = b$: KKT квадратичной модели

Обозначим

$$g = \nabla F_t(x), \qquad H = \nabla^2 F_t(x).$$

Лагранжиан локальной квадратичной задачи:

$$\mathcal{L}_{\text{quad}}(\Delta x, w) = g^\top \Delta x + \frac{1}{2}\Delta x^\top H \Delta x + w^\top A \Delta x.$$

Условия KKT этой задачи дают

$$g + H\Delta x + A^\top w = 0, \qquad A\Delta x = 0.$$

То есть

$$H\Delta x + A^\top w = -g, \qquad A\Delta x = 0.$$

Здесь w — множитель Лагранжа именно для *локальной квадратичной модели*; он возникает из условия $A\Delta x = 0$, а не вводится как готовая формула.

Ньютон при $Ax = b$: блочная система

Два уравнения KKT записываются одной системой

$$\boxed{\begin{bmatrix} \nabla^2 F_t(x) & A^\top \\ A & 0 \end{bmatrix} \begin{bmatrix} \Delta x \\ w \end{bmatrix} = - \begin{bmatrix} \nabla F_t(x) \\ 0 \end{bmatrix}.} \tag{11}$$

Связь тем курса

Здесь буквально соединяются две предыдущие темы: **Ньютон** задаёт локальную квадратичную модель, а **KKT** этой модели дают линейную систему, из которой находится направление Δx.

После решения системы остаётся выбрать длину шага так, чтобы сохранить строгую допустимость по неравенствам и обеспечить уменьшение F_t.

Центральная траектория

Пусть для каждого $t > 0$ центрирующая задача имеет единственное решение $x^\star(t)$; например, это обеспечивается строгой выпуклостью на аффинном множестве $Ax = b$.

Definition 2 (Центральная траектория)

$$\boxed{\mathcal{C} = \{x^\star(t) : t > 0\}, \qquad x^\star(t) \in \operatorname*{arg\,min}_{Ax=b} \big(tf(x) + \phi(x)\big).} \tag{12}$$

t — **тот же параметр барьерной задачи**. Например, $t = 1, 10, 100$ задают три разные задачи и три точки $x^\star(1), x^\star(10), x^\star(100)$.
Название “траектория” отражает зависимость решения от непрерывного параметра. При стандартных невырожденных условиях эта зависимость локально непрерывна и гладка (по теореме о неявной функции для условий оптимальности); без таких условий гладкость не автоматична.

Два вопроса о центральной траектории

Формальная гладкость кривой для нас вторична. Главные вопросы — её связь с исходной задачей:

1. почему $x^\star(t)$ при $t \to \infty$ вообще приближает решение исходной условной задачи;
2. как количественно оценить оставшуюся ошибку при конечном t.

План ответа

Начнём с условия оптимальности барьерной задачи. Из него появятся коэффициенты перед ∇s_i, которые окажутся двойственными множителями; затем через двойственную функцию получим явную оценку ошибки.

То есть центральная траектория будет связана с исходной задачей не геометрической картинкой, а KKT и двойственностью.

Связь с KKT и двойственностью: цель вывода

До сих пор $x_t = x^\star(t)$ — просто решение

$$\min_{Ax=b} \left\{ tf(x) - \sum_{i=1}^{m} \log(-s_i(x)) \right\}.$$

Из определения ещё не видно, почему рост t приближает нас к решению исходной задачи и как измерить ошибку.

Цель следующих шагов

Из условия оптимальности барьерной задачи получить почти все KKT исходной задачи, построить двойственные множители и затем вывести

$$\boxed{0 \le f(x_t) - f^\star \le \frac{m}{t}.}$$

Логика вывода:

$$\boxed{\begin{array}{c}\text{барьерная задача} \Longrightarrow \text{возмущённые KKT} \Longrightarrow \text{двойственные переменные} \\ \Downarrow \\ \text{двойственный разрыв} \Longrightarrow \text{оценка ошибки.}\end{array}}$$

Шаг 1. Условие оптимальности центрирующей задачи

Зафиксируем $t > 0$ и обозначим $x_t = x^\star(t)$. Для задачи

$$\min_x \; tf(x) + \phi(x) \qquad \text{при } Ax = b$$

лагранжиан по равенствам равен

$$\mathcal{L}_t(x, w) = tf(x) + \phi(x) + w^\top (Ax - b).$$

Стационарность в x_t даёт

$$t\nabla f(x_t) + \nabla\phi(x_t) + A^\top w_t = 0. \tag{13}$$

Подставляем формулу (7):

$$t\nabla f(x_t) - \sum_{i=1}^{m} \frac{1}{s_i(x_t)} \nabla s_i(x_t) + A^\top w_t = 0.$$

Делим на t:

$$\nabla f(x_t) + \sum_{i=1}^{m} \left(-\frac{1}{t s_i(x_t)} \right) \nabla s_i(x_t) + A^\top \frac{w_t}{t} = 0. \tag{14}$$

Шаг 2. В формуле сами появляются двойственные переменные

После деления условия стационарности на t получили ключевую формулу

$$\nabla f(x_t) + \sum_{i=1}^{m} \left(-\frac{1}{t s_i(x_t)} \right) \nabla s_i(x_t) + A^\top \frac{w_t}{t} = 0.$$

Сравним её со стационарностью KKT исходной задачи:

$$\nabla f(x^\star) + \sum_i \lambda_i^\star \nabla s_i(x^\star) + A^\top \nu^\star = 0.$$

Сравнение подсказывает определения

$$\boxed{\lambda_i(t) := -\frac{1}{t s_i(x_t)}, \qquad \nu(t) := \frac{w_t}{t}.} \tag{15}$$

Поскольку $s_i(x_t) < 0$, автоматически $\lambda_i(t) > 0$: двойственная допустимость по знаку уже выполнена.
После этого исходная формула становится

$$\boxed{\nabla f(x_t) + \sum_i \lambda_i(t) \nabla s_i(x_t) + A^\top \nu(t) = 0,} \tag{16}$$

то есть *точно* стационарностью KKT исходной задачи в точке x_t с построенными множителями.

Шаг 3. Что из KKT уже выполнено?

Для исходной выпуклой задачи KKT требуют стационарность, прямую и двойственную допустимость и дополняющую нежесткость.
Для тройки $(x_t, \lambda(t), \nu(t))$ уже имеем:

- **стационарность** — точно по (16);
- **прямая допустимость** — $Ax_t = b$, $s_i(x_t) < 0$;
- **двойственная допустимость** — $\lambda_i(t) > 0$.

Остаётся проверить дополняющую нежесткость. Из определения $\lambda_i(t)$ немедленно следует

$$\boxed{\lambda_i(t)s_i(x_t) = -\frac{1}{t}, \qquad \lambda_i(t)(-s_i(x_t)) = \frac{1}{t}.} \tag{17}$$

В обычных KKT справа стоит 0; здесь — $1/t$.

Шаг 3. Центральная траектория как возмущённые KKT

Утверждение 3 (Возмущённые KKT)

Для каждого $t > 0$ тройка $(x_t, \lambda(t), \nu(t))$ удовлетворяет

$$\boxed{\begin{cases} \nabla f(x) + \sum_i \lambda_i \nabla s_i(x) + A^\top \nu = 0, \\ Ax = b, \\ s_i(x) < 0, \quad \lambda_i > 0, \\ -\lambda_i s_i(x) = 1/t, \qquad i = 1, \dots, m. \end{cases}} \tag{18}$$

От обычной системы KKT отличается только

$$-\lambda_i s_i(x) = 0 \quad \rightsquigarrow \quad -\lambda_i s_i(x) = \frac{1}{t}.$$

При $t \to \infty$ возмущение исчезает. Именно в этом точный смысл фразы “центральная траектория описывается возмущёнными KKT”.

Но этого ещё недостаточно

Формального приближения KKT мало: нужна количественная связь с оптимальным значением. Для неё переходим к двойственной задаче.

Шаг 4. Двойственная задача: от центральной точки к лагранжиану

Напомним лагранжиан исходной задачи:

$$L(x, \lambda, \nu) = f(x) + \sum_{i=1}^{m} \lambda_i s_i(x) + \nu^\top (Ax - b), \qquad \lambda \geq 0. \tag{19}$$

Двойственная функция

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$$

даёт нижнюю оценку $g(\lambda, \nu) \leq f^\star$ для любой $\lambda \geq 0$.
Мы уже построили из центральной точки множители $\lambda(t), \nu(t)$.
Полученная ранее стационарность означает

$$\nabla_x L(x_t, \lambda(t), \nu(t)) = 0.$$

Для фиксированных $\lambda(t), \nu(t)$ функция $x \mapsto L(x, \lambda(t), \nu(t))$ выпукла: f, s_i выпуклы, $\lambda_i(t) \geq 0$, а член с равенствами аффинен.

Шаг 4. Двойственная задача: вычисляем g в центральной точке

Для дифференцируемой выпуклой функции нулевой градиент достаточен для глобального минимума. Поэтому

$$\boxed{x_t \in \arg\min_x L(x, \lambda(t), \nu(t)).}$$

По определению

$$g(\lambda, \nu) = \inf_x L(x, \lambda, \nu),$$

а для построенной пары этот инфимум достигается в x_t:

$$\boxed{g(\lambda(t), \nu(t)) = L(x_t, \lambda(t), \nu(t)).} \tag{20}$$

Где именно появляется двойственность?

Центральная точка порождает двойственно допустимые множители; стационарность вместе с выпуклостью показывает, что в x_t достигается инфимум, определяющий двойственную функцию.

Шаг 5. Вывод двойственного разрыва m/t

Подставим x_t в лагранжиан. Поскольку $Ax_t = b$,

$$\nu(t)^\top (Ax_t - b) = 0,$$

поэтому

$$\begin{aligned} g(\lambda(t), \nu(t)) &= L(x_t, \lambda(t), \nu(t)) \\ &= f(x_t) + \sum_{i=1}^{m} \lambda_i(t) s_i(x_t). \end{aligned}$$

По возмущённой дополняющей нежесткости

$$\lambda_i(t) s_i(x_t) = -\frac{1}{t} \quad \Longrightarrow \quad \sum_{i=1}^{m} \lambda_i(t) s_i(x_t) = -\frac{m}{t}.$$

Следовательно,

$$\boxed{g(\lambda(t), \nu(t)) = f(x_t) - \frac{m}{t}.} \tag{21}$$

$$\boxed{f(x_t) - g(\lambda(t), \nu(t)) = \frac{m}{t}.} \tag{22}$$

Это **точная** формула для точной центральной точки, а не только оценка $O(1/t)$.

Шаг 6. Из двойственного разрыва — к ошибке по целевой функции

Слабая двойственность и допустимость x_t дают

$$g(\lambda(t), \nu(t)) \le f^\star \le f(x_t).$$

Следовательно,

$$0 \le f(x_t) - f^\star \le f(x_t) - g(\lambda(t), \nu(t)).$$

Подставляем точный разрыв из шага 5:

Theorem 4 (Оценка точности центральной точки)

Для $x_t = x^\star(t)$

$$\boxed{0 \le f(x_t) - f^\star \le \frac{m}{t}.} \tag{23}$$

Отсюда внешний критерий остановки: для точности ε достаточно

$$\boxed{\frac{m}{t} \le \varepsilon.} \tag{24}$$

Как читать возмущённую дополняющую нежесткость?

$$\boxed{\lambda_i(t)(-s_i(x_t)) = \frac{1}{t}.}$$

При большом t произведение мало, и это связывает геометрию прямой задачи с двойственными переменными.

Ограничение остаётся неактивным

Если $-s_i(x_t)$ отделено от нуля, то

$$\lambda_i(t) \to 0.$$

Множитель остаётся существенным

Если $\lambda_i(t)$ не мал, то

$$-s_i(x_t) \to 0,$$

то есть точка идёт к соответствующей границе.

В пределе это согласуется с обычной дополняющей нежесткостью: активное ограничение может иметь положительный множитель, а строго неактивное должно иметь нулевой.

Path-following: общая идея

Definition 5 (Path-following)

Рассматриваем параметризованное семейство задач, решения которого образуют траекторию; параметр меняем постепенно, а решение предыдущей задачи используем как начальное приближение для следующей.

Это частный случай *continuation / homotopy*: вместо решения конечной сложной задачи с нуля постепенно деформируем более простую задачу и отслеживаем движение её решения.
В нашем случае семейство уже построено:

$$(P_t): \quad \min_{Ax=b} \; tf(x) + \phi(x), \qquad \text{траектория решений } x^\star(t).$$

Следовательно, path-following IPM означает: **увеличивать t и численно следовать за $x^\star(t)$ через внутренность допустимой области**. Предыдущее решение используется как тёплый старт для следующего центрирования.

Почему не взять сразу огромное t?

Оценка m/t провоцирует выбрать $t \gg m/\varepsilon$ и решить одну задачу. Но:

- центральная точка при большом t может быть близко к границе;
- барьерная геометрия становится резко анизотропной;
- произвольная стартовая точка может быть далеко от $x^\star(t)$.

Вместо этого:

$$\boxed{t_{k+1} = \mu t_k, \qquad \mu > 1.}$$

Решение при t_k служит начальным приближением при t_{k+1}.

Тёплый старт (warm start)

При умеренном изменении t соседние центральные точки близки, поэтому Ньютон стартует в благоприятной области.

Барьерный path-following метод

Пусть задана строго допустимая точка $x^{(0)}$, начальное $t_0 > 0$, множитель $\mu > 1$ и требуемая точность ε.

1. Для текущего t приблизительно решить

$$\min_{Ax=b} \; tf(x) + \phi(x)$$

   методом Ньютона, начиная с текущей строго допустимой точки.
2. Если $m/t \leq \varepsilon$ и центрирование достаточно точное — остановиться.
3. Увеличить параметр: $t \leftarrow \mu t$.
4. Использовать найденную точку как начальное приближение для следующей барьерной задачи и вернуться к шагу 1.

Почему это именно следование по траектории?

На каждом внешнем шаге меняется параметр t, а внутренний метод Ньютона возвращает нас к соответствующей центральной точке $x^\star(t)$.

Два уровня точности в барьерном методе

Важно различать два разных вопроса.

Внутренний уровень

Насколько хорошо решена *текущая центрирующая задача*? Это контролируется ньютоновским декрементом или нормой соответствующей невязки.

Внешний уровень

Насколько центральная точка близка к решению *исходной задачи*?

$$\frac{m}{t} \leq \varepsilon.$$

Оценка m/t выведена для точной центральной точки; в практическом алгоритме к ней добавляется ошибка неполного центрирования. Параметр μ задаёт компромисс: большое μ уменьшает число внешних этапов, но следующая центральная точка дальше; μ близкое к 1 облегчает повторное центрирование, но увеличивает число внешних этапов.

Phase I: найти внутреннюю стартовую точку

Чистый логарифмический барьер требует стартовать из точки

$$Ax = b, \qquad s_i(x) < 0.$$

Такую точку мы можем заранее не знать. Поэтому решению исходной задачи часто предшествует *Phase I* — вспомогательная задача поиска строго допустимой точки.
Одна базовая конструкция:

$$\begin{aligned} & \min_{x,r} && r, \\ \text{при условиях} \quad & && s_i(x) \le r, \qquad i = 1, \dots, m, \\ & && Ax = b. \end{aligned}$$

Если найдено $r < 0$, то $s_i(x) \le r < 0$ для всех i, следовательно, x строго допустима для исходных неравенств.

Смысл Phase I

Поиск внутренней стартовой точки — отдельный подготовительный этап, а не бесплатное предположение барьерного метода.

Полная организация Phase I требует дополнительных технических деталей; здесь важен сам принцип.

От барьерного к прямодвойственному методу

В чистой барьерной схеме мы действовали так:

$$t \longrightarrow \text{решить центрирующую задачу} \longrightarrow x^\star(t) \longrightarrow \lambda(t), \nu(t).$$

Но раздел о KKT показал: центральная траектория уже эквивалентно описывается системой *возмущённых условий оптимальности*.

Следующая идея

Перестать считать двойственные переменные величинами, которые восстанавливаются только *после* решения прямой барьерной задачи, и обновлять прямые и двойственные переменные совместно.

Это и есть концептуальный переход от чистого барьерного метода к primal–dual interior-point method.

Дополнительные переменные

Для каждого неравенства $s_i(x) \le 0$ введём *дополнительную переменную* (slack variable)

$$\boxed{z_i = -s_i(x) \ge 0.}$$

Она превращает неравенство в равенство с условием неотрицательности:

$$s_i(x) + z_i = 0, \qquad z_i \ge 0.$$

Геометрический смысл:

- на границе $s_i(x) = 0 \iff z_i = 0$;
- во внутренней точке $s_i(x) < 0 \iff z_i > 0$.

В прямодвойственном методе поддерживается $z_i > 0$. Возмущённая дополняющая нежесткость становится симметричной:

$$\boxed{\lambda_i z_i = \frac{1}{t}.}$$

Возмущённая прямодвойственная система ККТ

Пусть $z = (z_1, \ldots, z_m)$, $\Lambda = \operatorname{diag}(\lambda)$. Тогда

$$\boxed{\begin{cases} \nabla f(x) + \sum_i \lambda_i \nabla s_i(x) + A^\top \nu = 0, \\ Ax - b = 0, \\ s(x) + z = 0, \\ \Lambda z - \dfrac{1}{t} 1 = 0, \\ \lambda > 0, \quad z > 0. \end{cases}} \tag{25}$$

Естественные невязки:

$$r_{\text{dual}} = \nabla f(x) + \sum_i \lambda_i \nabla s_i(x) + A^\top \nu,$$

$$r_{\text{pri,eq}} = Ax - b, \qquad r_{\text{pri,ineq}} = s(x) + z,$$

$$r_{\text{cent}} = \Lambda z - \frac{1}{t} 1.$$

Идея прямодвойственного метода

Вместо точного решения каждой барьерной подзадачи применяем ньютоновскую идею **непосредственно к возмущённой системе KKT**: линеаризуем её невязки и одновременно вычисляем

$$(\Delta x, \Delta\lambda, \Delta\nu, \Delta z).$$

Шаг выбирается так, чтобы

- сохранять $\lambda > 0$ и $z > 0$;
- уменьшать прямые, двойственные и центрирующие невязки.

Суть primal–dual IPM

Алгоритм одновременно ведёт прямые переменные x и двойственные (λ, ν) к выполнению KKT, оставаясь во внутренности по неравенствам и положительности множителей.

Полная блочная система Ньютона, стратегии центрирования и predictor–corrector варианты выходят за рамки лекции. Для нас важно происхождение метода: это прямое развитие возмущённых KKT, уже описывающих центральную траекторию.

Стоимость шага метода внутренней точки

Основная вычислительная цена ньютоновского шага — решение линейной/KKT-системы.

- Для плотной матрицы порядка n: типично $O(n^3)$ операций и $O(n^2)$ памяти.
- В условной задаче размер системы зависит также от числа ограничений.
- На практике решающими становятся **разреженность и структура** матриц.

Поэтому

Фраза “итерация interior-point метода стоит $O(n^3)$” слишком груба для общей условной задачи.

Барьерные и primal–dual методы особенно привлекательны при высокой требуемой точности и подходящей выпуклой структуре, если структурированные линейные системы решаются приемлемо. Методы первого порядка могут выигрывать в очень больших задачах при дешёвых проекциях/проксимальных операциях и умеренной требуемой точности.

Карта подходов к ограничениям

подход	основная идея
проекция	шаг, затем возврат в допустимое множество
квадратичный штраф	разрешить нарушение и всё сильнее его штрафовать
точный негладкий штраф	конечный штраф ценой негладкости
барьер	оставаться строго внутри и приближаться к границе изнутри
augmented Lagrangian	штраф + явное обновление множителей
active set	определять активные ограничения
SQP	решать последовательность условных квадратичных моделей
primal–dual IPM	ньютоновски решать возмущённую систему KKT

Сквозная геометрическая картина

Для

$$\min_x \frac{1}{2}\|x-c\|^2, \qquad a_i^\top x - b_i \le 0,$$

барьер и его гессиан:

$$\phi(x) = -\sum_i \log(b_i - a_i^\top x), \qquad \nabla^2\phi(x) = \sum_i \frac{a_i a_i^\top}{(b_i - a_i^\top x)^2}.$$

- малое t: центральная точка глубже внутри;
- рост t: x_t движется по центральной траектории к решению;
- одновременно
$$\lambda_i(t) = \frac{1}{t(b_i - a_i^\top x_t)};$$
- $(x_t, \lambda(t), \nu(t))$ удовлетворяет возмущённым KKT;
- прямодвойственный разрыв равен m/t.

Итоги: от ограничений к центральной траектории

- **Проекция** возвращает шаг в допустимое множество; **штраф** разрешает нарушение, но делает его дорогим; **барьер** заставляет двигаться только изнутри.
- Точные негладкие штрафы могут работать с конечным параметром, но ценой негладкости.
- Логарифмический барьер стремится к $+\infty$ на границе, сохраняет выпуклость и создаёт геометрию, хорошо согласованную с методом Ньютона.
- Для каждого t решение

$$\min_{Ax=b} \; tf(x) + \phi(x)$$

задаёт центральную точку $x_t = x^\star(t)$; совокупность этих точек — центральная траектория.

Итоги: KKT, двойственность и алгоритм

Центральной точке соответствуют

$$\lambda_i(t) = -\frac{1}{t s_i(x_t)}, \qquad \nu(t),$$

и тройка $(x_t, \lambda(t), \nu(t))$ удовлетворяет стационарности, прямой и двойственной допустимости, а вместо точной дополняющей нежесткости имеет

$$-\lambda_i(t) s_i(x_t) = \frac{1}{t}.$$

Отсюда

$$\boxed{f(x_t) - g(\lambda(t), \nu(t)) = \frac{m}{t}}, \qquad \boxed{f(x_t) - f^\star \le \frac{m}{t}}.$$

- **Path-following**: постепенно увеличивать t и использовать предыдущее решение как начальное приближение для следующей центрирующей задачи.
- **Primal–dual IPM**: применять ньютоновскую идею непосредственно к возмущённой системе KKT и совместно обновлять прямые и двойственные переменные.