Дополнительные главы оптимизации

Лекция 6. Ускоренные и стохастические градиентные методы

План лекции

1. Квадратичная задача и спектральная динамика градиентного спуска
2. Метод тяжёлого шарика Поляка
3. Быстрый градиентный метод Нестерова
4. Ускоренный проксимальный градиентный метод
5. Стохастическая градиентная информация и метод SGD
6. Шум и сходимость SGD
7. Мини-батчевый SGD
8. Организация вычислений в задачах конечных сумм
9. Сочетание стохастического градиента и momentum

Две вычислительные проблемы градиентного спуска

Для задачи

$$\min_{x \in \mathbb{R}^n} f(x)$$

напомним две базовые оценки.

- Если f выпукла и L-гладка, то при шаге $1/L$

$$f(x_k) - f^\star = O\left(\frac{L\|x_0 - x^\star\|^2}{k}\right).$$

- Если f дополнительно μ-сильно выпукла,

$$k = O\left(\kappa \log \frac{1}{\varepsilon}\right), \qquad \kappa = \frac{L}{\mu}.$$

Две линии этой лекции

1. **Ускорение:** уменьшить число точных шагов первого порядка.
2. **Стохастический подход:** уменьшить стоимость получения градиентной информации на одном шаге.

Эти идеи решают разные вычислительные проблемы и могут сочетаться.

Квадратичная задача как точная модель динамики

Рассмотрим

$$\boxed{f(x) = \frac{1}{2} x^\top A x - b^\top x, \qquad A = A^\top \succ 0.}$$

Здесь $A \in \mathbb{R}^{n \times n}$, $b \in \mathbb{R}^n$.

- $A \succ 0$ означает $x^\top A x > 0$ для всех $x \neq 0$.
- $$\nabla f(x) = Ax - b, \qquad \nabla^2 f(x) = A.$$
- Функция сильно выпукла, поэтому точка минимума единственна:

$$Ax^\star = b, \qquad x^\star = A^{-1} b.$$

Почему этот класс полезен?

На квадратичной задаче динамика методов первого порядка линейна и разбирается точно; собственные значения A непосредственно описывают кривизну по различным направлениям.

Градиентный спуск: рекурсия ошибки

Градиентный шаг с постоянным $\alpha > 0$:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) = x_k - \alpha(Ax_k - b).$$

Определим ошибку относительно точки минимума

$$e_k := x_k - x^\star.$$

Так как $Ax^\star = b$,

$$\begin{aligned} e_{k+1} &= x_{k+1} - x^\star \\ &= e_k - \alpha A(x_k - x^\star). \end{aligned}$$

Следовательно,

$$\boxed{e_{k+1} = (I - \alpha A)e_k.}$$

Здесь I — единичная матрица.

Следующий шаг анализа

Скорость определяется действием матрицы $I - \alpha A$. Для симметричной A это действие удобно разложить по собственным направлениям.

Спектральное разложение и собственные координаты

По спектральной теореме

$$A = Q\Lambda Q^\top, \qquad Q^\top Q = I, \qquad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n).$$

Поскольку $A \succ 0$, все $\lambda_i > 0$. Введём

$$\mu := \lambda_{\min}(A), \qquad L := \lambda_{\max}(A).$$

Тогда

$$\mu I \preceq A \preceq LI,$$

то есть квадратичная функция μ-сильно выпукла и L-гладка.
Перейдём к координатам ошибки в собственном базисе:

$$z_k := Q^\top e_k.$$

Тогда

$$z_{k+1} = (I - \alpha\Lambda) z_k,$$

и покоординатно

$$\boxed{z_{k+1}^{(i)} = (1 - \alpha\lambda_i) z_k^{(i)}.}$$

Почему плохая обусловленность замедляет GD

Один и тот же шаг α должен работать для всех

$$\lambda_i \in [\mu, L].$$

- Направления с $\lambda_i \approx L$ ограничивают допустимый размер шага.
- В направлениях с $\lambda_i \approx \mu$ множитель

$$1 - \alpha\lambda_i$$

может оставаться близким к 1, поэтому ошибка затухает медленно.

Число обусловленности

$$\boxed{\kappa = \frac{L}{\mu}}$$

характеризует различие этих масштабов.

Геометрическая картина

При $\kappa \gg 1$ линии уровня сильно вытянуты: GD быстро подавляет ошибку поперёк узкого направления и медленно продвигается вдоль длинной оси.

Обычный GD использует только текущий градиент. Возникает идея добавить память о предыдущем движении.

Метод тяжёлого шарика: инерционный член

Определим предыдущее перемещение

$$v_k := x_k - x_{k-1}, \qquad x_{-1} = x_0 \;\Rightarrow\; v_0 = 0.$$

Вместо полного забывания предыдущего шага сохраняем его часть:

$$\boxed{v_{k+1} = \beta v_k - \alpha \nabla f(x_k),}$$

где $\alpha > 0$ — шаг, $\beta \geq 0$ — параметр инерции.
Поскольку $x_{k+1} = x_k + v_{k+1}$,

$$\boxed{x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).}$$

При $\beta = 0$ получаем обычный GD.

Интуиция

$-\nabla f(x_k)$ задаёт новое направление, а βv_k сохраняет часть накопленного движения. Это может усиливать устойчивое направление и сглаживать поперечные колебания.

Слишком большой β способен вызвать колебания или неустойчивость, поэтому параметры нужно анализировать.

Стоимость и память heavy ball

На одной итерации heavy ball требует:

- одного вычисления $\nabla f(x_k)$ — столько же, сколько GD;
- нескольких векторных операций порядка $O(n)$;
- хранения текущей и предыдущей точек либо текущей точки и скорости v_k.

Практический смысл

Если вычисление градиента доминирует по стоимости, одна итерация heavy ball имеет тот же порядок стоимости, что и итерация GD. Потенциальный выигрыш должен прийти от меньшего числа итераций.

Heavy ball на квадратичной задаче

Для ошибки $e_k = x_k - x^\star$:

$$e_{k+1} = ((1+\beta)I - \alpha A)e_k - \beta e_{k-1}.$$

В собственных координатах $z_k = Q^\top e_k$:

$$\boxed{z_{k+1}^{(i)} = (1 - \alpha\lambda_i + \beta)z_k^{(i)} - \beta z_{k-1}^{(i)}.}$$

Для фиксированного собственного значения λ получаем скалярную рекурсию

$$z_{k+1} = (1 - \alpha\lambda + \beta)z_k - \beta z_{k-1}.$$

Ищем элементарное решение $z_k = r^k$. Тогда

$$\boxed{r^2 - (1 - \alpha\lambda + \beta)r + \beta = 0.}$$

Модули корней задают скорость затухания; комплексно-сопряжённые корни соответствуют затухающим колебаниям.

Оптимальная настройка heavy ball: постановка

Обозначим через $\rho_\lambda(\alpha, \beta)$ максимальный модуль двух корней характеристического многочлена. Хотим минимизировать худший коэффициент затухания по всему спектру:

$$\boxed{\min_{\alpha,\beta} \max_{\lambda \in [\mu, L]} \rho_\lambda(\alpha, \beta).}$$

Введём желаемый общий модуль корней $q \in (0, 1)$ и положим

$$\beta = q^2.$$

Если дискриминант неположителен, корни комплексно-сопряжённые или совпадают, а по теореме Виета их модуль равен q.
Для

$$a(\lambda) := 1 - \alpha\lambda + q^2$$

требование $\rho_\lambda \leq q$ эквивалентно

$$a(\lambda)^2 - 4q^2 \leq 0.$$

Оптимальная настройка heavy ball: спектральная полоса

Из

$$(1 - \alpha\lambda + q^2)^2 \le 4q^2$$

получаем

$$-2q \le 1 - \alpha\lambda + q^2 \le 2q,$$

то есть

$$\boxed{(1-q)^2 \le \alpha\lambda \le (1+q)^2.}$$

Чтобы это выполнялось для всех $\lambda \in [\mu, L]$, необходимо и достаточно

$$(1-q)^2 \le \alpha\mu, \qquad \alpha L \le (1+q)^2.$$

Следовательно, допустимый α существует тогда и только тогда, когда

$$\frac{(1-q)^2}{\mu} \le \frac{(1+q)^2}{L}.$$

После извлечения корня:

$$\sqrt{L}(1-q) \le \sqrt{\mu}(1+q).$$

Оптимальные параметры heavy ball

Из предыдущего неравенства

$$q \geq \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.$$

Минимум достигается при равенстве:

$$\boxed{q^\star = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.}$$

Тогда обе границы для α совпадают:

$$\boxed{\alpha^\star = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2},}$$

а

$$\boxed{\beta^\star = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}\right)^2.}$$

При большой κ:

$$q^\star = 1 - \Theta(1/\sqrt{\kappa}),$$

тогда как для оптимально настроенного GD характерен масштаб $1 - \Theta(1/\kappa)$.

Что доказал квадратичный анализ — и чего не доказал

Доказано

Для сильно выпуклой квадратичной задачи со спектром A в $[\mu, L]$ heavy ball допускает точную настройку с характерной зависимостью от $\sqrt{\kappa}$.

Ограничение

Этот вывод не даёт автоматически такой же глобальной гарантии на всём классе произвольных L-гладких μ-сильно выпуклых функций.

Для общего гладкого выпуклого класса GD даёт

$$f(x_k) - f^\star = O(1/k).$$

Гарантированным ускорением будем называть улучшение до

$$\boxed{f(x_k) - f^\star = O(1/k^2).}$$

В сильно выпуклом случае цель — заменить

$$O\left(\kappa \log \frac{1}{\varepsilon}\right) \quad \text{на} \quad O\left(\sqrt{\kappa} \log \frac{1}{\varepsilon}\right).$$

Heavy ball и Нестеров: принципиальное различие

Heavy ball:

$$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1}).$$

Градиент вычисляется в текущей точке x_k, после чего добавляется инерционный член.
В методе Нестерова порядок действий другой. Сначала строится экстраполированная точка

$$\boxed{y_k = x_{k-1} + \beta_{k-1}(x_{k-1} - x_{k-2}),}$$

а затем градиент вычисляется уже в ней:

$$\boxed{x_k = y_k - \frac{1}{L}\nabla f(y_k).}$$

Ключевое отличие

У Нестерова новая градиентная информация оценивает функцию в предсказанной точке y_k. Именно эта схема допускает общую гарантию $O(1/k^2)$.

Параметры Нестерова: последовательность t_k

Для общего выпуклого случая вводим

$$\boxed{t_1 = 1, \qquad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}.}$$

Это положительный корень уравнения

$$\boxed{t_{k+1}^2 - t_{k+1} = t_k^2.}$$

Именно это тождество позже обеспечит сокращение коэффициентов в доказательстве скорости.
Коэффициент экстраполяции:

$$\boxed{\beta_k = \frac{t_k - 1}{t_{k+1}}.}$$

Важно

Параметры не подбираются эмпирически: выбранная рекурсия согласована с доказательной конструкцией и обеспечивает телескопическую потенциальную оценку.

Быстрый градиентный метод: полная схема

Пусть $x_0 \in \mathbb{R}^n$, $y_1 = x_0$, $t_1 = 1$. Для $k = 1, 2, \ldots$:

$$\boxed{\begin{aligned} x_k &= y_k - \frac{1}{L}\nabla f(y_k), \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\ y_{k+1} &= x_k + \frac{t_k - 1}{t_{k+1}}(x_k - x_{k-1}). \end{aligned}}$$

При $k = 1$ коэффициент $t_1 - 1 = 0$, поэтому отдельное x_{-1} не требуется.

Стоимость одной итерации

Один градиент $\nabla f(y_k)$, несколько векторных операций $O(n)$ и хранение нескольких векторов. По числу градиентных вычислений шаг сопоставим с GD; выигрыш — в числе итераций.

Лемма: неравенство градиентного шага

Lemma 1 (Неравенство градиентного шага)

Пусть f выпукла и L-гладка. Для произвольных $y, u \in \mathbb{R}^n$ положим

$$x^+ = y - \frac{1}{L}\nabla f(y).$$

Тогда

$$\boxed{f(x^+) \leq f(u) + \frac{L}{2}\left(\|u - y\|^2 - \left\|u - x^+\right\|^2\right).}$$

Лемма объединяет в одной формуле два свойства:

- гладкость контролирует результат градиентного шага;
- выпуклость позволяет сравнить $f(y)$ с произвольной опорной точкой u.

Доказательство леммы: гладкость и выпуклость

По L-гладкости

$$f(x^+) \leq f(y) + \langle \nabla f(y), x^+ - y \rangle + \frac{L}{2} \|x^+ - y\|^2 .$$

Так как $x^+ - y = -\nabla f(y)/L$,

$$f(x^+) \leq f(y) - \frac{1}{2L} \|\nabla f(y)\|^2 .$$

По выпуклости

$$f(u) \geq f(y) + \langle \nabla f(y), u - y \rangle ,$$

то есть

$$f(y) \leq f(u) - \langle \nabla f(y), u - y \rangle .$$

Следовательно,

$$f(x^+) \leq f(u) - \langle \nabla f(y), u - y \rangle - \frac{1}{2L} \|\nabla f(y)\|^2 .$$

Доказательство леммы: разность квадратов

Поскольку

$$x^+ = y - \frac{1}{L}\nabla f(y),$$

имеем

$$\begin{aligned}\|u-y\|^2 - \left\|u-x^+\right\|^2 &= \|u-y\|^2 - \left\|u-y+\tfrac{1}{L}\nabla f(y)\right\|^2 \\ &= -\frac{2}{L}\langle \nabla f(y), u-y\rangle - \frac{1}{L^2}\|\nabla f(y)\|^2.\end{aligned}$$

После умножения на $L/2$:

$$\frac{L}{2}\left(\|u-y\|^2 - \left\|u-x^+\right\|^2\right) = -\langle \nabla f(y), u-y\rangle - \frac{1}{2L}\|\nabla f(y)\|^2.$$

Подстановка в предыдущую оценку даёт утверждение леммы. □

Теорема о скорости метода Нестерова

Theorem 2 (Скорость быстрого градиентного метода)

Пусть $f : \mathbb{R}^n \to \mathbb{R}$ выпукла, дифференцируема, ∇f является L-липшицевым, и существует $x^\star \in \arg\min f$. Пусть x_k, y_k, t_k строятся по ускоренной схеме. Тогда для всех $k \geq 1$

$$\boxed{f(x_k) - f^\star \leq \frac{2L\|x_0 - x^\star\|^2}{(k+1)^2}.}$$

В частности,

$$k = O\left(\sqrt{\frac{L\|x_0 - x^\star\|^2}{\varepsilon}}\right)$$

итераций достаточно для $f(x_k) - f^\star \leq \varepsilon$.

Доказательство теоремы: вспомогательные величины

Обозначим

$$\delta_k := f(x_k) - f^\star \geq 0$$

и введём

$$\boxed{u_k := t_k x_k - (t_k - 1)x_{k-1} - x^\star.}$$

Экстраполяция устроена так, что для $k \geq 2$

$$\begin{aligned} t_k y_k - (t_k - 1)x_{k-1} - x^\star &= t_{k-1}x_{k-1} - (t_{k-1} - 1)x_{k-2} - x^\star \\ &= u_{k-1}. \end{aligned}$$

Теперь определим

$$w_k := \left(1 - \frac{1}{t_k}\right) x_{k-1} + \frac{1}{t_k} x^\star.$$

По выпуклости

$$f(w_k) - f^\star \leq \left(1 - \frac{1}{t_k}\right) \delta_{k-1}.$$

Доказательство: одношаговая потенциальная оценка

Применим лемму к шагу

$$x_k = y_k - \frac{1}{L}\nabla f(y_k)$$

с $u = w_k$:

$$\delta_k \le f(w_k) - f^\star + \frac{L}{2}\Big(\|w_k - y_k\|^2 - \|w_k - x_k\|^2\Big).$$

Умножаем на $2t_k^2/L$:

$$\begin{aligned}\frac{2}{L}t_k^2\delta_k \le \frac{2}{L}t_k(t_k-1)\delta_{k-1} \\ + t_k^2\|w_k - y_k\|^2 - t_k^2\|w_k - x_k\|^2.\end{aligned}$$

Используем

$$t_k(t_k-1) = t_{k-1}^2, \qquad t_k(w_k - y_k) = -u_{k-1}, \qquad t_k(w_k - x_k) = -u_k.$$

Получаем

$$\boxed{\frac{2}{L}t_k^2\delta_k + \|u_k\|^2 \le \frac{2}{L}t_{k-1}^2\delta_{k-1} + \|u_{k-1}\|^2.}$$

Доказательство: телескопирование

Для первого шага $t_1 = 1$, $y_1 = x_0$, $u_1 = x_1 - x^\star$. Лемма с $u = x^\star$ даёт

$$\frac{2}{L}\delta_1 + \|x_1 - x^\star\|^2 \le \|x_0 - x^\star\|^2 .$$

Итеративно применяя одношаговую оценку,

$$\frac{2}{L}t_k^2\delta_k + \|u_k\|^2 \le \|x_0 - x^\star\|^2 .$$

Отбрасываем неотрицательный член $\|u_k\|^2$:

$$\boxed{\delta_k \le \frac{L\|x_0 - x^\star\|^2}{2t_k^2}.}$$

Потенциальная функция

$$\Phi_k := \frac{2}{L}t_k^2(f(x_k) - f^\star) + \|u_k\|^2$$

не возрастает. Рекурсия для t_k выбрана именно так, чтобы получить это телескопирование.

Доказательство: рост t_k и итоговая скорость

Докажем по индукции

$$t_k \geq \frac{k+1}{2}.$$

Для $k = 1$ — равенство. Если утверждение верно для k, то

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2} \geq \frac{1 + 2t_k}{2} \geq \frac{k+2}{2}.$$

Следовательно,

$$\begin{aligned} f(x_k) - f^\star &\leq \frac{L \|x_0 - x^\star\|^2}{2t_k^2} \\ &\leq \frac{L \|x_0 - x^\star\|^2}{2((k+1)/2)^2} \\ &= \boxed{\frac{2L \|x_0 - x^\star\|^2}{(k+1)^2}}. \end{aligned}$$

□

Нестеров в сильно выпуклом случае

Если f дополнительно μ-сильно выпукла, параметры можно выбрать постоянными. При шаге $1/L$:

$$y_k = x_k + \beta(x_k - x_{k-1}), \qquad x_{k+1} = y_k - \frac{1}{L}\nabla f(y_k),$$

где

$$\boxed{\beta = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}.}$$

Для соответствующей потенциальной оценки

$$f(x_k) - f^\star \leq C\left(1 - \sqrt{\frac{\mu}{L}}\right)^k.$$

Следовательно,

$$\boxed{k = O\left(\sqrt{\kappa}\log\frac{1}{\varepsilon}\right).}$$

Сравнение:

$$\text{GD: } O(\kappa\log(1/\varepsilon)) \quad \to \quad \text{NAG: } O(\sqrt{\kappa}\log(1/\varepsilon)).$$

Зачем снова нужен проксимальный метод?

До сих пор ускоренные схемы предполагали гладкую целевую функцию. Во многих задачах

$$\boxed{\min_x F(x) := f(x) + g(x),}$$

где

- f — выпуклая, дифференцируемая, L-гладкая;
- g — собственная замкнутая выпуклая, возможно негладкая функция;
- проксимальный оператор g вычисляется удобно.

Примеры:

$$g(x) = \lambda \|x\|_1, \qquad g = \delta_C \text{ — индикатор допустимого множества.}$$

В этом случае ∇F может не существовать, поэтому обычные гладкие схемы Нестерова и heavy ball к полной функции F напрямую неприменимы.

Идея

Заменяем градиентный шаг по всей функции на проксимально-градиентный шаг, а затем переносим на него ту же экстраполяцию Нестерова.

Обычный проксимально-градиентный метод

Проксимальный оператор:

$$\operatorname{prox}_{\alpha g}(v) := \arg\min_x \left\{ g(x) + \frac{1}{2\alpha} \|x - v\|^2 \right\}.$$

При шаге $1/L$:

$$\boxed{x_{k+1} = \operatorname{prox}_{g/L}\left(x_k - \frac{1}{L}\nabla f(x_k) \right).}$$

Если существует $x^\star \in \arg\min F$, то для стандартной инициализации

$$F(x_k) - F^\star \le \frac{L\|x_0 - x^\star\|^2}{2k} = O(1/k).$$

Стоимость шага

Один градиент ∇f плюс одно вычисление $\operatorname{prox}_{g/L}$. Метод особенно полезен, когда prox вычисляется существенно проще, чем исходная негладкая задача напрямую.

FISTA: экстраполяция перед тем же proximal-gradient шагом

Инициализация:

$$y_1 = x_0, \qquad t_1 = 1.$$

Для $k = 1, 2, \ldots$:

$$\boxed{x_k = \operatorname{prox}_{g/L}\left(y_k - \frac{1}{L}\nabla f(y_k)\right),}$$

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2},$$

$$\boxed{y_{k+1} = x_k + \frac{t_k - 1}{t_{k+1}}(x_k - x_{k-1}).}$$

Где именно находится ускорение?

Proximal-gradient отображение не меняется. Ускорение создаёт экстраполяция точки перед его применением.

FISTA = *Fast Iterative Shrinkage-Thresholding Algorithm*.

FISTA: скорость и область применимости

При тех же предпосылках

$$\boxed{F(x_k) - F^\star \leq \frac{2L\|x_0 - x^\star\|^2}{(k+1)^2} = O(1/k^2).}$$

Сравнение:

$$\text{proximal gradient: } O(1/k) \quad \to \quad \text{FISTA: } O(1/k^2).$$

- Если $g \equiv 0$, то $\text{prox}_{g/L}$ — тождественное отображение, и FISTA сводится к ускоренному градиентному методу.
- Если g негладкая, FISTA использует гладкость только f и проксимальную структуру g.
- Цена расширения класса задач — один prox на итерацию.

$$\boxed{\text{proximal gradient} + \text{экстраполяция Нестерова} = \text{FISTA}.}$$

Часть II: исходная задача остаётся обычной

Начинаем с общей детерминированной задачи

$$\min_{x \in \mathbb{R}^d} F(x).$$

Пока никакой специальной структуры F не предполагается; далее считаем F дифференцируемой.

- Если $\nabla F(x)$ дёшев, используем детерминированные методы первого порядка.
- Нас интересует случай, когда точный градиент слишком дорог или практически недоступен, но случайную информацию о нём можно получать существенно дешевле.

Пусть ζ — источник случайности, а

$$g(x, \zeta)$$

— случайная оценка $\nabla F(x)$.

Стохастический оракул первого порядка

Механизм, который по заданной точке x возвращает случайную градиентную информацию $g(x, \zeta)$.

Несмещённая стохастическая оценка градиента

Definition 3 (Несмещённая стохастическая оценка)

Для фиксированного x случайный вектор $g(x, \zeta)$ называется несмещённой оценкой $\nabla F(x)$, если

$$\boxed{\mathbb{E}_\zeta[g(x, \zeta)] = \nabla F(x).}$$

В алгоритме x_k зависит от предыдущих случайностей, поэтому удобна условная запись

$$\boxed{\mathbb{E}[g_k \mid x_k] = \nabla F(x_k).}$$

Она означает: текущая точка уже зафиксирована, а усредняется только новая случайность шага.

Что важно

Отдельная реализация g_k может сильно отличаться от $\nabla F(x_k)$. Несмещённость требует только правильного среднего направления.

Дешёвая стохастическая оценка — дополнительное свойство задачи или способа доступа к ней; для произвольной F она может отсутствовать.

Стохастический градиентный спуск

На итерации k получаем новую случайность ζ_k и строим

$$g_k := g(x_k, \zeta_k), \qquad \mathbb{E}[g_k \mid x_k] = \nabla F(x_k).$$

Тогда SGD задаётся формулой

$$\boxed{x_{k+1} = x_k - \alpha_k g_k,} \qquad \alpha_k > 0.$$

Сравнение:

$$\text{GD: } x_{k+1} = x_k - \alpha_k \nabla F(x_k),$$

$$\text{SGD: } x_{k+1} = x_k - \alpha_k g_k.$$

Глобальная идея

дорогой точный градиент $\longrightarrow$ дешёвая случайная оценка.

Цена экономии — случайный разброс направления. На отдельном шаге значение функции может даже увеличиться.

Первый источник stochastic gradient: конечная сумма

Рассмотрим специальный класс задач

$$\boxed{F(x) = \frac{1}{N}\sum_{i=1}^{N} f_i(x).}$$

Здесь N — число компонент, $f_i : \mathbb{R}^d \to \mathbb{R}$ — компонентные функции. Это дополнительная структура задачи, а не универсальное представление любой F.

Если все f_i дифференцируемы,

$$\nabla F(x) = \frac{1}{N}\sum_{i=1}^{N} \nabla f_i(x).$$

Если N велико и одна компонента существенно дешевле полной суммы, полный градиентный шаг дорог.

Выберем

$$I \sim \mathrm{Unif}\{1, \dots, N\}, \qquad g(x, I) := \nabla f_I(x).$$

Тогда

$$\boxed{\mathbb{E}_I[g(x, I)] = \frac{1}{N}\sum_{i=1}^{N} \nabla f_i(x) = \nabla F(x).}$$

Откуда здесь взялась вероятность?

Функция

$$F(x) = \frac{1}{N} \sum_{i=1}^{N} f_i(x)$$

полностью детерминирована.

Источник случайности

Вероятность вводит сам алгоритм: вместо вычисления всех N компонент мы случайно выбираем индекс I и используем $\nabla f_I(x)$.

Если вычисление компонент имеет сопоставимую стоимость:

- полный градиент: N компонентных градиентов;
- один stochastic gradient: один компонентный градиент.

Поэтому выигрыш — не в точности одного направления, а в его существенно меньшей стоимости.

Эмпирический риск как важный пример конечной суммы

Пусть имеется выборка

$$\mathcal{D} = \{(a_i, b_i)\}_{i=1}^{N},$$

где a_i — признаки объекта, b_i — ответ или метка, x — параметры модели. Потеря на объекте:

$$f_i(x) = \ell(x; a_i, b_i).$$

Эмпирический риск:

$$\boxed{F(x) = \frac{1}{N} \sum_{i=1}^{N} \ell(x; a_i, b_i).}$$

Это важный источник finite-sum-задач, но дальнейший анализ SGD опирается на свойства компонентных градиентов и не требует интерпретации f_i именно как функции потерь.

Пример: линейная регрессия и один шаг SGD

Пусть

$$f_i(x) = \frac{1}{2}(a_i^\top x - b_i)^2.$$

Тогда

$$F(x) = \frac{1}{N}\sum_{i=1}^{N}\frac{1}{2}(a_i^\top x - b_i)^2,$$

$$\nabla F(x) = \frac{1}{N}\sum_{i=1}^{N}(a_i^\top x - b_i)a_i.$$

Для случайного объекта I:

$$\boxed{g(x, I) = (a_I^\top x - b_I)a_I.}$$

Один шаг SGD:

1. выбрать объект I;
2. вычислить ошибку $a_I^\top x - b_I$;
3. получить градиент индивидуальной потери;
4. сразу обновить параметры.

Полный градиент требует сначала обработать все N объектов.

Второй источник stochastic gradient: математическое ожидание

Другой важный класс задач:

$$\boxed{F(x) = \mathbb{E}_{\zeta \sim P}[\varphi(x; \zeta)].}$$

Здесь ζ — случайный элемент с распределением P.

- После взятия ожидания F — обычная детерминированная функция от x.
- Случайность находится в её представлении через сценарии ζ.
- Точное ожидание может быть дорогим, а отдельный сценарий — дешёвым.

При условиях регулярности, допускающих дифференцирование под знаком ожидания,

$$\nabla F(x) = \mathbb{E}_{\zeta}[\nabla_x \varphi(x; \zeta)].$$

Тогда естественная оценка

$$\boxed{g(x, \zeta) = \nabla_x \varphi(x; \zeta)}$$

несмещённа.

Как связаны finite sum и expectation formulation

Если

$$F(x) = \frac{1}{N}\sum_{i=1}^{N} f_i(x), \qquad I \sim \mathrm{Unif}\{1, \dots, N\},$$

то

$$\boxed{F(x) = \mathbb{E}[f_I(x)].}$$

Поэтому конечная сумма — дискретный частный случай постановки через математическое ожидание.
Но для алгоритма существенно не само формальное представление F как ожидания, а возможность получать

$$g(x, \zeta)$$

существенно дешевле точного $\nabla F(x)$.

Дальнейший анализ

Нам уже не принципиально, откуда именно получен g_k. Важны его свойства: несмещённость, второй момент и величина шума.

Шум и два разных ограничения второго порядка

Определим шум

$$\boxed{\xi_k := g_k - \nabla F(x_k).}$$

Тогда

$$g_k = \nabla F(x_k) + \xi_k, \qquad \mathbb{E}[\xi_k \mid x_k] = 0.$$

Часто предполагают

$$\boxed{\mathbb{E}[\|\xi_k\|^2 \mid x_k] \le \sigma^2,}$$

то есть ограничивают средний квадрат отклонения от точного градиента. Другое условие:

$$\boxed{\mathbb{E}[\|g_k\|^2 \mid x_k] \le G^2.}$$

Не путать

Первое ограничивает шум $g_k - \nabla F(x_k)$, второе — полный второй момент самой стохастической оценки. Они не эквивалентны и используются в разных теоремах.

Базовое рекуррентное соотношение для SGD

Пусть $x^\star \in \arg\min F$. Из

$$x_{k+1} = x_k - \alpha_k g_k$$

следует

$$\|x_{k+1} - x^\star\|^2 = \|x_k - x^\star\|^2 - 2\alpha_k \langle g_k, x_k - x^\star \rangle + \alpha_k^2 \|g_k\|^2 .$$

Берём условное ожидание. Несмещённость даёт

$$\mathbb{E}[\langle g_k, x_k - x^\star \rangle \mid x_k] = \langle \nabla F(x_k), x_k - x^\star \rangle .$$

Поэтому

$$\boxed{\begin{aligned}\mathbb{E}[\|x_{k+1} - x^\star\|^2 \mid x_k] = \|x_k - x^\star\|^2 \\ - 2\alpha_k \langle \nabla F(x_k), x_k - x^\star \rangle \\ + \alpha_k^2 \mathbb{E}[\|g_k\|^2 \mid x_k].\end{aligned}}$$

Почему эта рекурсия центральна

Она содержит три части:

$$\underbrace{\|x_k - x^\star\|^2}_{\text{текущая ошибка}} - \underbrace{2\alpha_k \langle \nabla F(x_k), x_k - x^\star \rangle}_{\text{детерминированный прогресс}} + \underbrace{\alpha_k^2 \mathbb{E}\,\|g_k\|^2}_{\text{цена случайности}} .$$

Разные результаты получаются из одной и той же формулы за счёт:

- выпуклости или сильной выпуклости F;
- гладкости;
- ограничений на шум или второй момент;
- выбора постоянного или убывающего шага.

Дальше

Сначала посмотрим, что происходит при постоянном шаге на сильно выпуклой гладкой функции.

Нужное следствие выпуклости и гладкости

Пусть F выпукла и L-гладка. Тогда

$$\boxed{\|\nabla F(x) - \nabla F(y)\|^2 \leq L \langle \nabla F(x) - \nabla F(y), x - y \rangle .}$$

Краткий вывод. Для фиксированного y положим

$$h(z) := F(z) - \langle \nabla F(y), z \rangle .$$

Тогда h выпукла, L-гладка и $\nabla h(y) = 0$, значит y — её точка минимума. По лемме о спуске для шага $1/L$:

$$h\left(x - \frac{1}{L}\nabla h(x)\right) \leq h(x) - \frac{1}{2L}\|\nabla h(x)\|^2 ,$$

а минимальность y даёт нижнюю оценку этим же значением через $h(y)$.

Доказательство неравенства для градиента

Из предыдущих двух оценок

$$F(x) - F(y) - \langle \nabla F(y), x - y \rangle \geq \frac{1}{2L} \|\nabla F(x) - \nabla F(y)\|^2 .$$

Меняем x и y местами и складываем:

$$\boxed{\|\nabla F(x) - \nabla F(y)\|^2 \leq L \langle \nabla F(x) - \nabla F(y), x - y \rangle .}$$

При $y = x^\star$ имеем $\nabla F(x^\star) = 0$, поэтому

$$\boxed{\|\nabla F(x)\|^2 \leq L \langle \nabla F(x), x - x^\star \rangle .}$$

Именно эту форму подставим в рекурсию SGD.

Постоянный шаг: рекурсия с шумом

Пусть F μ-сильно выпукла и L-гладка, а

$$\mathbb{E}[\|\xi_k\|^2 \mid x_k] \le \sigma^2.$$

Поскольку $g_k = \nabla F(x_k) + \xi_k$,

$$\mathbb{E}[\|g_k\|^2 \mid x_k] \le \|\nabla F(x_k)\|^2 + \sigma^2.$$

Для $0 < \alpha \le 1/L$ базовая рекурсия и предыдущая оценка дают

$$\mathbb{E}[\|x_{k+1} - x^\star\|^2 \mid x_k] \le \|x_k - x^\star\|^2 - \alpha \langle \nabla F(x_k), x_k - x^\star \rangle + \alpha^2\sigma^2.$$

Из сильной выпуклости

$$\langle \nabla F(x_k), x_k - x^\star \rangle \ge \mu \|x_k - x^\star\|^2.$$

Следовательно,

$$\boxed{\mathbb{E}\|x_{k+1} - x^\star\|^2 \le (1 - \alpha\mu)\mathbb{E}\|x_k - x^\star\|^2 + \alpha^2\sigma^2.}$$

Шумовая окрестность при постоянном шаге

Обозначим

$$D_k := \mathbb{E}\,\|x_k - x^\star\|^2 .$$

Разворачивая рекурсию,

$$D_k \le (1-\alpha\mu)^k D_0 + \alpha^2\sigma^2 \sum_{j=0}^{k-1} (1-\alpha\mu)^j .$$

Геометрическая сумма не превосходит $1/(\alpha\mu)$:

$$\boxed{D_k \le (1-\alpha\mu)^k D_0 + \frac{\alpha\sigma^2}{\mu}.}$$

Отсюда

$$\boxed{\limsup_{k\to\infty} \mathbb{E}\,\|x_k - x^\star\|^2 \le \frac{\alpha\sigma^2}{\mu}.}$$

Компромисс

Меньший α уменьшает шумовой уровень, но делает $1-\alpha\mu$ ближе к 1 и замедляет начальное стягивание.

Убывающий шаг и условия Роббинса–Монро

Шумовой уровень при постоянном шаге мотивирует

$$\alpha_k \downarrow 0.$$

Классические условия стохастической аппроксимации:

$$\boxed{\sum_{k=0}^{\infty} \alpha_k = \infty, \qquad \sum_{k=0}^{\infty} \alpha_k^2 < \infty.}$$

- Первая сумма расходится: суммарный ресурс движения не должен оказаться конечным.
- Вторая сходится: шум входит в оценки с квадратом шага, и его накопленный эффект должен контролироваться.

Типичный пример:

$$\alpha_k = \frac{c}{k+1}, \qquad c > 0.$$

Оговорка

Эти два условия сами по себе не являются полной теоремой сходимости: нужны дополнительные предпосылки о F и о стохастических оценках.

Теорема: базовая оценка SGD для выпуклой функции

Theorem 4 (Базовая оценка SGD)

Пусть F выпукла и дифференцируема, $x^\star \in \arg\min F$, а

$$\mathbb{E}[g_k \mid x_k] = \nabla F(x_k), \qquad \mathbb{E}[\|g_k\|^2 \mid x_k] \le G^2.$$

Пусть K шагов выполняются с постоянным $\alpha > 0$, и

$$\bar{x}_K := \frac{1}{K} \sum_{k=0}^{K-1} x_k.$$

Тогда

$$\boxed{\mathbb{E}[F(\bar{x}_K)] - F^\star \le \frac{\|x_0 - x^\star\|^2}{2\alpha K} + \frac{\alpha G^2}{2}.}$$

Доказательство: от базовой рекурсии к сумме ошибок

Из базовой рекурсии и $\mathbb{E}[\|g_k\|^2 \mid x_k] \le G^2$:

$$\mathbb{E}[\|x_{k+1} - x^\star\|^2 \mid x_k] \le \|x_k - x^\star\|^2 - 2\alpha \langle \nabla F(x_k), x_k - x^\star \rangle + \alpha^2 G^2.$$

По выпуклости

$$F(x_k) - F^\star \le \langle \nabla F(x_k), x_k - x^\star \rangle .$$

Следовательно,

$$2\alpha(F(x_k) - F^\star) \le \|x_k - x^\star\|^2 - \mathbb{E}[\|x_{k+1} - x^\star\|^2 \mid x_k] + \alpha^2 G^2.$$

Берём полное ожидание и суммируем $k = 0, \dots, K-1$:

$$2\alpha \sum_{k=0}^{K-1} \mathbb{E}[F(x_k) - F^\star] \le \|x_0 - x^\star\|^2 + K\alpha^2 G^2.$$

Доказательство: усреднение и выбор шага

Делим на $2\alpha K$:

$$\frac{1}{K}\sum_{k=0}^{K-1}\mathbb{E}[F(x_k) - F^\star] \leq \frac{\|x_0 - x^\star\|^2}{2\alpha K} + \frac{\alpha G^2}{2}.$$

По выпуклости

$$F(\bar{x}_K) \leq \frac{1}{K}\sum_{k=0}^{K-1} F(x_k),$$

что доказывает теорему.
Если $\|x_0 - x^\star\| \leq R$, оптимизируем правую часть:

$$\boxed{\alpha = \frac{R}{G\sqrt{K}}.}$$

Тогда

$$\boxed{\mathbb{E}[F(\bar{x}_K)] - F^\star \leq \frac{RG}{\sqrt{K}}.}$$

Следовательно,

$$\boxed{K = O(1/\varepsilon^2)}$$

в этой базовой выпуклой постановке. □

Почему в теореме появляется усреднение

Суммирование рекурсии естественно контролирует

$$\frac{1}{K}\sum_{k=0}^{K-1} F(x_k).$$

Выпуклость переводит эту оценку в одну точку:

$$F\left(\frac{1}{K}\sum_{k=0}^{K-1} x_k\right) \le \frac{1}{K}\sum_{k=0}^{K-1} F(x_k).$$

При переменных шагах естественно возникает взвешенное среднее

$$\boxed{\bar{x}_K = \frac{\sum_{k=0}^{K-1} \alpha_k x_k}{\sum_{k=0}^{K-1} \alpha_k}.}$$

Более развитые схемы усреднения связаны с усреднением Поляка–Рупперта.

Важно

Оценка $O(1/\sqrt{K})$ использует выпуклость и ограничение второго момента; гладкость здесь не требуется.

Теорема: SGD для сильно выпуклой гладкой функции

Theorem 5 (Сильно выпуклый случай)

Пусть F μ-сильно выпукла и L-гладка,

$$\mathbb{E}[g_k \mid x_k] = \nabla F(x_k), \qquad \mathbb{E}[\|g_k - \nabla F(x_k)\|^2 \mid x_k] \leq \sigma^2.$$

Выберем $c \geq 2L/\mu$ и

$$\boxed{\alpha_k = \frac{2}{\mu(k+c)}.}$$

Тогда

$$\boxed{\mathbb{E}[F(x_k) - F^\star] \leq \frac{C}{k+c-1},}$$

где

$$C = \max\left\{(c-1)(F(x_0) - F^\star), \frac{2L\sigma^2}{\mu^2}\right\}.$$

В частности, $\mathbb{E}[F(x_k) - F^\star] = O(1/k)$.

Доказательство: одношаговая оценка по функции

По L-гладкости

$$F(x_{k+1}) \leq F(x_k) - \alpha_k \langle \nabla F(x_k), g_k \rangle + \frac{L\alpha_k^2}{2} \|g_k\|^2 .$$

Берём условное ожидание. Из

$$g_k = \nabla F(x_k) + \xi_k, \qquad \mathbb{E}[\xi_k \mid x_k] = 0$$

следует

$$\mathbb{E}[\|g_k\|^2 \mid x_k] \leq \|\nabla F(x_k)\|^2 + \sigma^2.$$

Поэтому

$$\mathbb{E}[F(x_{k+1}) - F^\star \mid x_k] \leq F(x_k) - F^\star - \alpha_k \left(1 - \frac{L\alpha_k}{2}\right) \|\nabla F(x_k)\|^2 + \frac{L\alpha_k^2\sigma^2}{2}.$$

Так как $c \geq 2L/\mu$, имеем $\alpha_k \leq 1/L$.

Доказательство: сильная выпуклость усиливает прогресс

Из μ-сильной выпуклости

$$\boxed{\|\nabla F(x)\|^2 \geq 2\mu(F(x) - F^\star).}$$

Действительно,

$$F(x^\star) \geq F(x) + \langle \nabla F(x), x^\star - x\rangle + \frac{\mu}{2}\|x^\star - x\|^2,$$

откуда

$$F(x) - F^\star \leq \langle \nabla F(x), x - x^\star\rangle - \frac{\mu}{2}\|x - x^\star\|^2 \leq \frac{1}{2\mu}\|\nabla F(x)\|^2.$$

Обозначая

$$a_k := \mathbb{E}[F(x_k) - F^\star],$$

получаем

$$\boxed{a_{k+1} \leq (1 - \mu\alpha_k)a_k + \frac{L\alpha_k^2\sigma^2}{2}.}$$

Доказательство: подстановка шага и индукция

Подставляем

$$\alpha_k = \frac{2}{\mu(k+c)}.$$

Тогда

$$a_{k+1} \leq \left(1 - \frac{2}{k+c}\right) a_k + \frac{B}{(k+c)^2}, \qquad B := \frac{2L\sigma^2}{\mu^2}.$$

Покажем по индукции

$$a_k \leq \frac{C}{k+c-1}, \qquad C \geq \max\{(c-1)a_0, B\}.$$

Если $s = k + c$ и оценка верна для k, то

$$\begin{aligned} a_{k+1} &\leq \frac{s-2}{s}\frac{C}{s-1} + \frac{B}{s^2} \\ &\leq \frac{s-2}{s}\frac{C}{s-1} + \frac{C}{s^2} \leq \frac{C}{s}. \end{aligned}$$

Значит

$$\boxed{\mathbb{E}[F(x_k) - F^\star] = O(1/k).}$$

□

От одной компоненты к мини-батчу

Для конечной суммы

$$F(x) = \frac{1}{N}\sum_{i=1}^{N} f_i(x)$$

вместо одной компоненты можно усреднить b компонент.
Для индексов $I_1, \ldots, I_b$:

$$\boxed{g_B(x) = \frac{1}{b}\sum_{j=1}^{b} \nabla f_{I_j}(x).}$$

Обновление:

$$x_{k+1} = x_k - \alpha_k g_{B_k}(x_k).$$

Крайние случаи:

- $b = 1$ — одна компонента;
- $1 < b < N$ — mini-batch;
- выбор всех N различных компонент — точный полный градиент.

Зачем mini-batch?

Усреднение уменьшает разброс направления, но увеличивает стоимость одного обновления.

Единая мера разброса компонентных градиентов

При фиксированном x определим

$$\sigma^2_{\text{comp}}(x) := \frac{1}{N}\sum_{i=1}^{N} \|\nabla f_i(x) - \nabla F(x)\|^2 .$$

Это средний квадрат отклонения компонентного градиента от полного. Дальше сравним две разные схемы выбора b компонент:

1. независимый выбор с возвращением;
2. равномерный выбор b различных индексов без возвращения.

Обе оценки несмещённы, но их второй центральный момент различается.

Mini-batch с возвращением: дисперсия $1/b$

Пусть $I_1, \ldots, I_b$ независимы и равномерны. Тогда

$$g_B(x) = \frac{1}{b} \sum_{j=1}^{b} \nabla f_{I_j}(x).$$

Введём

$$\eta_j := \nabla f_{I_j}(x) - \nabla F(x), \qquad \mathbb{E}\eta_j = 0.$$

Тогда

$$\begin{aligned} \mathbb{E} \left\| g_B(x) - \nabla F(x) \right\|^2 &= \frac{1}{b^2} \mathbb{E} \left\| \sum_{j=1}^{b} \eta_j \right\|^2 \\ &= \frac{1}{b^2} \sum_{j=1}^{b} \mathbb{E} \left\| \eta_j \right\|^2, \end{aligned}$$

поскольку независимость и нулевые средние уничтожают перекрёстные члены. Следовательно,

$$\boxed{\mathbb{E} \left\| g_B(x) - \nabla F(x) \right\|^2 = \frac{\sigma^2_{\text{comp}}(x)}{b}.}$$

Mini-batch без возвращения: поправка на конечную совокупность

Пусть $B \subset \{1, \dots, N\}$ — равномерное подмножество из b различных индексов. Обозначим

$$d_i := \nabla f_i(x) - \nabla F(x), \qquad \sum_{i=1}^{N} d_i = 0.$$

Имеем

$$\mathbb{P}(i \in B) = \frac{b}{N}, \qquad \mathbb{P}(i, j \in B) = \frac{b(b-1)}{N(N-1)}.$$

Поэтому

$$\mathbb{E}\,\|g_B - \nabla F\|^2 = \frac{1}{b^2}\left[\frac{b}{N}\sum_i \|d_i\|^2 + \frac{b(b-1)}{N(N-1)}\sum_{i \neq j}\langle d_i, d_j\rangle\right].$$

Так как $\sum_i d_i = 0$,

$$\sum_{i \neq j}\langle d_i, d_j\rangle = -\sum_i \|d_i\|^2.$$

С возвращением и без возвращения: прямое сравнение

После упрощения для выбора без возвращения:

$$\boxed{\mathbb{E}\,\|g_B(x) - \nabla F(x)\|^2 = \frac{N-b}{N-1}\,\frac{\sigma^2_{\text{comp}}(x)}{b}.}$$

Сравним:

$$\underbrace{\frac{\sigma^2_{\text{comp}}(x)}{b}}_{\text{с возвращением}} \quad \text{и} \quad \underbrace{\frac{N-b}{N-1}\,\frac{\sigma^2_{\text{comp}}(x)}{b}}_{\text{без возвращения}}.$$

Так как

$$0 \le \frac{N-b}{N-1} \le 1,$$

выбор без возвращения имеет не больший разброс.

- Если $b \ll N$, различие невелико.
- Если $b = N$, без возвращения получаем точный полный градиент и нулевую дисперсию.
- При выборе с возвращением даже при $b = N$ повторы возможны, и дисперсия остаётся σ^2_{comp}/N.

Размер мини-батча: стоимость и дисперсия

$$b \uparrow \quad \Longrightarrow \quad \begin{cases} \text{разброс направления уменьшается,} \\ \text{стоимость одного обновления возрастает.} \end{cases}$$

Поэтому размер mini-batch нельзя выбирать только по дисперсии.

- Большой b даёт более точное направление.
- При фиксированном бюджете компонентных градиентов обновления происходят реже.
- Вычисления внутри mini-batch хорошо распараллеливаются, поэтому арифметическая стоимость и wall-clock time могут различаться.

Принцип

Нужен баланс между стоимостью компонент, уменьшением шума, числом обновлений и возможностями параллельной обработки.

Чем честно измерять стоимость?

Definition 6 (Компонентное градиентное вычисление)

Одно вычисление $\nabla f_i(x)$.

Definition 7 (Эпоха)

Объём вычислений, примерно соответствующий одному полному проходу по всем N компонентам. В empirical risk — один проход по выборке.

Если отбросить последний неполный batch:

метод	компонент на обновление	обновлений на эпоху
SGD	1	N
mini-batch SGD	b	N/b
полный градиент	N	1

Итерации, эпохи и реальное время — разные величины

Для сравнения методов полезно различать

итерации,	компонентные градиенты,	эпохи,	wall-clock time.

Метод может:

- требовать больше итераций, но меньше компонентных вычислений;
- использовать столько же компонентных вычислений, но выполняться быстрее благодаря параллельному mini-batch;
- делать меньше обновлений, но каждое обновление будет намного дороже.

Следствие

Сравнивать GD и SGD только по числу итераций некорректно: стоимость одной итерации радикально различается.

IID sampling и random reshuffling

Теоретическая модель SGD часто использует

$$I_k \overset{\text{iid}}{\sim} \text{Unif}\{1, \dots, N\}.$$

Индекс выбирается независимо с возвращением; одна компонента может встретиться несколько раз до другой.
На практике часто используют *random reshuffling*:

1. случайно переставить все N индексов перед эпохой;
2. пройти по полученному порядку, обычно группируя индексы в mini-batches;
3. перед следующей эпохой снова перемешать.

Тогда каждая компонента используется ровно один раз за эпоху, но выборы внутри эпохи зависимы.

Следствие для теории

Доказательства для iid sampling нельзя буквально переносить на random reshuffling без дополнительного анализа.

Стохастический momentum

Пусть g_k — стохастическая оценка $\nabla F(x_k)$. Чтобы не путать накопленное направление с перемещением v_k heavy ball, обозначим его m_k:

$$\boxed{\begin{aligned} m_{k+1} &= \beta m_k + (1-\beta) g_k, \\ x_{k+1} &= x_k - \alpha_k m_{k+1}, \end{aligned}} \qquad 0 \le \beta < 1.$$

Здесь

- g_k даёт дешёвую новую информацию;
- m_k аккумулирует историю стохастических направлений.

Такое усреднение может сглаживать быстрые случайные колебания и усиливать устойчивое направление движения.

Оговорка

Анализ stochastic momentum отличается и от квадратичного heavy ball, и от детерминированного ускорения Нестерова.

Итоги: детерминированное ускорение

- Квадратичная модель показывает, как обусловленность разделяет быстрые и медленные собственные направления GD.
- Heavy ball добавляет память о предыдущем перемещении; на сильно выпуклой квадратичной задаче

$$\alpha^\star = \frac{4}{(\sqrt{L}+\sqrt{\mu})^2}, \qquad \beta^\star = \left(\frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}\right)^2.$$

- Метод Нестерова даёт на общем гладком выпуклом классе

$$\boxed{O(1/k) \to O(1/k^2)}.$$

- В сильно выпуклом случае

$$\boxed{O(\kappa \log(1/\varepsilon)) \to O(\sqrt{\kappa}\log(1/\varepsilon)).}$$

- Для составных задач $F = f + g$ тот же механизм экстраполяции приводит к FISTA.

Итоги: стохастические методы

Исходная задача остаётся общей задачей $\min F(x)$. Меняется способ получения градиентной информации:

$$\boxed{\nabla F(x_k) \longrightarrow g_k.}$$

Естественные источники g_k:

$$F(x) = \frac{1}{N}\sum_{i=1}^{N} f_i(x), \qquad F(x) = \mathbb{E}_\zeta[\varphi(x;\zeta)].$$

Стохастичность создаёт разброс:

- постоянный шаг $\Rightarrow$ шумовая окрестность;
- убывающий шаг $\Rightarrow$ подавление шума;
- выпуклый случай: $O(1/\sqrt{K})$ для усреднённой итерации;
- сильно выпуклый гладкий случай: $O(1/k)$ при выбранном убывающем шаге.

Mini-batch уменьшает дисперсию ценой более дорогого обновления.