Дополнительные главы оптимизации

Лекция 7. Невыпуклая оптимизация

План лекции

1. Геометрия невыпуклой задачи
2. Градиентный спуск для гладкой невыпуклой функции
3. Седловые точки и отрицательная кривизна
4. Условие Поляка–Лоясиевича

Что меняется при отказе от выпуклости

Для безусловной задачи

$$\min_{x \in \mathbb{R}^n} f(x)$$

с дифференцируемой выпуклой функцией условие

$$\nabla f(x^\star) = 0$$

необходимо и достаточно для глобального минимума.

- Если f выпукла и L-гладка, градиентный метод имеет сублинейную скорость
$$f(x_k) - f^\star = O(1/k).$$
- Если f L-гладкая и μ-сильно выпуклая, минимум единственен, а ошибка убывает геометрически:
$$f(x_k) - f^\star \le Cq^k, \qquad 0 < q < 1.$$

В невыпуклом случае

Стационарность больше не гарантирует ни глобальной, ни локальной оптимальности. Поэтому надо отдельно изучать геометрию стационарных точек и алгоритмические гарантии.

L-гладкость не означает выпуклость

Definition 1 (L-гладкость)

Дифференцируемая функция $f : \mathbb{R}^n \to \mathbb{R}$ называется L-гладкой, если

$$\boxed{\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\| \qquad \forall x, y.}$$

Это условие ограничивает скорость изменения градиента, но не знак кривизны.
Например,

$$f(x) = \sin x$$

невыпукла на $\mathbb{R}$, но

$$|f'(x) - f'(y)| = |\cos x - \cos y| \leq |x - y|,$$

поэтому она 1-гладкая.

Что будет важно дальше

Лемма о спуске и базовая оценка сходимости градиентного метода к стационарности требуют гладкости, но не выпуклости.

Глобальные и локальные точки минимума

Definition 2 (Глобальная точка минимума)

$x^\star$ называется глобальной точкой минимума, если

$$\boxed{f(x^\star) \leq f(x) \qquad \forall x \in \mathbb{R}^n.}$$

Множество всех таких точек обозначается $\arg\min f$.

Definition 3 (Локальная точка минимума)

$x^\star$ называется локальной точкой минимума, если существует $r > 0$ такое, что

$$\boxed{f(x^\star) \leq f(x) \qquad \forall x \in B_r(x^\star),}$$

где

$$B_r(x^\star) = \{x : \|x - x^\star\| < r\}.$$

Если неравенство строго для всех близких $x \neq x^\star$, минимум называется строгим локальным.

Максимумы и соотношение локальной и глобальной оптимальности

Definition 4 (Глобальный и локальный максимумы)

Глобальная точка максимума удовлетворяет

$$f(x^\star) \geq f(x) \qquad \forall x \in \mathbb{R}^n.$$

Локальная точка максимума удовлетворяет

$$f(x^\star) \geq f(x) \qquad \forall x \in B_r(x^\star)$$

для некоторого $r > 0$.

- Глобальный минимум автоматически является локальным.
- Локальный минимум не обязан быть глобальным.
- Аналогично для максимумов.

Характерная особенность невыпуклой задачи

Одна функция может иметь несколько локальных минимумов и максимумов, причём разные локальные минимумы могут иметь разные значения функции.

Стационарная точка первого порядка

В точке с нулевым градиентом линейный член локального разложения функции исчезает, поэтому информация первого порядка сама по себе не определяет характер точки.

Definition 5 (Стационарная точка первого порядка)

Пусть f дифференцируема. Точка x называется стационарной точкой первого порядка, если

$$\boxed{\nabla f(x) = 0.}$$

Существенное отличие от выпуклого случая

Для невыпуклой функции стационарная точка может быть локальным минимумом, локальным максимумом или седловой точкой.

Седловая точка: определение и пример

Definition 6 (Седловая точка)

Стационарная точка $x^\star$ называется седловой, если она не является локальным минимумом или локальным максимумом и в любой её окрестности существуют точки x_+ и x_- такие, что

$$f(x_+) > f(x^\star), \qquad f(x_-) < f(x^\star).$$

Классический пример:

$$f(x, y) = x^2 - y^2, \qquad \nabla f(0, 0) = 0.$$

Но

$$f(t, 0) = t^2 > 0 = f(0, 0), \qquad f(0, t) = -t^2 < 0 = f(0, 0).$$

Следовательно, $(0, 0)$ — седловая точка.

Теорема: необходимое условие первого порядка

Theorem 7 (Необходимое условие первого порядка)

Пусть $f : \mathbb{R}^n \to \mathbb{R}$ *дифференцируема в окрестности* $x^\star$. *Если* $x^\star$ — *локальная точка минимума, то*

$$\boxed{\nabla f(x^\star) = 0.}$$

Идея доказательства

Исследуем функцию вдоль произвольного направления d:

$$\varphi(t) = f(x^\star + td).$$

Локальный минимум в $\mathbb{R}^n$ даёт локальный минимум одномерной функции при $t = 0$; знак разностного отношения справа и слева от нуля заставляет производную быть нулевой.

Доказательство: переход к одномерному направлению

По локальной минимальности существует $r > 0$, такое что

$$f(x^\star) \leq f(x) \qquad \forall x \in B_r(x^\star).$$

Фиксируем произвольное $d \neq 0$. Для достаточно малых $|t|$

$$\|td\| < r,$$

следовательно,

$$f(x^\star + td) \geq f(x^\star).$$

Положим

$$\varphi(t) := f(x^\star + td).$$

Тогда для малых $t > 0$

$$\frac{\varphi(t) - \varphi(0)}{t} \geq 0,$$

а для малых $t < 0$

$$\frac{\varphi(t) - \varphi(0)}{t} \leq 0.$$

Доказательство: почему градиент равен нулю

Поскольку φ дифференцируема в нуле, левая и правая производные совпадают. Поэтому одновременно

$$\varphi'(0) \geq 0, \qquad \varphi'(0) \leq 0,$$

откуда

$$\varphi'(0) = 0.$$

По правилу цепочки

$$\varphi'(0) = \nabla f(x^\star)^\top d.$$

Так как направление d произвольно,

$$\nabla f(x^\star)^\top d = 0 \qquad \forall d \in \mathbb{R}^n.$$

Единственный вектор, ортогональный всем d, — нулевой:

$$\boxed{\nabla f(x^\star) = 0.}$$

Важно

Это необходимое, но не достаточное условие локального минимума.

Одинаковая стационарность — разное локальное поведение

Рассмотрим

$$f_1(x) = x^4, \qquad f_2(x) = -x^4, \qquad f_3(x) = x^3.$$

Во всех случаях

$$f_i'(0) = 0.$$

Но:

- f_1: 0 — строгий локальный минимум;
- f_2: 0 — строгий локальный максимум;
- f_3: 0 не является локальным экстремумом.

Вывод

Градиент не позволяет классифицировать стационарную точку. Следующий естественный объект — матрица вторых производных, то есть матрица Гессе.

Теорема: необходимое условие второго порядка

Пусть

$$H(x) := \nabla^2 f(x).$$

Theorem 8 (Необходимое условие второго порядка)

Пусть $f \in C^2$ в окрестности $x^\star$. Если $x^\star$ — локальная точка минимума, то

$$\boxed{\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \succeq 0.}$$

Первая часть уже следует из необходимого условия первого порядка.
Осталось доказать положительную полуопределённость матрицы Гессе.

Доказательство второго порядка: одномерное разложение

Фиксируем произвольный $d \in \mathbb{R}^n$ и снова положим

$$\varphi(t) = f(x^\star + td).$$

Локальная минимальность даёт

$$\varphi(t) - \varphi(0) \geq 0$$

для всех достаточно малых t.
По необходимому условию первого порядка

$$\nabla f(x^\star) = 0,$$

поэтому

$$\varphi'(0) = \nabla f(x^\star)^\top d = 0.$$

Разложение Тейлора:

$$\varphi(t) = \varphi(0) + \varphi'(0)t + \frac{1}{2}\varphi''(0)t^2 + o(t^2),$$

то есть

$$\varphi(t) - \varphi(0) = \frac{1}{2}\varphi''(0)t^2 + o(t^2).$$

Доказательство второго порядка: знак квадратичной формы

Для $t \neq 0$ делим на $t^2 > 0$:

$$\frac{\varphi(t) - \varphi(0)}{t^2} = \frac{1}{2}\varphi''(0) + \frac{o(t^2)}{t^2}.$$

Левая часть неотрицательна. Переходя к пределу $t \to 0$,

$$\varphi''(0) \geq 0.$$

Но

$$\varphi''(0) = d^\top \nabla^2 f(x^\star) d.$$

Поэтому для любого d

$$\boxed{d^\top \nabla^2 f(x^\star) d \geq 0.}$$

Это и означает

$$\boxed{\nabla^2 f(x^\star) \succeq 0.}$$

Corollary 9 (Локальный максимум)

Если $x^\star$ — локальный максимум, то

$$\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \preceq 0.$$

Теорема: достаточное условие второго порядка

Theorem 10 (Достаточное условие второго порядка)

Пусть $f \in C^2$ в окрестности $x^\star$,

$$\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \succ 0.$$

Тогда $x^\star$ является строгой локальной точкой минимума.

Положительная определённость означает, что

$$m := \lambda_{\min}(\nabla^2 f(x^\star)) > 0$$

и

$$d^\top \nabla^2 f(x^\star) d \geq m \|d\|^2 \qquad \forall d.$$

Доказательство достаточного условия

Обозначим $H^\star = \nabla^2 f(x^\star)$. По Тейлору

$$f(x^\star + d) = f(x^\star) + \nabla f(x^\star)^\top d + \frac{1}{2} d^\top H^\star d + o(\|d\|^2).$$

Так как $\nabla f(x^\star) = 0$,

$$f(x^\star + d) - f(x^\star) \geq \frac{m}{2} \|d\|^2 + o(\|d\|^2).$$

Для достаточно малого ненулевого d

$$|o(\|d\|^2)| \leq \frac{m}{4} \|d\|^2,$$

поэтому

$$f(x^\star + d) - f(x^\star) \geq \frac{m}{4} \|d\|^2 > 0.$$

Следовательно, $x^\star$ — строгий локальный минимум.

Corollary 11

Если $\nabla^2 f(x^\star) \prec 0$, то $x^\star$ — строгий локальный максимум.

Неопределённая матрица Гессе означает седловое поведение

Утверждение 12

Пусть $f \in C^2$, $\nabla f(x^\star) = 0$, а $\nabla^2 f(x^\star)$ имеет хотя бы одно положительное и хотя бы одно отрицательное собственное значение. Тогда $x^\star$ — седловая точка.

Пусть

$$Hv_+ = \lambda_+ v_+, \qquad \lambda_+ > 0,$$

и

$$Hv_- = \lambda_- v_-, \qquad \lambda_- < 0.$$

Тогда по Тейлору для малых $t \neq 0$

$$f(x^\star + tv_+) - f(x^\star) > 0,$$

а

$$f(x^\star + tv_-) - f(x^\star) < 0.$$

Значит, в любой достаточно малой окрестности есть точки с большими и меньшими значениями функции.

Классификация стационарной точки по матрице Гессе

Условие на $\nabla^2 f(x^\star)$	Вывод
$\nabla^2 f(x^\star) \succ 0$	строгий локальный минимум
$\nabla^2 f(x^\star) \prec 0$	строгий локальный максимум
есть положительные и отрицательные собственные значения	седловое поведение; есть направление отрицательной кривизны
$\nabla^2 f(x^\star) \succeq 0$ или $\preceq 0$, но матрица вырождена	информации второго порядка может быть недостаточно

Definition 13 (Вырожденная стационарная точка)

Стационарная точка $x^\star$ называется вырожденной, если $\nabla^2 f(x^\star)$ имеет нулевое собственное значение.

Почему вырожденная матрица Гессе может не классифицировать точку

Для функций

$$x^4, \qquad -x^4, \qquad x^3$$

в точке 0 одновременно

$$f'(0) = 0, \qquad f''(0) = 0.$$

Однако первая функция имеет минимум, вторая максимум, а третья не имеет локального экстремума.

Вывод

Условие

$$\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \succeq 0$$

не является в общем случае достаточным условием локального минимума.

В вырожденной точке для классификации могут понадобиться члены более высокого порядка.

Приближённая стационарность первого и второго порядка

Definition 14 (ε-стационарность первого порядка)

$$\boxed{\|\nabla f(x)\| \le \varepsilon.}$$

Это основной критерий, который естественно возникает в анализе общего гладкого невыпуклого GD.

Definition 15 (Приближённая стационарность второго порядка)

Если $f \in C^2$, то x называется (ε, δ)-стационарной точкой второго порядка, если

$$\boxed{\|\nabla f(x)\| \le \varepsilon, \qquad \lambda_{\min}(\nabla^2 f(x)) \ge -\delta.}$$

Первое условие означает малость градиента, второе — отсутствие существенно отрицательной кривизны.

Что сохраняется без выпуклости

Рассмотрим градиентный метод

$$x_{k+1} = x_k - \alpha_k \nabla f(x_k).$$

Lemma 16 (Лемма о спуске)

Пусть f имеет L-липшицев градиент. Тогда для любых x, y

$$\boxed{f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.}$$

Ключевой факт

Выпуклость не предполагается: лемма следует только из L-гладкости.

Доказательство леммы о спуске: интеграл вдоль отрезка

Положим

$$d := y - x.$$

По основной теореме анализа вдоль пути $x + td$, $t \in [0, 1]$,

$$f(y) - f(x) = \int_0^1 \langle \nabla f(x + td), d \rangle \, dt.$$

Добавим и вычтем $\nabla f(x)$:

$$f(y) - f(x) = \langle \nabla f(x), d \rangle + \int_0^1 \langle \nabla f(x + td) - \nabla f(x), d \rangle \, dt.$$

Остаётся оценить второй интеграл.

Доказательство леммы о спуске: использование гладкости

По Коши–Буняковскому и L-липшицевости градиента

$$\begin{aligned}\langle \nabla f(x+td) - \nabla f(x), d\rangle &\le \|\nabla f(x+td) - \nabla f(x)\|\,\|d\| \\ &\le Lt\,\|d\|^2 .\end{aligned}$$

Поэтому

$$f(y) - f(x) \le \langle \nabla f(x), d\rangle + L\,\|d\|^2 \int_0^1 t\,dt,$$

то есть

$$f(y) - f(x) \le \langle \nabla f(x), d\rangle + \frac{L}{2}\,\|d\|^2 .$$

Подставляя $d = y - x$, получаем лемму.

Что использовано

Только липшицевость градиента; ни выпуклость, ни существование глобального минимума не требуются.

Утверждение: уменьшение за один шаг GD

Утверждение 17 (Одношаговое уменьшение)

Пусть f L-гладкая, не обязательно выпуклая, и

$$x_{k+1} = x_k - \alpha \nabla f(x_k), \qquad \alpha > 0.$$

Тогда

$$\boxed{f(x_{k+1}) \leq f(x_k) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x_k)\|^2 .}$$

Из леммы о спуске при

$$y - x = -\alpha \nabla f(x_k)$$

сразу получаем это неравенство.
При $0 < \alpha < 2/L$ функция строго убывает на каждой нестационарной итерации. При $\alpha = 1/L$:

$$\boxed{f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 .}$$

Что измерять в общем невыпуклом случае

Для выпуклой задачи естественная мера качества —

$$f(x_k) - f^\star.$$

В общем невыпуклом случае малый градиент не контролирует этот глобальный разрыв, поэтому основной доступный критерий — стационарность.
Потребуем только нижнюю ограниченность:

$$\boxed{f_{\inf} := \inf_{x \in \mathbb{R}^n} f(x) > -\infty.}$$

Существование точки, в которой этот инфимум достигается, не требуется.

Следующий результат

Из одношагового уменьшения можно получить оценку на наименьшую норму градиента среди первых K итераций.

Теорема: GD для гладкой невыпуклой функции

Theorem 18 (Сходимость к стационарности)

Пусть f L-гладкая и ограничена снизу. Рассмотрим

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k).$$

Тогда для любого $K \geq 1$

$$\boxed{\min_{0 \leq k < K} \|\nabla f(x_k)\|^2 \leq \frac{2L\big(f(x_0) - f_{\inf}\big)}{K}.}$$

Выпуклость функции не предполагается.

Доказательство теоремы: телескопическая сумма

Одношаговая оценка при $\alpha = 1/L$:

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 .$$

Следовательно,

$$\frac{1}{2L} \|\nabla f(x_k)\|^2 \leq f(x_k) - f(x_{k+1}).$$

Суммируем $k = 0, \ldots, K-1$:

$$\begin{aligned} \frac{1}{2L} \sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 &\leq \sum_{k=0}^{K-1} (f(x_k) - f(x_{k+1})) \\ &= f(x_0) - f(x_K). \end{aligned}$$

Так как $f(x_K) \geq f_{\text{inf}}$,

$$\sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 \leq 2L(f(x_0) - f_{\text{inf}}).$$

Доказательство теоремы: от суммы к лучшей итерации

Имеем

$$K \min_{0 \le k < K} \|\nabla f(x_k)\|^2 \le \sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 .$$

Объединяя с предыдущей оценкой,

$$\boxed{\min_{0 \le k < K} \|\nabla f(x_k)\|^2 \le \frac{2L(f(x_0) - f_{\inf})}{K}.}$$

Если обозначить

$$\Delta_0 := f(x_0) - f_{\inf},$$

то

$$\min_{0 \le k < K} \|\nabla f(x_k)\| \le \sqrt{\frac{2L\Delta_0}{K}}.$$

Следствие: сколько итераций нужно для ε-стационарности

Утверждение 19 (Итерационная сложность)

Чтобы среди первых K итераций гарантированно существовала точка x_k с

$$\|\nabla f(x_k)\| \leq \varepsilon,$$

достаточно

$$\boxed{K \geq \frac{2L\Delta_0}{\varepsilon^2}.}$$

Следовательно,

$$\boxed{K = O(1/\varepsilon^2).}$$

Что означает эта оценка

Она гарантирует малый градиент. Она не утверждает

$$f(x_k) - f^\star \leq \varepsilon$$

и не гарантирует, что найденная точка является локальным или глобальным минимумом.

Утверждение: норма градиента стремится к нулю

Утверждение 20 (Асимптотическая стационарность)

При тех же предположениях

$$\boxed{\|\nabla f(x_k)\| \longrightarrow 0.}$$

Из доказательства основной теоремы для любого K

$$\sum_{k=0}^{K-1} \|\nabla f(x_k)\|^2 \leq 2L\Delta_0.$$

Переходя к $K \to \infty$,

$$\sum_{k=0}^{\infty} \|\nabla f(x_k)\|^2 < \infty.$$

Необходимое условие сходимости ряда из неотрицательных членов:

$$\|\nabla f(x_k)\|^2 \to 0.$$

Что следует для предельных точек — и чего не следует

Из

$$\|\nabla f(x_k)\| \to 0$$

не следует автоматически сходимость самих x_k: последовательность может иметь несколько предельных точек или не иметь конечной предельной точки.

Утверждение 21 (Стационарность предельной точки)

Если подпоследовательность

$$x_{k_j} \to \bar{x},$$

то

$$\boxed{\nabla f(\bar{x}) = 0.}$$

Действительно, по непрерывности градиента

$$\nabla f(\bar{x}) = \lim_{j \to \infty} \nabla f(x_{k_j}) = 0.$$

Граница гарантии первого порядка

GD приводит к малому градиенту, но стационарность первого порядка не различает минимум, максимум и седло.

Утверждение: отрицательная кривизна даёт направление уменьшения

Утверждение 22 (Направление отрицательной кривизны)

Пусть $f \in C^2$ в окрестности стационарной точки $x^\star$. Если существует $v \neq 0$ такое, что

$$\boxed{v^\top \nabla^2 f(x^\star) v < 0,}$$

то $x^\star$ не является локальным минимумом. Более того, для достаточно малых $t \neq 0$

$$f(x^\star + tv) < f(x^\star).$$

Это прямой способ связать матрица Гессе с локальной геометрией функции.

Доказательство: отрицательная кривизна

Поскольку $\nabla f(x^\star) = 0$,

$$f(x^\star + tv) - f(x^\star) = \frac{t^2}{2} v^\top \nabla^2 f(x^\star) v + o(t^2).$$

Обозначим

$$c := -v^\top \nabla^2 f(x^\star) v > 0.$$

Тогда

$$f(x^\star + tv) - f(x^\star) = -\frac{c}{2} t^2 + o(t^2).$$

Для достаточно малого $|t|$

$$|o(t^2)| \leq \frac{c}{4} t^2,$$

поэтому

$$\boxed{f(x^\star + tv) - f(x^\star) \leq -\frac{c}{4} t^2 < 0.}$$

Следовательно, $x^\star$ не может быть локальным минимумом.

Строгая седловая точка

Definition 23 (Строгая седловая точка)

Седловая точка $x^\star$ называется строгой, если

$$\boxed{\lambda_{\min}(\nabla^2 f(x^\star)) < 0.}$$

Если

$$Hv = \lambda v, \qquad \lambda < 0,$$

то

$$v^\top Hv = \lambda \|v\|^2 < 0,$$

поэтому собственный вектор v является направлением отрицательной кривизны.

Не всякое седло строгое

У вырожденного седла матрица Гессе может иметь нулевые собственные значения и не обнаруживать седловую геометрию на втором порядке.

Пример вырожденного седла

Рассмотрим

$$f(x, y) = x^3 - 3xy^2.$$

В точке $(0, 0)$

$$\nabla f(0, 0) = 0, \qquad \nabla^2 f(0, 0) = 0.$$

При этом функция принимает в любой окрестности начала координат как положительные, так и отрицательные значения.
Значит, $(0, 0)$ одновременно:

- стационарная точка;
- вырожденная стационарная точка;
- седловая точка.

Такое седло называется *вырожденным седлом*; матрица Гессе в самой точке его не обнаруживает.

Неподвижная точка градиентного метода

Один шаг градиентного метода задаёт отображение

$$T_\alpha(x) = x - \alpha \nabla f(x).$$

Если $x^\star$ стационарна, то

$$T_\alpha(x^\star) = x^\star,$$

то есть $x^\star$ — неподвижная точка итерационного отображения.
Для строгого седла эта неподвижная точка имеет локально неустойчивое направление, соответствующее отрицательной кривизне.

Утверждение: неустойчивое собственное направление

Утверждение 24 (Локальная неустойчивость)

Пусть $x^\star$ — строгое седло,

$$H := \nabla^2 f(x^\star), \qquad Hv = \lambda v, \qquad \lambda < 0.$$

Тогда для малого скаляра a

$$\boxed{T_\alpha(x^\star + av) - x^\star = a(1 - \alpha\lambda)v + o(|a|).}$$

При этом

$$\boxed{1 - \alpha\lambda = 1 + \alpha|\lambda| > 1.}$$

Следовательно, в линейном приближении малая компонента вдоль v увеличивается после шага GD.

Доказательство локальной неустойчивости

Так как $f \in C^2$ и $\nabla f(x^\star) = 0$,

$$\nabla f(x^\star + av) = \nabla f(x^\star) + aHv + o(|a|) = a\lambda v + o(|a|).$$

Тогда

$$\begin{aligned} T_\alpha(x^\star + av) - x^\star &= av - \alpha \nabla f(x^\star + av) \\ &= av - \alpha(a\lambda v + o(|a|)) \\ &= a(1 - \alpha\lambda)v + o(|a|). \end{aligned}$$

Поскольку $\lambda < 0$,

$$1 - \alpha\lambda = 1 + \alpha|\lambda| > 1.$$

То есть отрицательная кривизна создаёт локально отталкивающее направление.

Локальная динамика в произвольном малом возмущении

Пусть

$$x = x^\star + d.$$

Для малого d

$$\nabla f(x^\star + d) = Hd + o(\|d\|).$$

Поэтому после одного шага

$$\boxed{d_{k+1} = (I - \alpha H)d_k + o(\|d_k\|).}$$

Компонента d_k вдоль собственного направления с отрицательным λ в линейном приближении умножается на число $1 + \alpha|\lambda| > 1$.

Но это не означает автоматического быстрого выхода

Если начать точно в седле, итерации останутся там. Начальная компонента вдоль неустойчивого направления может быть очень мала, а у вырожденного седла отрицательной кривизны второго порядка может вообще не быть.

Зачем добавлять случайное возмущение

Предположим, что на некоторой итерации

$$\|\nabla f(x_k)\| \leq g_{\text{thr}}.$$

Малый градиент не позволяет понять, близки ли мы к локальному минимуму или к седловой области.
Идея: добавить небольшое случайное возмущение

$$\boxed{\widetilde{x}_k = x_k + \xi,}$$

например, выбирая ξ из малого шара

$$\{u : \|u\| \leq r\}.$$

После этого выполнить несколько обычных градиентных шагов из $\widetilde{x}_k$.

Механизм градиентного метода со случайными возмущениями около строгого седла

Пусть $x^\star$ — строгое седло,

$$H^\star := \nabla^2 f(x^\star), \qquad H^\star v = -\gamma v, \quad \gamma > 0.$$

Если текущая точка близка к $x^\star$, локальная динамика усиливает компоненту вдоль v.
Если распределение ξ непрерывно и не сосредоточено в гиперплоскости, то

$$\Pr\{\langle \xi, v \rangle = 0\} = 0.$$

То есть случайное возмущение почти наверное создаёт ненулевую компоненту вдоль v.
Далее линейная динамика усиливает её примерно как

$$|a_{j+1}| \approx (1 + \alpha\gamma)|a_j|.$$

Смысл случайности

Шум не создаёт отрицательную кривизну; он помогает попасть в уже существующее неустойчивое направление.

Схема градиентного метода со случайными возмущениями

1. Пока $\|\nabla f(x_k)\|$ заметно велика, выполнять обычный градиентный шаг.
2. Когда градиент становится мал, добавить небольшое случайное возмущение ξ.
3. Из возмущённой точки выполнить несколько обычных градиентных шагов.
4. Если точка находится в окрестности строгого седла, возникшая компонента вдоль его неустойчивого направления может усиливаться и уводить траекторию из седловой области.

Почему возмущение должно быть небольшим

Слишком большое возмущение может разрушить уже достигнутый прогресс; кроме того, объяснение через матрицу Гессе является локальным и справедливо только в достаточно малой окрестности.

Границы качественной идеи градиентного метода со случайными возмущениями

Возмущение не требуется на каждом шаге: если градиент велик, обычный GD уже имеет заметное направление первого порядка.
Строгий анализ метода требует дополнительных условий:

- контроля изменения матрицы Гессе;
- согласованного выбора радиуса возмущения;
- выбора шага;
- выбора числа последующих градиентных итераций.

Что здесь доказано, а что нет

Мы разобрали механизм выхода из окрестности строгого седла. Полные оценки вероятности и сложности такого выхода требуют отдельной теории.

Почему нужен критерий второго порядка

Условие

$$\|\nabla f(x)\| \leq \varepsilon$$

означает лишь малость градиента и не исключает наличия направления отрицательной кривизны.
Поэтому добавляют условие

$$\lambda_{\min}(\nabla^2 f(x)) \geq -\delta.$$

Итоговый критерий:

$$\boxed{\|\nabla f(x)\| \leq \varepsilon, \qquad \lambda_{\min}(\nabla^2 f(x)) \geq -\delta.}$$

Интерпретация

Нет ни заметного направления спуска первого порядка, ни направления с существенно отрицательной кривизной.

Методы доверительной области и кубической регуляризации используют кривизну более непосредственно, но их подробная теория выходит за рамки этой лекции.

Когда малый градиент снова контролирует глобальную ошибку

Для общей гладкой невыпуклой функции мы доказали

$$\|\nabla f(x_k)\| \to 0,$$

но это не даёт контроля над

$$f(x_k) - f^\star.$$

Чтобы вернуть такую связь без требования выпуклости, нужна дополнительная глобальная геометрическая структура.
Пусть

$$f^\star := \inf_{x \in \mathbb{R}^n} f(x) > -\infty.$$

Definition 25 (Условие Поляка–Лоясиевича)

f удовлетворяет PL-условию с параметром $\mu > 0$, если

$$\boxed{\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu(f(x) - f^\star) \qquad \forall x.}$$

Смысл PL-условия

PL связывает локальную информацию первого порядка с глобальным разрывом по значению функции:

$$\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu(f(x) - f^\star).$$

Если $f(x) - f^\star$ велико, градиент не может быть слишком мал. Эквивалентно,

$$f(x) - f^\star \leq \frac{1}{2\mu}\|\nabla f(x)\|^2.$$

Поэтому малый градиент уже даёт количественный контроль глобального разрыва.

Принципиальная особенность

PL-условие не предполагает выпуклости.

Утверждение: стационарная точка PL-функции оптимальна

Утверждение 26 (Стационарность под PL)

Пусть f удовлетворяет PL-условию. Если

$$\nabla f(x) = 0,$$

то

$$\boxed{f(x) = f^\star.}$$

Следовательно, x — глобальная точка минимума.

Смысл результата

При PL-условии неоптимальных стационарных точек нет: нулевой градиент уже означает достижение глобального оптимального значения.

Доказательство: стационарность под PL

Из PL-условия

$$\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu(f(x) - f^\star).$$

Если $\nabla f(x) = 0$, то

$$0 \geq \mu(f(x) - f^\star).$$

С другой стороны, поскольку $f^\star$ — инфимум,

$$f(x) - f^\star \geq 0.$$

Следовательно,

$$\boxed{f(x) - f^\star = 0,}$$

то есть $f(x) = f^\star$.

Теорема: сильная выпуклость ⇒ PL

Theorem 27 (Сильная выпуклость ⇒ PL)

Пусть f дифференцируема и μ-сильно выпукла:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|^2 \qquad \forall x, y.$$

Тогда

$$\boxed{\frac{1}{2} \|\nabla f(x)\|^2 \geq \mu (f(x) - f^*).}$$

То есть сильная выпуклость автоматически даёт PL с тем же параметром.

Доказательство: подстановка точки минимума

Сильно выпуклая функция имеет единственную точку минимума $x^\star$. В определение сильной выпуклости подставим $y = x^\star$:

$$f^\star \geq f(x) + \langle \nabla f(x), x^\star - x \rangle + \frac{\mu}{2} \|x^\star - x\|^2 .$$

Переносим члены:

$$f(x) - f^\star \leq \langle \nabla f(x), x - x^\star \rangle - \frac{\mu}{2} \|x - x^\star\|^2 .$$

Обозначим

$$a := \nabla f(x), \qquad d := x - x^\star .$$

Остаётся оценить выражение

$$\langle a, d \rangle - \frac{\mu}{2} \|d\|^2 .$$

Доказательство: завершение квадрата

Для любых $a, d \in \mathbb{R}^n$

$$0 \leq \|a - \mu d\|^2 = \|a\|^2 - 2\mu \langle a, d \rangle + \mu^2 \|d\|^2 .$$

После перестановки

$$\boxed{\langle a, d \rangle - \frac{\mu}{2} \|d\|^2 \leq \frac{1}{2\mu} \|a\|^2 .}$$

Следовательно,

$$f(x) - f^\star \leq \frac{1}{2\mu} \|\nabla f(x)\|^2 .$$

Умножая на μ,

$$\boxed{\frac{1}{2} \|\nabla f(x)\|^2 \geq \mu (f(x) - f^\star).}$$

То есть сильная выпуклость $\Rightarrow$ PL.

Невыпуклая функция, удовлетворяющая PL

Рассмотрим

$$\boxed{F(x, y) = (y - x^2)^2.}$$

Глобальный минимум равен нулю и достигается на параболе

$$y = x^2.$$

Функция невыпукла: в точке $(0, 1)$

$$\nabla^2 F(0, 1) = \begin{pmatrix} -4 & 0 \\ 0 & 2 \end{pmatrix},$$

то есть матрица Гессе неопределена.

Задача

Покажем, что несмотря на невыпуклость функция удовлетворяет PL.

Проверка PL для невыпуклого примера

Положим

$$r := y - x^2.$$

Тогда

$$\nabla F(x, y) = \begin{pmatrix} -4xr \\ 2r \end{pmatrix}.$$

Следовательно,

$$\begin{aligned} \|\nabla F(x, y)\|^2 &= 16x^2r^2 + 4r^2 \\ &= 4r^2(4x^2 + 1) \\ &\geq 4r^2. \end{aligned}$$

Но

$$F(x, y) = r^2, \qquad F^\star = 0.$$

Поэтому

$$\boxed{\frac{1}{2}\|\nabla F(x, y)\|^2 \geq 2(F(x, y) - F^\star).}$$

То есть PL выполнено с $\mu = 2$, хотя F невыпукла.

Оговорка к PL-примеру

Пример

$$F(x, y) = (y - x^2)^2$$

показывает, что PL не влечёт выпуклость.
Однако его градиент не является глобально липшицевым на всей $\mathbb{R}^2$.
Поэтому следующая теорема, где одновременно предполагаются

- PL-условие;
- глобальная L-гладкость,

не применяется к этому примеру напрямую без дополнительных ограничений на область траектории.

Разделяем две роли примера

Он демонстрирует независимость PL от выпуклости, но не служит примером для глобальной теоремы L-smooth + PL.

Теорема: линейная сходимость GD под PL

Theorem 28 (Линейная сходимость при PL)

Пусть f L-гладкая и удовлетворяет PL с параметром $\mu > 0$. Выпуклость не предполагается. Рассмотрим

$$x_{k+1} = x_k - \frac{1}{L}\nabla f(x_k).$$

Тогда

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^\star).}$$

Таким образом, PL возвращает глобальную линейную сходимость по значению функции без предположения выпуклости.

Доказательство линейной сходимости под PL

Из L-гладкости

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2L} \|\nabla f(x_k)\|^2 .$$

Из PL

$$\frac{1}{2} \|\nabla f(x_k)\|^2 \geq \mu(f(x_k) - f^\star).$$

Следовательно,

$$f(x_{k+1}) \leq f(x_k) - \frac{\mu}{L}(f(x_k) - f^\star).$$

Вычитая $f^\star$,

$$\boxed{f(x_{k+1}) - f^\star \leq \left(1 - \frac{\mu}{L}\right)(f(x_k) - f^\star).}$$

Итерация этого неравенства даёт теорему.

Следствие: итерационная сложность под PL

Из

$$f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^\star)$$

и неравенства

$$1 - t \leq e^{-t}$$

получаем

$$f(x_k) - f^\star \leq \exp\left(-\frac{\mu}{L} k\right) (f(x_0) - f^\star).$$

Чтобы достичь

$$f(x_k) - f^\star \leq \varepsilon,$$

достаточно

$$\boxed{k \geq \frac{L}{\mu} \log \frac{f(x_0) - f^\star}{\varepsilon}.}$$

Следовательно,

$$\boxed{O\left(\frac{L}{\mu} \log \frac{1}{\varepsilon}\right).}$$

Что даёт PL — и чего оно не даёт

Из PL следует:

- всякая стационарная точка глобально оптимальна;
- малый градиент контролирует $f(x) - f^\star$;
- вместе с L-гладкостью GD имеет линейную сходимость по значению функции.

Но из PL в общем случае не следует:

- выпуклость функции;
- единственность точки минимума;
- положительная определённость матрицы Гессе во всех точках.

Например, у

$$F(x, y) = (y - x^2)^2$$

множество глобальных минимумов содержит целую параболу.

Итоги: общая гладкая невыпуклая функция

Если f L-гладкая и ограничена снизу, то при шаге $1/L$

$$\boxed{\min_{0 \le k < K} \|\nabla f(x_k)\|^2 \le \frac{2L\Delta_0}{K}, \qquad \Delta_0 = f(x_0) - f_{\inf}.}$$

Следовательно,

$$\boxed{K = O(1/\varepsilon^2)}$$

итераций достаточно для поиска ε-стационарной точки первого порядка.

Но

Эта гарантия не различает локальный минимум, локальный максимум и седло.

Итоги: роль второго порядка

Для $f \in C^2$:

- локальный минимум требует

$$\nabla f(x^\star) = 0, \qquad \nabla^2 f(x^\star) \succeq 0;$$

- $\nabla^2 f(x^\star) \succ 0$ достаточна для строгого локального минимума;
- отрицательное собственное значение матрицы Гессе даёт направление локального уменьшения;
- строгая седловая точка имеет локально неустойчивое направление для GD.

Это мотивирует критерий

$$\boxed{\|\nabla f(x)\| \le \varepsilon, \qquad \lambda_{\min}(\nabla^2 f(x)) \ge -\delta.}$$

Итоги: PL возвращает глобальную гарантию

Если дополнительно

$$\frac{1}{2}\|\nabla f(x)\|^2 \geq \mu(f(x) - f^\star),$$

то малый градиент уже означает малый глобальный разрыв.
При L-гладкости

$$\boxed{f(x_k) - f^\star \leq \left(1 - \frac{\mu}{L}\right)^k (f(x_0) - f^\star).}$$

Выпуклость при этом не требуется.

Иерархия

общая невыпуклая задача

$\Downarrow$

стационарность первого порядка

$\Downarrow$

кривизна и стационарность второго порядка

$\Downarrow$

PL связывает стационарность с глобальной оптимальностью

Связь с выпуклой частью курса

Класс функций	Основная гарантия
L-гладкая невыпуклая, ограниченная снизу	$\min \|\nabla f\|^2 = O(1/K)$; приближённая стационарность первого порядка
L-гладкая + PL	глобальная линейная сходимость по значению без выпуклости
выпуклая и L-гладкая	стационарность эквивалентна глобальной оптимальности; $O(1/K)$ по значению
μ-сильно выпуклая и L-гладкая	единственный минимум, PL автоматически, линейная сходимость GD и возможность ускорения

Главный смысл лекции

При ослаблении геометрических предположений меняется не существование математической теории, а уровень гарантии, который можно получить от локальной информации и алгоритма.

Ориентиры по источникам

- MIT 6.7220/15.084 *Nonlinear Optimization*: гладкая невыпуклая оптимизация и stationarity guarantees.
- Stanford EE364b *Convex Optimization II*: smooth nonconvex gradient descent.
- J. Nocedal, S. Wright, *Numerical Optimization*: условия первого и второго порядка и классическая нелинейная оптимизация.
- C. Jin, P. Netrapalli, R. Ge, S. Kakade, M. Jordan: perturbed gradient descent и выход из окрестностей строгих седел.
- H. Karimi, J. Nutini, M. Schmidt: линейная сходимость при условии Поляка–Лоясиевича.