Дополнительные главы оптимизации

Семинар 1. Выпуклость, строгая и сильная выпуклость, гладкость

Задача 1. Условие

Пусть $C \subseteq \mathbb{R}^n$. Докажите, что следующие утверждения эквивалентны:

i. множество C выпукло;

ii. для любой аффинной прямой

$$\ell = \{x_0 + tv : t \in \mathbb{R}\}, \qquad v \neq 0,$$

пересечение $C \cap \ell$ является выпуклым множеством.

Задача 1. Решение: $(i) \Rightarrow (ii)$ I

Докажем обе импликации непосредственно из определения. Напомним, что множество $D \subseteq \mathbb{R}^n$ называется выпуклым, если для любых $u, w \in D$ и любого $\theta \in [0, 1]$ выполняется

$$\theta u + (1 - \theta) w \in D.$$

$(i) \Rightarrow (ii)$.
Предположим, что C выпукло, и зафиксируем произвольную аффинную прямую ℓ. Сначала отметим, что сама прямая выпукла: если $x = x_0 + t_1 v$ и $y = x_0 + t_2 v$, то

$$\theta x + (1 - \theta) y = x_0 + \big(\theta t_1 + (1 - \theta) t_2\big) v \in \ell.$$

Теперь возьмём $x, y \in C \cap \ell$. Для любого $\theta \in [0, 1]$ из выпуклости C следует

$$\theta x + (1 - \theta) y \in C,$$

а из выпуклости прямой ℓ следует

$$\theta x + (1 - \theta) y \in \ell.$$

Значит,

$$\theta x + (1 - \theta) y \in C \cap \ell.$$

Задача 1. Решение: $(ii) \Rightarrow (i)$ I

$(ii) \Rightarrow (i)$.
Предположим теперь, что пересечение C с любой прямой выпукло.
Возьмём произвольные $x, y \in C$.
Если $x = y$, то

$$\theta x + (1 - \theta)y = x \in C$$

для любого $\theta \in [0, 1]$, и требуемое свойство выполнено.
Пусть $x \neq y$. Рассмотрим прямую, проходящую через x и y:

$$\ell = \{x + t(y - x) : t \in \mathbb{R}\}.$$

Поскольку $x, y \in C$ и одновременно $x, y \in \ell$, имеем

$$x, y \in C \cap \ell.$$

По предположению $C \cap \ell$ выпукло. Поэтому для любого $\theta \in [0, 1]$

$$\theta x + (1 - \theta)y \in C \cap \ell.$$

В частности,

$$\theta x + (1 - \theta)y \in C.$$

Так как $x, y \in C$ и $\theta \in [0, 1]$ были произвольны, множество C выпукло.

Задача 1. Решение: $(ii) \Rightarrow (i)$ II

Итак,

$$\boxed{C \text{ выпукло} \quad \Longleftrightarrow \quad C \cap \ell \text{ выпукло для любой прямой } \ell.}$$

Задача 2. Условие

Пусть $x = (x_1, \ldots, x_n) \in \mathbb{R}^n$, а $k \in \{1, \ldots, n\}$. Обозначим через

$$x_{[1]} \geq x_{[2]} \geq \cdots \geq x_{[n]}$$

координаты вектора x, упорядоченные по невозрастанию, и определим

$$s_k(x) = \sum_{j=1}^{k} x_{[j]}.$$

Докажите, что функция $s_k : \mathbb{R}^n \to \mathbb{R}$ выпукла.

Задача 2. Решение I

Идея состоит в том, чтобы представить s_k как поточечный максимум линейных функций, а затем применить правило: поточечный максимум конечного семейства выпуклых функций выпукл. Сначала построим нужное представление. Рассмотрим семейство всех подмножеств индексов мощности k:

$$\mathcal{I}_k = \{I \subseteq \{1, \dots, n\} : |I| = k\}.$$

Для каждого $I \in \mathcal{I}_k$ определим линейную функцию

$$f_I(x) = \sum_{i \in I} x_i.$$

Каждая f_I линейна, следовательно, выпукла.
Ключевой шаг — доказать представление

$$\boxed{s_k(x) = \max_{I \in \mathcal{I}_k} \sum_{i \in I} x_i.}$$

Действительно, пусть $I^\star$ — множество индексов, соответствующих k наибольшим координатам x. Тогда

$$\sum_{i \in I^\star} x_i = x_{[1]} + \cdots + x_{[k]} = s_k(x),$$

поэтому

$$\max_{I \in \mathcal{I}_k} \sum_{i \in I} x_i \geq s_k(x).$$

Задача 2. Решение II

С другой стороны, возьмём произвольное $I \in \mathcal{I}_k$. Пусть выбранные координаты занимают в упорядоченном наборе места

$$1 \leq r_1 < r_2 < \cdots < r_k \leq n.$$

Тогда $r_j \geq j$ для каждого $j = 1, \ldots, k$. Поскольку последовательность $x_{[1]} \geq \cdots \geq x_{[n]}$ невозрастает,

$$x_{[r_j]} \leq x_{[j]} \qquad j = 1, \ldots, k.$$

Следовательно,

$$\sum_{i \in I} x_i = \sum_{j=1}^{k} x_{[r_j]} \leq \sum_{j=1}^{k} x_{[j]} = s_k(x).$$

Это верно для любого $I \in \mathcal{I}_k$, поэтому

$$\max_{I \in \mathcal{I}_k} \sum_{i \in I} x_i \leq s_k(x).$$

Совмещая две оценки, получаем требуемое представление.
Теперь s_k является поточечным максимумом конечного семейства линейных функций:

$$s_k(x) = \max_{I \in \mathcal{I}_k} f_I(x).$$

Задача 2. Решение III

Каждая f_l линейна, следовательно, выпукла. Применяем правило о поточечном максимуме: если $g_1, \ldots, g_m$ выпуклы, то $g = \max_j g_j$ выпукла. В нашем случае это можно сразу проверить по определению: для любых $x, y \in \mathbb{R}^n$ и $\theta \in [0, 1]$

$$\begin{aligned} s_k(\theta x + (1-\theta)y) &= \max_{l \in \mathcal{I}_k} f_l(\theta x + (1-\theta)y) \\ &= \max_{l \in \mathcal{I}_k} \big(\theta f_l(x) + (1-\theta) f_l(y)\big) \\ &\le \theta \max_{l \in \mathcal{I}_k} f_l(x) + (1-\theta) \max_{l \in \mathcal{I}_k} f_l(y) \\ &= \theta s_k(x) + (1-\theta) s_k(y). \end{aligned}$$

Следовательно,

$$\boxed{s_k \text{ выпукла на } \mathbb{R}^n.}$$

Проверка крайних случаев.
При $k = 1$

$$s_1(x) = \max_i x_i,$$

что является стандартным примером поточечного максимума аффинных функций. При $k = n$

$$s_n(x) = \sum_{i=1}^{n} x_i,$$

то есть функция линейна.

Задача 3. Условие

Пусть $C \subseteq \mathbb{R}^n$ — непустое замкнутое выпуклое множество, а $f : \mathbb{R}^n \to \mathbb{R}$ — дифференцируемая выпуклая функция. Для $z \in \mathbb{R}^n$ обозначим через $\Pi_C(z)$ евклидову проекцию точки z на C, то есть единственную точку решения задачи

$$\min_{y \in C} \frac{1}{2}\|y - z\|_2^2.$$

Докажите, что для любого $\eta > 0$ следующие утверждения эквивалентны:

(i) $x^\star$ является точкой глобального минимума задачи

$$\min_{x \in C} f(x);$$

(ii) выполняется равенство неподвижной точки

$$\boxed{x^\star = \Pi_C\left(x^\star - \eta \nabla f(x^\star)\right).}$$

Задача 3. Решение: $(i) \Rightarrow (ii)$ I

Зафиксируем произвольное $\eta > 0$. В доказательстве понадобятся две формы одного и того же условия первого порядка; введём их ровно в момент применения.

$(i) \Rightarrow (ii)$.

Пусть $x^\star$ минимизирует f на C. Применяем условие первого порядка для дифференцируемой выпуклой функции на выпуклом множестве: точка $x^\star \in C$ является точкой глобального минимума тогда и только тогда, когда

$$\nabla f(x^\star)^\top (y - x^\star) \geq 0 \qquad \forall y \in C.$$

Следовательно, для нашей точки $x^\star$ это вариационное неравенство выполнено. Умножим это неравенство на $-\eta < 0$; знак неравенства изменится:

$$-\eta \nabla f(x^\star)^\top (y - x^\star) \leq 0 \qquad \forall y \in C.$$

Но

$$-\eta \nabla f(x^\star) = \big(x^\star - \eta \nabla f(x^\star)\big) - x^\star.$$

Поэтому

$$\Big(\big(x^\star - \eta \nabla f(x^\star)\big) - x^\star\Big)^\top (y - x^\star) \leq 0 \qquad \forall y \in C.$$

Теперь применяем характеризацию евклидовой проекции. Для непустого замкнутого выпуклого множества C и любой точки $z \in \mathbb{R}^n$ единственная проекция $p = \Pi_C(z)$ характеризуется условием

$$(z - p)^\top (y - p) \leq 0 \qquad \forall y \in C.$$

Задача 3. Решение: $(i) \Rightarrow (ii)$ II

Действительно, p минимизирует на C функцию $q(y) = \frac{1}{2}\|y - z\|_2^2$, для которой $\nabla q(y) = y - z$; применение только что сформулированного условия первого порядка к q даёт

$$(p - z)^\top (y - p) \geq 0,$$

что эквивалентно указанной форме. Для непустого замкнутого выпуклого множества C евклидова проекция существует и единственна.[1]
В нашем случае берём

$$z = x^\star - \eta \nabla f(x^\star), \qquad p = x^\star.$$

Полученное выше неравенство в точности имеет вид характеризации проекции, поэтому

$$x^\star = \Pi_C\big(x^\star - \eta \nabla f(x^\star)\big).$$

[1] **Существование следует из непрерывности и коэрцитивности функции $q(y) = \frac{1}{2}\|y - z\|_2^2$ на непустом замкнутом множестве C; единственность — из строгой выпуклости q на выпуклом множестве C.**

Задача 3. Решение: $(ii) \Rightarrow (i)$ I

$(ii) \Rightarrow (i)$.
Пусть теперь

$$x^\star = \Pi_C\big(x^\star - \eta \nabla f(x^\star)\big).$$

Используем ту же характеризацию проекции: из равенства

$$x^\star = \Pi_C\big(x^\star - \eta \nabla f(x^\star)\big)$$

следует

$$\Big(\big(x^\star - \eta \nabla f(x^\star)\big) - x^\star\Big)^\top (y - x^\star) \leq 0 \qquad \forall y \in C.$$

То есть

$$-\eta \nabla f(x^\star)^\top (y - x^\star) \leq 0 \qquad \forall y \in C.$$

Поскольку $\eta > 0$, делим на $-\eta$ и меняем знак неравенства:

$$\nabla f(x^\star)^\top (y - x^\star) \geq 0 \qquad \forall y \in C.$$

Снова применяем условие первого порядка для выпуклой задачи с ограничениями: полученное вариационное неравенство необходимо и достаточно для глобальной оптимальности $x^\star$. Следовательно,

$$x^\star \in \arg\min_{x \in C} f(x).$$

Задача 3. Решение: $(ii) \Rightarrow (i)$ II

Итак, для любого $\eta > 0$

$$\boxed{x^\star \in \arg\min_{x \in C} f(x) \quad \Longleftrightarrow \quad x^\star = \Pi_C\left(x^\star - \eta \nabla f(x^\star)\right).}$$

Задача 4. Условие

Рассмотрим функцию

$$f(x) = \log\left(\sum_{i=1}^{n} e^{x_i}\right), \qquad x \in \mathbb{R}^n.$$

a. Найдите $\nabla f(x)$.
b. Найдите $\nabla^2 f(x)$.
c. Докажите, что f выпукла на $\mathbb{R}^n$.

Задача 4. Решение: (a) I

Обозначим

$$S(x) = \sum_{j=1}^{n} e^{x_j}.$$

Тогда

$$f(x) = \log S(x).$$

Шаг 1. Градиент.
Для каждой координаты i

$$\frac{\partial f}{\partial x_i} = \frac{1}{S(x)} \frac{\partial S(x)}{\partial x_i} = \frac{e^{x_i}}{\sum_{j=1}^{n} e^{x_j}}.$$

Введём обозначение

$$p_i(x) = \frac{e^{x_i}}{\sum_{j=1}^{n} e^{x_j}}.$$

Тогда $p_i(x) > 0$ и

$$\sum_{i=1}^{n} p_i(x) = 1.$$

Следовательно,

$$\boxed{\nabla f(x) = p(x),}$$

где $p = (p_1, \ldots, p_n)^\top$.

Задача 4. Решение: (b) I

Шаг 2. Гессиан.
Дифференцируем p_i по x_j. Если $i = j$, то

$$\frac{\partial p_i}{\partial x_i} = \frac{e^{x_i} S - e^{2x_i}}{S^2} = p_i(1 - p_i).$$

Если $i \neq j$, то

$$\frac{\partial p_i}{\partial x_j} = -\frac{e^{x_i} e^{x_j}}{S^2} = -p_i p_j.$$

Таким образом,

$$\boxed{\nabla^2 f(x) = \mathrm{Diag}(p) - pp^\top.}$$

Задача 4. Решение: (c) I

Шаг 3. Положительная полуопределённость гессиана.
Применим критерий выпуклости второго порядка: поскольку $f \in C^2(\mathbb{R}^n)$ и $\mathbb{R}^n$ открыто и выпукло, достаточно показать

$$\nabla^2 f(x) \succeq 0 \qquad \forall x \in \mathbb{R}^n.$$

По определению симметричная матрица H положительно полуопределена тогда и только тогда, когда $v^\top H v \geq 0$ для всех v. Поэтому возьмём произвольный $v \in \mathbb{R}^n$. Тогда

$$\begin{aligned} v^\top \nabla^2 f(x) v &= v^\top \operatorname{Diag}(p) v - v^\top p p^\top v \\ &= \sum_{i=1}^n p_i v_i^2 - \left(\sum_{i=1}^n p_i v_i \right)^2. \end{aligned}$$

Обозначим

$$\bar{v} = \sum_{i=1}^n p_i v_i.$$

Задача 4. Решение: (c) II

Поскольку $\sum_i p_i = 1$,

$$\begin{aligned}\sum_{i=1}^{n} p_i (v_i - \bar{v})^2 &= \sum_i p_i v_i^2 - 2\bar{v} \sum_i p_i v_i + \bar{v}^2 \sum_i p_i \\ &= \sum_i p_i v_i^2 - 2\bar{v}^2 + \bar{v}^2 \\ &= \sum_i p_i v_i^2 - \bar{v}^2.\end{aligned}$$

Следовательно,

$$v^\top \nabla^2 f(x) v = \sum_{i=1}^{n} p_i (v_i - \bar{v})^2 \geq 0.$$

Это верно для любого v, значит

$$\nabla^2 f(x) \succeq 0 \qquad \forall x \in \mathbb{R}^n.$$

Следовательно, критерий второго порядка даёт

$$\boxed{f(x) = \log\left(\sum_{i=1}^{n} e^{x_i}\right) \text{ выпукла на } \mathbb{R}^n.}$$

Задача 4. Решение: (c) III

Полезное наблюдение.
Если $1 = (1, \dots, 1)^\top$, то

$$\nabla^2 f(x) 1 = 0,$$

поскольку $\mathrm{Diag}(p)1 = p$ и $pp^\top 1 = p$. Поэтому при каждом x гессиан имеет ненулевое направление нулевой кривизны и не является положительно определённым; это согласуется с тождеством

$$f(x + c1) = f(x) + c.$$

Задача 5. Условие

Для каждой из следующих функций определите наиболее точный класс из перечисленных: невыпуклая; выпуклая, но не строго выпуклая; строго выпуклая, но не сильно выпуклая; сильно выпуклая. Все утверждения относятся ко всей указанной области определения.

a. $f(x) = x \log x$, $x \in (0, \infty)$;

b. $f(x) = x^4$, $x \in \mathbb{R}$;

c. $f(x) = \log(1 + e^x)$, $x \in \mathbb{R}$;

d. $f(x) = \frac{1}{2} x^\top Q x$, $x \in \mathbb{R}^n$, где $Q = Q^\top$.

Для пункта (d) дайте ответ в зависимости от спектра матрицы Q.

Задача 5. Решение: (a) I

(a) $f(x) = x \log x$ **на** $(0, \infty)$**.**
Вычислим производные:

$$f'(x) = \log x + 1, \qquad f''(x) = \frac{1}{x}.$$

Для любого $x > 0$

$$f''(x) = \frac{1}{x} > 0.$$

Применяем достаточное условие строгой выпуклости в одномерном случае: если $f \in C^2$ на интервале и $f''(x) > 0$ во всех его точках, то f строго выпукла.
Значит, f строго выпукла на $(0, \infty)$.
Проверим сильную выпуклость. Для C^2-функции на интервале критерий сильной выпуклости имеет вид: f является μ-сильно выпуклой тогда и только тогда, когда $f''(x) \geq \mu$ для всех x области. Поэтому, если бы существовала константа $\mu > 0$, для которой f была бы μ-сильно выпуклой на всём $(0, \infty)$, необходимо было бы

$$\frac{1}{x} \geq \mu \qquad \forall x > 0.$$

Но

$$\inf_{x>0} \frac{1}{x} = 0,$$

поскольку $1/x \to 0$ при $x \to \infty$. Ни одной положительной равномерной нижней границы не существует. Поэтому функция не является сильно выпуклой на всей области.

Задача 5. Решение: (a) II

Итак,

$x \log x$ строго выпукла, но не сильно выпукла на $(0, \infty)$.

Задача 5. Решение: (b) I

(b) $f(x) = x^4$ **на** $\mathbb{R}$**.**
Имеем

$$f'(x) = 4x^3, \qquad f''(x) = 12x^2 \geq 0.$$

Применяем критерий выпуклости второго порядка в одномерном случае: C^2-функция на интервале выпукла тогда и только тогда, когда $f''(x) \geq 0$ во всех точках. Следовательно, f выпукла.
Условия $f''(x) > 0$ во всех точках здесь нет, поскольку

$$f''(0) = 0.$$

Поэтому для строгой выпуклости используем другой стандартный критерий: дифференцируемая функция на интервале строго выпукла, если её производная строго возрастает. Функция

$$f'(x) = 4x^3$$

строго возрастает на $\mathbb{R}$, следовательно, f строго выпукла.
Сильная выпуклость невозможна. По критерию второго порядка для сильной выпуклости существование параметра $\mu > 0$ потребовало бы

$$f''(x) = 12x^2 \geq \mu \qquad \forall x \in \mathbb{R}.$$

Задача 5. Решение: (b) II

При $x = 0$ получили бы

$$0 \geq \mu,$$

что противоречит $\mu > 0$.
Следовательно,

x^4 строго выпукла, но не сильно выпукла на $\mathbb{R}$.

Задача 5. Решение: (c) I

(c) $f(x) = \log(1 + e^x)$ **на** $\mathbb{R}$**.**

Вычислим производные:

$$f'(x) = \frac{e^x}{1 + e^x},$$

$$f''(x) = \frac{e^x}{(1 + e^x)^2}.$$

Для каждого $x \in \mathbb{R}$

$$f''(x) > 0.$$

По достаточному условию $f'' > 0$ на интервале функция строго выпукла. Однако для сильной выпуклости потребовалась бы равномерная нижняя оценка $f''(x) \geq \mu > 0$. Здесь

$$\frac{e^x}{(1 + e^x)^2} \to 0 \quad \text{при } x \to +\infty,$$

и также

$$\frac{e^x}{(1 + e^x)^2} \to 0 \quad \text{при } x \to -\infty.$$

Следовательно,

$$\inf_{x \in \mathbb{R}} f''(x) = 0,$$

Задача 5. Решение: (c) II

и положительной константы μ с $f''(x) \geq \mu$ для всех x не существует.
Значит, функция не сильно выпукла на всей $\mathbb{R}$.
Итак,

$\log(1 + e^x)$ строго выпукла, но не сильно выпукла на $\mathbb{R}$.

Дополнительно отметим, что

$$f''(x) = \frac{e^x}{(1 + e^x)^2} \leq \frac{1}{4},$$

поэтому эта функция является L-гладкой с $L = 1/4$.

Задача 5. Решение: (d) I

(d) $f(x) = \frac{1}{2} x^\top Q x$, $Q = Q^\top$.
Градиент и гессиан равны

$$\nabla f(x) = Qx, \qquad \nabla^2 f(x) = Q.$$

Пусть собственные значения Q равны $\lambda_1, \ldots, \lambda_n$.
Применяем критерий выпуклости второго порядка: для C^2-функции на $\mathbb{R}^n$ выпуклость эквивалентна условию $\nabla^2 f(x) \succeq 0$ во всех точках. Поскольку здесь гессиан постоянен и равен Q,

$$f \text{ выпукла} \quad \Longleftrightarrow \quad Q \succeq 0 \quad \Longleftrightarrow \quad \lambda_i \geq 0 \quad \forall i.$$

Отсюда получаем три случая.

1. Если существует i с $\lambda_i < 0$, то $Q \not\succeq 0$, поэтому f не выпукла.

Задача 5. Решение: (d) II

2. Если $Q \succeq 0$, но Q вырождена, то f выпукла, но не строго выпукла. Действительно, существует ненулевой $v \in \ker Q$. Для $x = 0$, $y = v$ и любого $\theta \in (0, 1)$

$$f(\theta v) = \frac{1}{2}\theta^2 v^\top Q v = 0,$$

и одновременно

$$\theta f(v) + (1 - \theta) f(0) = 0.$$

Получаем равенство вместо строгого неравенства, значит строгой выпуклости нет.

3. Если $Q \succ 0$, то по спектральной характеризации положительной определённости все собственные значения Q строго положительны. Следовательно,

$$\lambda_{\min}(Q) > 0.$$

Положим

$$\mu = \lambda_{\min}(Q).$$

Покажем явно, почему тогда $Q \succeq \mu I$. По определению матричного порядка

$$Q \succeq \mu I \quad \Longleftrightarrow \quad Q - \mu I \succeq 0.$$

Задача 5. Решение: (d) III

Если $\lambda_i(Q)$ — собственные значения Q, то собственные значения матрицы $Q - \mu I$ равны $\lambda_i(Q) - \mu$. Действительно, если $v_i \neq 0$ — собственный вектор Q, соответствующий собственному значению $\lambda_i(Q)$, то

$$Qv_i = \lambda_i(Q)v_i,$$

и поэтому

$$\begin{aligned}(Q - \mu I)v_i &= Qv_i - \mu I v_i \\ &= \lambda_i(Q)v_i - \mu v_i \\ &= (\lambda_i(Q) - \mu)v_i.\end{aligned}$$

Следовательно, тот же вектор v_i является собственным вектором матрицы $Q - \mu I$ с собственным значением $\lambda_i(Q) - \mu$. При $\mu = \lambda_{\min}(Q)$ получаем

$$\lambda_i(Q) - \mu = \lambda_i(Q) - \lambda_{\min}(Q) \geq 0 \qquad \forall i.$$

Следовательно, $Q - \mu I \succeq 0$, то есть

$$Q \succeq \mu I.$$

Задача 5. Решение: (d) IV

Применяем критерий сильной выпуклости второго порядка: f является μ-сильно выпуклой тогда и только тогда, когда $\nabla^2 f(x) \succeq \mu I$ во всех точках. Поскольку $\nabla^2 f(x) = Q$, функция является μ-сильно выпуклой и, следовательно, строго выпуклой.

Итак,

Q имеет отрицательное собственное значение

$$\Rightarrow f \text{ невыпукла,}$$

$Q \succeq 0,\ \lambda_{\min}(Q) = 0$

$$\Rightarrow f \text{ выпукла, но не строго выпукла,}$$

$Q \succ 0$

$$\Rightarrow f \text{ сильно выпукла с } \mu_{\max} = \lambda_{\min}(Q).$$

Задача 6. Условие

Пусть $C \subseteq \mathbb{R}^n$ — открытое выпуклое множество, а $f : C \to \mathbb{R}$ — выпуклая L-гладкая функция, $L > 0$. Пусть $x^\star \in C$ является точкой глобального минимума f на C.

a) Докажите, что для любого $y \in C$

$$\boxed{f(y) - f(x^\star) \leq \frac{L}{2}\|y - x^\star\|_2^2.}$$

b) Дополнительно предположим, что $C = \mathbb{R}^n$. Докажите, что для любого $y \in \mathbb{R}^n$

$$\boxed{\frac{1}{2L}\|\nabla f(y)\|_2^2 \leq f(y) - f(x^\star).}$$

Задача 6. Решение: (a) I

(a) Верхняя оценка ошибки по функции через расстояние до точки минимума.

Так как $x^\star \in C$ и C открыто, точка $x^\star$ является внутренней точкой области. Применяем необходимое условие первого порядка для дифференцируемой функции: во внутренней точке локального (а значит и глобального) минимума градиент равен нулю. Поэтому

$$\nabla f(x^\star) = 0.$$

Теперь применяем лемму о спуске. Она утверждает, что для L-гладкой функции на выпуклом множестве

$$f(v) \leq f(u) + \nabla f(u)^\top (v - u) + \frac{L}{2}\|v - u\|_2^2 \qquad \forall u, v \in C.$$

Берём $u = x^\star$ и $v = y$:

$$f(y) \leq f(x^\star) + \nabla f(x^\star)^\top (y - x^\star) + \frac{L}{2}\|y - x^\star\|_2^2.$$

Поскольку $\nabla f(x^\star) = 0$,

$$f(y) \leq f(x^\star) + \frac{L}{2}\|y - x^\star\|_2^2.$$

Переносим $f(x^\star)$ в левую часть:

$$\boxed{f(y) - f(x^\star) \leq \frac{L}{2}\|y - x^\star\|_2^2.}$$

Задача 6. Решение: (b) I

(b) Нижняя оценка ошибки по функции через норму градиента.
Теперь $C = \mathbb{R}^n$, поэтому для любого $y \in \mathbb{R}^n$ точка

$$z = y - \frac{1}{L}\nabla f(y)$$

также принадлежит области определения.
Применяем ту же лемму о спуске в точке $u = y$, взяв в качестве второй точки $v = z$:

$$f(z) \leq f(y) + \nabla f(y)^\top (z - y) + \frac{L}{2}\|z - y\|_2^2.$$

Но

$$z - y = -\frac{1}{L}\nabla f(y).$$

Следовательно,

$$\nabla f(y)^\top (z - y) = -\frac{1}{L}\|\nabla f(y)\|_2^2,$$

а

$$\frac{L}{2}\|z - y\|_2^2 = \frac{L}{2}\frac{1}{L^2}\|\nabla f(y)\|_2^2 = \frac{1}{2L}\|\nabla f(y)\|_2^2.$$

Задача 6. Решение: (b) II

Подставляем:

$$f(z) \leq f(y) - \frac{1}{L}\|\nabla f(y)\|_2^2 + \frac{1}{2L}\|\nabla f(y)\|_2^2$$
$$= f(y) - \frac{1}{2L}\|\nabla f(y)\|_2^2.$$

Поскольку $x^\star$ — точка глобального минимума,

$$f(x^\star) \leq f(z).$$

Поэтому

$$f(x^\star) \leq f(y) - \frac{1}{2L}\|\nabla f(y)\|_2^2.$$

Переносим слагаемые:

$$\boxed{\frac{1}{2L}\|\nabla f(y)\|_2^2 \leq f(y) - f(x^\star).}$$

Смысл двух оценок.

Задача 6. Решение: (b) III

Вместе получаем

$$\boxed{\frac{1}{2L}\|\nabla f(y)\|_2^2 \leq f(y) - f(x^\star) \leq \frac{L}{2}\|y - x^\star\|_2^2}$$

для случая $C = \mathbb{R}^n$. Левая оценка показывает: большой градиент несовместим с малой ошибкой по значению функции. Правая оценка показывает: для гладкой функции близость к точке минимума по аргументу контролирует ошибку по значению.

Задача 7. Условие

Пусть $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ и

$$f(x) = \frac{1}{2}\|Ax - b\|_2^2, \qquad x \in \mathbb{R}^n.$$

Определим

$$\sigma_{\max}(A) = \max_{\|v\|_2 = 1} \|Av\|_2, \qquad \sigma_{\min}(A) = \min_{\|v\|_2 = 1} \|Av\|_2.$$

a. Найдите $\nabla f(x)$ и $\nabla^2 f(x)$ и докажите выпуклость f.

b. Найдите точную наименьшую неотрицательную константу Липшица градиента $L_\star$.

c. Определите, когда f сильно выпукла, и в этом случае найдите наибольшую константу сильной выпуклости $\mu_\star$.

d. Если A имеет полный ранг по столбцам, выразите число обусловленности

$$\kappa_f = \frac{L_\star}{\mu_\star}$$

через сингулярные числа A.

e. Рассмотрите квадратично регуляризованную функцию

$$f_\lambda(x) = \frac{1}{2}\|Ax - b\|_2^2 + \frac{\lambda}{2}\|x\|_2^2, \qquad \lambda > 0.$$

Найдите для неё лучшие константы L_λ и μ_λ и соответствующее число обусловленности.

Задача 7. Решение: (a) I

(a) Градиент, гессиан и выпуклость.
Раскроем квадрат нормы:

$$f(x) = \frac{1}{2}(Ax - b)^\top (Ax - b)$$
$$= \frac{1}{2}x^\top A^\top Ax - b^\top Ax + \frac{1}{2}b^\top b.$$

Поскольку $A^\top A$ симметрична,

$$\boxed{\nabla f(x) = A^\top (Ax - b),}$$

и

$$\boxed{\nabla^2 f(x) = A^\top A.}$$

Для любого $v \in \mathbb{R}^n$

$$v^\top \nabla^2 f(x) v = v^\top A^\top Av = \|Av\|_2^2 \geq 0.$$

Следовательно, $A^\top A \succeq 0$. Применяем критерий выпуклости второго порядка: C^2-функция на открытом выпуклом множестве выпукла тогда и только тогда, когда её гессиан положительно полуопределён во всех точках. Поэтому

$$\boxed{f \text{ выпукла на } \mathbb{R}^n.}$$

Задача 7. Решение: (b) I

(b) Лучшая константа гладкости.

Для выпуклой C^2-функции L-гладкость эквивалентна матричному неравенству

$$0 \preceq \nabla^2 f(x) \preceq LI \qquad \forall x.$$

Здесь $\nabla^2 f = A^\top A$ постоянно, поэтому наименьшая неотрицательная константа Липшица градиента равна максимальному собственному значению $A^\top A$:

$$L_\star = \lambda_{\max}(A^\top A).$$

По определению сингулярных чисел собственные значения $A^\top A$ равны квадратам сингулярных чисел A, следовательно,

$$\boxed{L_\star = \sigma_{\max}(A)^2.}$$

Если придерживаться соглашения $L > 0$ и $A = 0$, то любая положительная L допустима, а точная нижняя грань допустимых констант равна 0. Проверим это также непосредственно через градиент. Для любых x, y

$$\begin{aligned} \|\nabla f(x) - \nabla f(y)\|_2 &= \|A^\top A(x-y)\|_2 \\ &\le \|A^\top A\|_{\mathrm{op}} \|x-y\|_2 \\ &= \lambda_{\max}(A^\top A)\|x-y\|_2. \end{aligned}$$

Задача 7. Решение: (b) II

Тем самым $L_\star = \lambda_{\max}(A^\top A)$ является допустимой константой. Чтобы увидеть, что меньшая константа невозможна, возьмём единичный собственный вектор $v_{\max}$ матрицы $A^\top A$, соответствующий $\lambda_{\max}$. При $x - y = v_{\max}$ имеем

$$\frac{\|\nabla f(x) - \nabla f(y)\|_2}{\|x - y\|_2} = \|A^\top A v_{\max}\|_2 = \lambda_{\max}(A^\top A).$$

Следовательно, указанная константа действительно наименьшая.

Задача 7. Решение: (c) I

(c) Сильная выпуклость.
Применяем критерий сильной выпуклости второго порядка: C^2-функция является μ-сильно выпуклой тогда и только тогда, когда $\nabla^2 f(x) \succeq \mu I$ во всех точках. В нашей задаче это условие принимает вид

$$A^\top A \succeq \mu I$$

для некоторого $\mu > 0$. Оно возможно тогда и только тогда, когда

$$\lambda_{\min}(A^\top A) > 0.$$

Для $A \in \mathbb{R}^{m \times n}$ имеем

$$\lambda_{\min}(A^\top A) = \sigma_{\min}(A)^2,$$

где $\sigma_{\min}(A) = \min_{\|v\|_2 = 1} \|Av\|_2$. Эта величина положительна тогда и только тогда, когда $\ker A = \{0\}$, то есть A имеет полный ранг по столбцам. Следовательно,

f сильно выпукла	$\iff$	$\sigma_{\min}(A) > 0$
	$\iff$	A имеет полный ранг по столбцам.

Задача 7. Решение: (c) II

В этом случае наибольшая допустимая константа равна

$$\boxed{\mu_\star = \sigma_{\min}(A)^2.}$$

Действительно, неравенство $A^\top A \succeq \mu I$ эквивалентно условиям $\lambda_i(A^\top A) \geq \mu$ для всех i, поэтому максимально возможное μ равно $\lambda_{\min}(A^\top A)$. Если A не имеет полного ранга по столбцам, существует $v \neq 0$ такое, что $Av = 0$. Тогда вдоль направления v

$$\nabla^2 f\, v = A^\top A v = 0,$$

поэтому положительной равномерной нижней границы μI быть не может.

Задача 7. Решение: (d) I

(d) Число обусловленности.
Если A имеет полный ранг по столбцам, то

$$L_\star = \sigma_{\max}(A)^2, \qquad \mu_\star = \sigma_{\min}(A)^2.$$

Поэтому

$$\boxed{\kappa_f = \frac{L_\star}{\mu_\star} = \frac{\sigma_{\max}(A)^2}{\sigma_{\min}(A)^2} = \left(\frac{\sigma_{\max}(A)}{\sigma_{\min}(A)}\right)^2.}$$

Если обозначить

$$\kappa_2(A) = \frac{\sigma_{\max}(A)}{\sigma_{\min}(A)},$$

то

$$\boxed{\kappa_f = \kappa_2(A)^2.}$$

Таким образом, в задаче наименьших квадратов число обусловленности целевой функции связано с матрицей A через квадрат её спектрального числа обусловленности.

Задача 7. Решение: (e) I

(e) Квадратичная регуляризация.

Рассмотрим

$$f_\lambda(x) = \frac{1}{2}\|Ax - b\|_2^2 + \frac{\lambda}{2}\|x\|_2^2, \qquad \lambda > 0.$$

Градиент:

$$\nabla f_\lambda(x) = A^\top(Ax - b) + \lambda x.$$

Гессиан:

$$\boxed{\nabla^2 f_\lambda(x) = A^\top A + \lambda I.}$$

Чтобы найти лучшие константы гладкости и сильной выпуклости, снова используем спектральные критерии: для постоянного симметричного положительно определённого гессиана H наименьшая неотрицательная константа гладкости равна $\lambda_{\max}(H)$, а наибольшая константа сильной выпуклости — $\lambda_{\min}(H)$.

Если собственные значения $A^\top A$ равны $\rho_1, \ldots, \rho_n$, то собственные значения $A^\top A + \lambda I$ равны

$$\rho_i + \lambda.$$

Поэтому

$$\lambda_{\min}(A^\top A + \lambda I) = \lambda_{\min}(A^\top A) + \lambda = \sigma_{\min}(A)^2 + \lambda,$$

Задача 7. Решение: (e) II

и

$$\lambda_{\max}(A^\top A + \lambda I) = \lambda_{\max}(A^\top A) + \lambda = \sigma_{\max}(A)^2 + \lambda.$$

Следовательно,

$$\boxed{\mu_\lambda = \sigma_{\min}(A)^2 + \lambda > 0,}$$

$$\boxed{L_\lambda = \sigma_{\max}(A)^2 + \lambda.}$$

В частности, регуляризация делает функцию сильно выпуклой даже тогда, когда A не имеет полного ранга по столбцам.
Соответствующее число обусловленности равно

$$\boxed{\kappa_\lambda = \frac{L_\lambda}{\mu_\lambda} = \frac{\sigma_{\max}(A)^2 + \lambda}{\sigma_{\min}(A)^2 + \lambda}.}$$

Если A имеет полный ранг по столбцам и $\sigma_{\max}(A) > \sigma_{\min}(A)$, то при $\lambda > 0$

$$\frac{\sigma_{\max}^2 + \lambda}{\sigma_{\min}^2 + \lambda} < \frac{\sigma_{\max}^2}{\sigma_{\min}^2},$$

Задача 7. Решение: (e) III

поскольку после перемножения положительных знаменателей это эквивалентно

$$\lambda\sigma_{\text{min}}^2 < \lambda\sigma_{\text{max}}^2.$$

То есть при полном столбцовом ранге квадратичная регуляризация уменьшает отношение экстремальных масштабов второй производной. Если же A не имеет полного ранга по столбцам, нерегуляризованная функция вообще не является сильно выпуклой, тогда как при любом $\lambda > 0$ регуляризованная задача имеет конечное число обусловленности κ_λ.